Manual de Configuração

Sistema AGIA — Prospecção Tecnológica

Documentação do sistema AGIA

17/10/2026

Sumário

1. Como a configuração é organizada **3**

2. Ciclo de vida: do `.env` ao banco **4**

3. Arquivo `.env` **5**
3.1 Banco de dados 5
3.2 Aplicação 5
3.3 API 6
3.4 Flags de API 6
3.5 MinIO (armazenamento dos gráficos, das figuras e da capa) 6
3.6 ChromaDB (RAG do relatório) 7
3.7 Compilador LaTeX e revisão de língua 7
3.8 Chaves de provedores de IA externos 7
3.9 Endereço do Ollama 8
3.10 Credenciais de busca 8
3.11 Frontend 8

4. Provedores de IA **9**
4.1 Cadastrar um provedor 9
4.2 Escolher o provedor de cada ponto de uso 9
4.3 Remover um provedor 9
4.4 Chaves de API e segurança 10

5. APIs de busca **11**
5.1 Passo a passo 11
5.2 O que acontece sem credencial 11
5.3 Como uma API é escolhida 12

6. Parâmetros da tela Configurações **13**
6.1 Geral 13
6.2 Busca 13
6.3 Inteligência Artificial 14
6.4 Relevância & Qualidade 14
6.5 Extração de Termos 14
6.6 Inferência Estatística 15
6.7 Fuzzy matching 15

7. Relatório: capa, LaTeX e revisão **17**

7.1 Imagem de capa 17
7.2 Compilação de PDF 17
7.3 Revisão de texto 17

8. Configuração pela API **18**

9. Segurança **20**

10. Quando reiniciar o backend **21**

11. Exemplos de cenários **22**

12. Limitações conhecidas **23**

Atualizado em 17/10/2026.

Este manual descreve **tudo o que pode ser configurado** no sistema: variáveis do arquivo `.env`, parâmetros da tela **Configurações**, provedores de IA, APIs de busca, relatório e segurança.

Pré-requisito: o sistema instalado e em execução, com o banco migrado e o backend no ar.

---

1. Como a configuração é organizada

Há **três lugares** onde um valor pode ser definido. Eles não são equivalentes:

Onde	O que fica ali	Quando vale
Arquivo `.env` (na raiz do projeto)	Infraestrutura (banco, MinIO, endereços dos serviços), flags de API e **credenciais**	Infraestrutura e flags: lidas sempre. Credenciais: copiadas para o banco só na **primeira subida**. Não definem mais os parâmetros de comportamento.
Padrões do código	Os valores iniciais de todos os parâmetros de comportamento	Gravados no banco pelo seed automático, na primeira subida.
Banco de dados (tabelas `app_settings`, `search_api_selection`, `llm_provider_configs`, `llm_call_site_bindings`)	Todas as configurações editáveis	Fonte da verdade depois do seed.
Tela Configurações (ou API `/config/*`)	Interface para editar o banco	Onde você deve mudar valores no dia a dia.

Regra prática: para mudar um parâmetro de comportamento ou um modelo de IA, use a **tela Configurações**. O `.env` não controla mais esses valores, em nenhuma subida. Flags de API continuam lidas do `.env` a cada requisição. Credenciais são copiadas do `.env` para o banco na primeira subida; depois disso, altere-as pela tela.

---

2. Ciclo de vida: do `.env` ao banco

Na subida do backend:

1. **Migrações** (`alembic upgrade head`, passo manual da instalação) criam as tabelas de sessão.
2. O backend cria as demais tabelas e executa o **seed**, que preenche as tabelas de configuração.
3. O **seed** só grava valores de cada tabela de configuração **se ela estiver vazia**. Os parâmetros de comportamento vêm dos padrões do código; credenciais vêm do `.env`. Chaves novas introduzidas em versões futuras são acrescentadas sem sobrescrever o que já existe.
4. **Sincronização:** os valores do banco são carregados na memória do backend, e o código passa a usá-los a partir daí.
5. **Edição pela tela:** cada alteração é gravada no banco e aplicada **imediatamente**, sem reiniciar, exceto nos casos listados na seção 10.

Consequência importante: editar parâmetros de comportamento no `.env` não tem efeito. Para mudar um valor, use a tela. Para voltar ao padrão do código, apague a linha da chave na tabela `app_settings` e reinicie o backend: o seed recria a chave com o padrão.

> Se o seu banco foi criado antes desta mudança, alguns valores podem ter vindo do `.env` daquela época (ex.: ano inicial 2010, relevância 0,5). Eles continuam no banco e valem até você alterá-los. Confira na tela **Configurações** o valor vigente.

---

3. Arquivo `.env`

O `.env` é lido pelo sistema na subida e **não deve ser versionado** (nem enviado a repositórios), porque contém credenciais. Ele é criado na instalação, com as variáveis descritas abaixo.

Convenção: o nome da variável é o nome do parâmetro em `UPPER_SNAKE_CASE`. Ex.: `ollama_base_url` -> `OLLAMA_BASE_URL`.

> **Só estas variáveis são lidas do `.env`:** infraestrutura (banco, MinIO, ChromaDB, LaTeX, LanguageTool, endereço do Ollama), flags de API e credenciais. Credenciais são copiadas para o banco só na primeira subida. Os parâmetros de comportamento (busca, IA, extração de termos, inferência, relatório) não estão aqui: seus padrões estão na seção 6 e são alterados pela tela.

3.1 Banco de dados

Variável	Padrão	Descrição	Quando mudar
`DATABASE_URL`	`postgresql+asyncpg://postgres:postgres@localhost:5432/pfc_db`	URL do PostgreSQL. O driver `asyncpg` é usado pelo backend; as migrações usam `psycopg2` automaticamente.	Banco em outro host, porta, usuário ou senha.

3.2 Aplicação

Variável	Padrão	Descrição
`APP_NAME`	`Technology Prospecting API`	Nome exibido na documentação da API e nos logs.
`APP_VERSION`	`0.1.0`	Versão exibida na documentação da API.
`ENVIRONMENT`	`development`	Com `production`, o banco usa pool de conexões; fora disso, conexões são abertas sob demanda. Também controla o formato dos logs.
`DEBUG`	`True`	Modo de depuração do FastAPI. Desligue em ambientes compartilhados.
`LOG_LEVEL`	`INFO`	Nível de log.

Variável	Padrão	Descrição
SQL_ECHO	False	Registra **todas** as queries SQL no log. Ligue só para depurar uma query específica (o log fica muito grande).

3.3 API

Variável	Padrão	Descrição
API_PREFIX	/api/v1	Prefixo de todas as rotas. O frontend assume esse valor. Mudar exige ajustar VITE_API_BASE_URL.
ALLOWED_ORIGINS	["http://localhost:3000","http://localhost:5173","http://localhost:8000"]	Origens autorizadas pelo CORS. **Formato JSON obrigatório.** Inclua a origem do frontend (ex.: http://localhost:5173).

3.4 Flags de API

Variável	Padrão	Descrição
LENS_PATENT_ENABLED	True	Habilita a Lens como fonte de **patentes** na busca final.
LENS_SCHOLARLY_ENABLED	True	Habilita a Lens como fonte de **artigos** na busca final.
OPS_ENABLED	True	Habilita a OPS (Escritório Europeu de Patentes) para patentes.
SCOPUS_ENABLED	True	Habilita a Scopus para artigos.
LENS_ENABLED	True	Liga/desliga **as duas** APIs Lens de uma vez (compatibilidade com versões anteriores).

Essas flags são lidas a cada requisição, na montagem das listas de campos disponíveis para a IA. Na **primeira subida**, OPS_ENABLED e SCOPUS_ENABLED também definem qual API cada família começa ativa. Depois disso, a escolha é feita na tela Configurações › Busca (ver seção 5).

3.5 MinIO (armazenamento dos gráficos, das figuras e da capa)

Variável	Padrão	Descrição
MINIO_ENDPOINT	localhost:9000	Endereço da API S3 (sem http://).

Variável	Padrão	Descrição
MINIO_ACCESS_KEY	minioadmin	Usuário. Deve coincidir com o usuário configurado no serviço MinIO.
MINIO_SECRET_KEY	minioadmin	Senha. Deve coincidir com a senha configurada no serviço MinIO.
MINIO_BUCKET	session-charts	Bucket criado automaticamente na subida.
MINIO_SECURE	False	True para HTTPS.

Se o MinIO não responder, o backend sobe com aviso (minio_bucket_ensure_failed), mas gráficos, anexos e a capa do relatório não são persistidos.

3.6 ChromaDB (RAG do relatório)

Variável	Padrão	Descrição
CHROMA_HOST	localhost	Endereço do serviço ChromaDB.
CHROMA_PORT	8001	Porta no host. A 8000 é a do backend.

3.7 Compilador LaTeX e revisão de língua

Variável	Padrão	Descrição
LATEX_COMPILER_URL	http://localhost:8090	Serviço que compila o .tex em PDF (sob demanda).
LANGUAGETOOL_URL	http://localhost:8010	Serviço de revisão ortográfica e gramatical.

3.8 Chaves de provedores de IA externos

Variável	Padrão	Descrição
LLM_GEMINI_API_KEY	vazio	Chave do Google Gemini. Copiada para o banco na primeira subida; depois, edite pela tela.
LLM_ANTHROPIC_API_KEY	vazio	Chave da Anthropic (é separada de uma assinatura Claude Pro). Mesmo comportamento da chave do Gemini.

O provedor e o modelo de cada ponto de uso são escolhidos na tela (ver seção 4). Os modelos iniciais estão na seção 6.3.

3.9 Endereço do Ollama

Variável	Padrão	Descrição
OLLAMA_BASE_URL	http://localhost:11434	Endereço do servidor compatível com a API da OpenAI. Local: o serviço do Docker. Intranet: o endpoint da intranet. Copiado para o banco na primeira subida.
OLLAMA_API_KEY	vazio	Bearer token. Deixe vazio para o Ollama local, que não exige autenticação.

3.10 Credenciais de busca

Veja a seção 5 para o passo a passo.

Variável	Padrão	Descrição
LENS_API_TOKEN	vazio	Token da API Lens (patentes e artigos).
OPS_CONSUMER_KEY	vazio	Consumer key OAuth2 da OPS (EPO).
OPS_CONSUMER_SECRET	vazio	Consumer secret OAuth2 da OPS.
SCOPUS_API_KEY	vazio	Chave da Scopus (Elsevier).

3.11 Frontend

Variável	Padrão	Descrição
VITE_API_BASE_URL	http://localhost:8000/api/v1	Endereço da API vista pelo navegador. Só mude se o backend estiver em outro endereço. Vale após reiniciar o servidor de desenvolvimento do frontend.

Se essa variável não for definida, o padrão do código é usado.

---

4. Provedores de IA

O sistema usa IA em **cinco pontos de uso** (chamadas), e cada um pode apontar para um provedor diferente:

Ponto de uso	Para que serve
`theme_candidates`	Geração e especificação de variações do tema (Refinamento de Parâmetros).
`probe_query`	Geração da query exploratória.
`final_query`	Geração da query final.
`report_writing`	Redação do texto das seções do relatório.
`report_review`	Sugestões de revisão de texto do relatório.

4.1 Cadastrar um provedor

Tela **Configurações › Inteligência Artificial › Provider**, botão **Adicionar nova configuração**. Campos:

- **Provider:** `gemini`, `anthropic` ou `ollama` (este cobre qualquer servidor compatível com a API da OpenAI: Ollama local ou o LLM da intranet).
- **Modelo:** nome do modelo no provedor (ex.: `gemini-2.0-flash-exp`, `claude-haiku-4-5`, `qwen2.5:3b-instruct`).
- **Base URL:** obrigatória para `ollama`.
- **API key:** obrigatória para `gemini` e `anthropic`; **opcional** para `ollama`.

Uma mesma combinação de provedor, modelo e URL não pode ser cadastrada duas vezes (o sistema recusa com "talvez já exista uma igual").

4.2 Escolher o provedor de cada ponto de uso

Na mesma tela, **Qual IA cada chamada usa**: para cada ponto de uso, escolha uma das configurações cadastradas. A troca vale para a **próxima** chamada.

4.3 Remover um provedor

Remover configuração exclui o cadastro. Os pontos de uso que o usavam precisam ser reapontados antes.

4.4 Chaves de API e segurança

A chave gravada no banco aparece **mascarada** nas listagens da tela. Ela fica guardada no banco, então proteja o acesso ao PostgreSQL (ver seção 9).

---

5. APIs de busca

O sistema consulta **duas famílias** de fontes:

Família	Fontes disponíveis	Padrão na primeira subida
Patentes	OPS (Escritório Europeu de Patentes), Lens Patent	OPS
Artigos	Scopus, Lens Scholarly	Scopus

Também existe a **OpenAlex** (pública, sem chave), usada como complemento para obter resumos que a Scopus não devolve para algumas chaves. Ela não exige configuração.

5.1 Passo a passo

1. **Obtenha as credenciais** (são pessoais; não as envie a repositórios nem por canais inseguros):
   - **OPS:** consumer key e secret, no portal de desenvolvedores do Escritório Europeu de Patentes.
   - **Scopus:** API key, no portal de desenvolvedores da Elsevier.
   - **Lens:** token, em lens.org (serve para patentes e artigos).
2. **Preencha** as credenciais no `.env` antes da primeira subida (elas são copiadas para o banco nessa subida), ou depois em Configurações › Busca e credenciais: `OPS_CONSUMER_KEY`, `OPS_CONSUMER_SECRET`, `SCOPUS_API_KEY` e `LENS_API_TOKEN`.
3. **Escolha a API ativa** de cada família na tela Busca (ou via API, ver seção 8).
4. **Reinicie o backend.** Esse passo é obrigatório: os adaptadores de busca são montados na subida. Sem o reinício, a API que você acabou de configurar **não aparece** como disponível, mesmo com a chave preenchida.

5.2 O que acontece sem credencial

- A família sem credencial é **pulada** na montagem (aviso `container_*_api_skipped ... missing_credentials` no log).
- O sistema sobe normalmente, mas a busca externa daquela família volta **vazia**.
- Com nenhuma API de patentes e nenhuma de artigos configurada, nenhuma prospecção retorna resultados.

5.3 Como uma API é escolhida

- Família **Patentes**: a seleção guarda a API ativa (`ops` ou `lens_patent`).
- Família **Artigos**: idem, com `scopus` ou `lens_scholarly`.
- A tela Busca mostra as opções e o estado de cada uma.

---

6. Parâmetros da tela Configurações

A tela **Configurações** tem seis grupos. Cada parâmetro abaixo é editável, gravado no banco e aplicado ao vivo (exceto os marcados como reinício). Os padrões são os do código; o valor **vigente** é o que aparece na tela.

6.1 Geral

Parâmetro	Chave	Padrão	Para que serve
Modelo de teste	`test_mode`	`false`	Usa respostas falsas em todas as chamadas de IA. Não ligar em uso normal.
Modelo do KeyBERT	`llm_keybert_model`	`distiluse-base-multilingual-cased-v2`	Modelo de embeddings da extração de termos e do RAG. **Reinício obrigatório.**
Timeout do Ollama (s)	`ollama_request_timeout_seconds`	`600`	Espera máxima por chamadas ao servidor Ollama ou compatível.
Corte relativo do RAG	`rag_relative_min_relevance`	`0.75`	Descarta trechos recuperados muito abaixo do melhor.
Top-K do RAG por seção	`rag_top_k_per_section`	`5`	Quantos trechos entram no prompt de cada seção.
Idioma da revisão de texto	`languagetool_language`	`pt-BR`	Idioma do botão Revisão do editor.

6.2 Busca

Parâmetro	Chave	Padrão	Para que serve
Ano inicial padrão	`search_year_from`	`2015`	Início da janela da busca exploratória. Quanto mais antigo, mais lenta e menos focada.
Ano final padrão	`search_year_to`	`2026`	Fim da janela. Não deve ser maior que o ano atual.

Parâmetro	Chave	Padrão	Para que serve
Top-K da probe	`probe_top_k`	`10`	Resultados da busca exploratória. Aumentar encarece a extração de termos.
Top-K da busca final	`final_top_k`	`100`	Resultados da busca final para os agregados. Muito alto pode esbarrar em paginação das APIs.
Credenciais de busca	`lens_api_token`, `ops_consumer_key`, `ops_consumer_secret`, `scopus_api_key`	vazio	Ver seção 5.

6.3 Inteligência Artificial

Tela própria, com provedores e pontos de uso. Ver seção 4.

Os modelos iniciais dos provedores não são parâmetros da tela: são gravados no cadastro do provedor na primeira subida e podem ser alterados lá.

Provedor	Modelo inicial	Observação
`ollama`	`qwen2.5:3b-instruct`	Cadastrado sempre. O endereço vem de `OLLAMA_BASE_URL`.
`gemini`	`gemini-2.0-flash-exp`	Cadastrado só se `LLM_GEMINI_API_KEY` estiver preenchida.
`anthropic`	`claude-haiku-4-5`	Cadastrado só se `LLM_ANTHROPIC_API_KEY` estiver preenchida.

6.4 Relevância & Qualidade

Parâmetro	Chave	Padrão	Para que serve
Threshold de relevância	`relevance_threshold`	`0.4`	Corte mínimo para um resultado ser considerado válido.
Complexidade máxima de query	`llm_max_query_complexity`	`0.6`	Teto de complexidade de query gerada por IA.

6.5 Extração de Termos

Parâmetro	Chave	Padrão	Efeito de aumentar
Peso do título	`term_extraction_title_weight`	`3.0`	Termos dependem mais do título.
Peso do abstract	`term_extraction_abstract_weight`	`1.0`	Abstract domina sobre o título.

Parâmetro	Chave	Padrão	Efeito de aumentar
Threshold de score	`term_extraction_score_threshold`	`0.024`	Menos termos, só os melhores. Se o lote inteiro ficar abaixo, entra o piso abaixo.
Piso de termos devolvidos	`term_extraction_min_returned_terms`	`10`	Mais termos garantidos, possivelmente de qualidade menor.
Penalidade de unigrama	`term_extraction_unigram_penalty`	`-0.4`	Mais negativo favorece termos compostos.
Bônus de bigrama	`term_extraction_bigram_bonus`	`0.0`	Favorece bigramas quando alto.
Bônus de trigrama	`term_extraction_trigram_bonus`	`0.25`	Favorece frases mais longas e específicas.
Penalidade de bigrama ruim	`term_extraction_bad_bigram_penalty`	`-0.8`	Filtra mais padrões gramaticais ruins.
Penalidade de trigrama ruim	`term_extraction_bad_trigram_penalty`	`-0.8`	Idem, para trigramas.
BM25 k1	`term_extraction_bm25_k1`	`1.2`	Termos muito repetidos dominam mais.
BM25 b	`term_extraction_bm25_b`	`0.75`	Penaliza mais documentos longos.
RRF k	`term_extraction_rrf_k`	`60`	Valores altos suavizam a fusão de rankings.
Frequência mínima (C-value)	`term_extraction_cvalue_min_frequency`	`1`	Descarta termos raros.

6.6 Inferência Estatística

Parâmetro	Chave	Padrão	Para que serve
Duração máxima (s)	`statistical_inference_max_duration_seconds`	`60`	Tempo para pedir buscas extras até a amostra saturar.
Threshold de saturação	`statistical_inference_saturation_threshold`	`0.5`	Cobertura mínima estimada.
Threshold de singletons	`statistical_inference_f1_ratio_threshold`	`0.7`	Proporção máxima de itens vistos uma vez.
Mínimo de doubletons	`statistical_inference_f2_min`	`5`	Mínimo de itens vistos duas vezes.
Reamostragens (bootstrap)	`statistical_inference_bootstrap_resamples`	`1000`	Precisão da estabilidade do ranking. Mais = mais lento.
Máximo de títulos (relevância)	`statistical_inference_max_titles_for_relevance`	`20`	Títulos usados na relevância semântica.

6.7 Fuzzy matching

Parâmetro	Chave	Padrão	Para que serve
Threshold de fuzzy match	`depositant_fuzzy_match_threshold`	`90.0`	Similaridade para tratar nomes parecidos como a mesma entidade. Mais baixo agrupa mais (risco de juntar entidades diferentes).

7. Relatório: capa, LaTeX e revisão

7.1 Imagem de capa

Tela **Configurações › Geral › Imagem de capa do relatório**, com recorte. Use **Trocar imagem** para enviar outra capa, ou **Restaurar imagem padrão** para voltar ao brasão do sistema. A capa padrão é enviada ao MinIO automaticamente na subida, se ainda não houver capa. Uma capa enviada pelo usuário nunca é sobrescrita pelo sistema. A imagem recortada é usada na capa do REPTEC.

API: `GET`, `POST` e `DELETE /config/report-cover-image` (o `DELETE` restaura a capa padrão).

7.2 Compilação de PDF

O PDF é gerado pelo serviço `latex-compiler` (container), sob demanda. Limites do compilador:

- Roda **sem internet**: só usa os pacotes instalados no serviço.
- Usa **pdflatex** (`latexmk -pdf -halt-on-error`, limite de 120 s por compilação).
- Não suporta `fontspec` nem XeLaTeX/LuaLaTeX; caracteres fora do alfabeto latino não compilam.

Pacotes disponíveis: `graphicx`, `float`, `tabularx`, `array`, `enumitem`, `caption`, `hyperref`, `setspace` e `babel` (português), além dos que o próprio template carrega (`geometry`, `fancyhdr`, `microtype`, `lastpage`, `titlesec`, `tocloft`, `indentfirst`, `tgtermes`). As coleções LaTeX recomendadas e de fontes também estão instaladas.

Pacotes ausentes: `multirow`, `makecell`, `siunitx`, `wrapfig`, `ulem` e `soul`. Um `\usepackage` desses interrompe a compilação com "File ... .sty not found".

Para adicionar um pacote ao compilador, inclua-o na lista de instalação do serviço `latex-compiler` e reconstrua esse serviço. Isso exige internet no momento do build.

7.3 Revisão de texto

O botão **Revisão** usa o LanguageTool (`LANGUAGETOOL_URL`, idioma `languagetool_language`) e a IA para sugerir correções. Cada sugestão é aplicada ou ignorada individualmente. O sistema recusa sugestões que alterem tempo verbal, pontuação ou maiúsculas.

8. Configuração pela API

Todas as rotas ficam sob `/api/v1`. A documentação interativa fica em http://localhost:8000/docs.

Método e rota	Função
`GET /config/settings`	Lista todas as configurações editáveis, com valor, tipo, categoria e limites.
`PUT /config/settings/{key}`	Altera uma configuração. Corpo: `{"value": "..."}`. **O valor é sempre texto**, mesmo para números e booleanos (ex.: `"2015"`, `"false"`). Aplicada imediatamente.
`GET /config/search-apis`	Mostra as opções de API por família e a ativa.
`PUT /config/search-apis/{family}`	Troca a API ativa. Corpo: `{"active_provider_code": "ops"}`. **Reinício obrigatório.**
`GET /config/llm/providers`	Provedores suportados e se exigem chave ou URL.
`GET /config/llm/configs`	Configurações de IA cadastradas (chave mascarada).
`POST /config/llm/configs`	Cadastra uma configuração de IA.
`PUT /config/llm/configs/{id}`	Altera uma configuração de IA.
`DELETE /config/llm/configs/{id}`	Remove uma configuração de IA.
`GET /config/llm/call-sites`	Mostra qual configuração atende cada ponto de uso.
`PUT /config/llm/call-sites/{call_site}`	Aponta um ponto de uso para outra configuração.
`GET, POST, DELETE /config/report-cover-image`	Imagem de capa do relatório.

Exemplo — alterar o ano inicial da busca:

```
curl -X PUT http://localhost:8000/api/v1/config/settings/search_year_from `
  -H "Content-Type: application/json" `
  -d '{"value": "2015"}'
```

Exemplo — trocar a API de patentes para OPS:

```
curl -X PUT http://localhost:8000/api/v1/config/search-apis/patent `
  -H "Content-Type: application/json" `
  -d '{"active_provider_code": "ops"}'
```

9. Segurança

Itens que **você deve tratar antes de uso compartilhado ou em intranet**:

1. **Senhas padrão.** Os serviços do Docker vêm com senhas de desenvolvimento: PostgreSQL (`postgres`/`postgres`), MinIO (`minioadmin`/`minioadmin`) e pgAdmin (`admin@example.com`/`admin`). Troque antes de expor qualquer porta.
2. **Chaves no banco.** Chaves de API de IA e de busca ficam gravadas no PostgreSQL. Restrinja o acesso ao banco e não faça backup em local aberto.
3. **Arquivo `.env` fora do repositório.** O `.env` real contém chaves. Não o envie a repositórios; confira antes de cada envio de código.
4. **`SECRET_KEY` e `ALGORITHM` não são usados.** O sistema não tem autenticação por token, então esses valores não têm efeito. Não os trate como proteção.
5. **Modo de teste desligado.** `TEST_MODE=False` em uso real. Com ele ligado, a aplicação responde com dados falsos e não chama nenhuma IA.
6. **CORS.** Em `ALLOWED_ORIGINS`, deixe apenas as origens que de fato acessam a API.
7. **Exposição de portas.** Os serviços do Docker publicam portas no host. Em uma máquina compartilhada, limite a interface de cada porta (ex.: `127.0.0.1:5432:5432`) na configuração dos serviços.

---

10. Quando reiniciar o backend

A maior parte das alterações vale na hora. **Reinicie o backend** nestes casos:

Alteração	Motivo
Credenciais de OPS, Scopus ou Lens (novas ou trocadas)	Os adaptadores de busca são montados na subida.
Troca da API ativa de patentes ou artigos	Idem. O backend registra no log o evento `search_api_selection_updated_restart_required`.
Modelo do KeyBERT (`llm_keybert_model`)	Carregado uma vez no boot.
Alteração no `.env` (credenciais e flags)	Lido na subida. Parâmetros de comportamento não são lidos do `.env` (ver seção 2).
`ALLOWED_ORIGINS`, `DATABASE_URL`, `API_PREFIX`	Configuração de subida.

Para reiniciar: interrompa o processo do backend (`Ctrl+C`) e suba de novo.

---

11. Exemplos de cenários

Os ajustes abaixo são feitos na tela **Configurações** (não no `.env`).

Cenário A — Máquina sem acesso a IA externa (padrão). Provedor `ollama` para as queries, com `OLLAMA_BASE_URL=http://localhost:11434` e o modelo baixado. Não precisa de chave de IA. Precisa de chave de busca para obter resultados.

Cenário B — Usar Gemini para as queries e Ollama para o texto do relatório. 1. Cadastre um provedor `gemini` com a chave em Configurações › Inteligência Artificial. 2. Em **Qual IA cada chamada usa**, aponte `theme_candidates`, `probe_query` e `final_query` para o Gemini. 3. Deixe `report_writing` e `report_review` no Ollama.

Cenário C — Servidor de IA da intranet. 1. Cadastre um provedor `ollama` com a Base URL do servidor e, se houver, a API key. 2. Aponte os pontos de uso para essa configuração. 3. Ajuste o timeout do Ollama se o servidor for lento.

Cenário D — Busca mais focada (menos ruído). - Aumente o threshold de relevância (ex.: 0,5) e o corte relativo do RAG. - Reduza o ano inicial se o tema for recente.

Cenário E — Busca mais ampla (mais resultados, mais ruído). - Reduza o threshold de relevância. - Aumente o Top-K da busca final (atenção ao tempo e aos limites das APIs).

Cenário F — Termos mais curtos e genéricos ou mais longos e específicos. - Mais longos: aumente o bônus de trigrama e deixe a penalidade de unigrama mais negativa. - Mais curtos: reduza o bônus de trigrama e aproxime a penalidade de unigrama de zero.

---

12. Limitações conhecidas

- **Valores do `.env` após a primeira subida.** Editar no `.env` parâmetros de comportamento não tem efeito, e editar credenciais também não: ambos já foram gravados no banco. Use a tela.
- **Credenciais novas exigem reinício.** Ver seção 10.
- **Status do Ollama.** A consulta de provedor atual pode indicar `available: true` mesmo com o Ollama parado. Teste com `curl http://localhost:11434/api/tags`.
- **Rodapé da barra lateral.** Em versões anteriores, mostrava valores fixos ("LLM: GEMINI 2.5", "API Artigos: SCOPUS") e não refletia a configuração atual. Para conferir qual IA está em uso, consulte a tela Configurações.
- **Primeira subida precisa de internet** para baixar o modelo de embeddings.
- **Modelo do spaCy.** Ele não é instalado pelos pacotes Python do projeto; instale-o conforme o passo de ambiente Python descrito na instalação. Sem ele, a extração de termos funciona, mas com resultados diferentes.