MINISTÉRIO DA DEFESA
EXÉRCITO BRASILEIRO
DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA
INSTITUTO MILITAR DE ENGENHARIA
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

JOÃO PEDRO BANDEIRA BELCHIOR
CARLOS ALEXANDRE SIQUEIRA DE ALMEIDA

# UTILIZAÇÃO DE INTELIGÊNCIA ARTIFICIAL PARA ANÁLISE E PROSPECÇÃO TECNOLÓGICA ATRAVÉS DA CONSULTA A ARTIGOS E PATENTES

RIO DE JANEIRO
2026

**JOÃO PEDRO BANDEIRA BELCHIOR**
**CARLOS ALEXANDRE SIQUEIRA DE ALMEIDA**

# UTILIZAÇÃO DE INTELIGÊNCIA ARTIFICIAL PARA ANÁLISE E PROSPECÇÃO TECNOLÓGICA ATRAVÉS DA CONSULTA A ARTIGOS E PATENTES

Projeto de Final de Curso apresentado ao Curso de Graduação em Engenharia de Computação do Instituto Militar de Engenharia, como requisito parcial para a obtenção do título de Bacharel em Engenharia de Computação.

Orientadora: Maria Cláudia Reis Cavalcanti, D.Sc.

Coorientadores externos:
Cel QEM José Adalberto França Junior – AGITEC
Maj Giselle de Farias Rosa – AGITEC

**RIO DE JANEIRO**
**2026**

© 2026
INSTITUTO MILITAR DE ENGENHARIA
Praça General Tibúrcio, 80 – Praia Vermelha
Rio de Janeiro – RJ  CEP: 22290-270

Este exemplar é de propriedade do Instituto Militar de Engenharia, que poderá incluí-lo em base de dados, armazenar em computador, microfilmar ou adotar qualquer forma de arquivamento.

É permitida a menção, reprodução parcial ou integral e a transmissão entre bibliotecas deste trabalho, sem modificação de seu texto, em qualquer meio que esteja ou venha a ser fixado, para pesquisa acadêmica, comentários e citações, desde que sem finalidade comercial e que seja feita a referência bibliográfica completa.

Os conceitos expressos neste trabalho são de responsabilidade do(s) autor(es) e do(s) orientador(es).

Bandeira Belchior, João Pedro; Siqueira de Almeida, Carlos Alexandre.

*Utilização de Inteligência Artificial para Análise e Prospecção Tecnológica Através da Consulta a Artigos e Patentes* / João Pedro Bandeira Belchior, Carlos Alexandre Siqueira de Almeida. – Rio de Janeiro, 2026.

67 f.

Orientadora: Maria Cláudia Reis Cavalcanti.

Coorientadores externos: José Adalberto França Junior; Giselle de Farias Rosa.

Projeto de Final de Curso (graduação) – Instituto Militar de Engenharia, Engenharia de Computação, 2026.

1. Inteligência Artificial. 2. Prospecção Tecnológica. 3. Análise de Patentes. 4. Processamento de Linguagem Natural. 5. Exército Brasileiro. 6. Recuperação Aumentada por Geração. 7. Modelos de Linguagem de Grande Escala.

I. Reis Cavalcanti, Maria Cláudia (orient.) II. França Junior, José Adalberto (coorient. externo) III. Rosa, Giselle de Farias (coorient. externa) IV. Título

## AGRADECIMENTOS

Agradecemos ao Instituto Militar de Engenharia (IME) pela formação técnica, científica e humana de excelência, que tornou possível conceber e desenvolver este trabalho.

Agradecemos especialmente à nossa orientadora, Prof.ª Maria Cláudia Reis Cavalcanti, D.Sc., pela confiança depositada na equipe, pelas discussões técnicas, pelas orientações metodológicas e pelo rigor acadêmico com que conduziu o projeto do início ao fim.

À Agência de Gestão e Inovação Tecnológica (AGITEC), pela demanda real que deu origem a este trabalho. Agradecemos em particular aos nossos coorientadores externos, Cel QEM José Adalberto França Junior e Maj Giselle de Farias Rosa, pela coordenação do projeto junto à Agência, pela disponibilidade em compartilhar sua experiência com a elaboração de Relatórios de Prospecção Tecnológica e pelas contribuições que aproximaram a solução das necessidades reais do Exército Brasileiro.

Aos nossos familiares, pela paciência, pelo apoio incondicional e pela compreensão nos inúmeros fins de semana dedicados a este trabalho.

Aos colegas de turma, com quem compartilhamos discussões técnicas, código, café e amizade.

Por fim, à comunidade de software livre e de código aberto, em especial aos mantenedores do Ollama, do ChromaDB, do PostgreSQL, do MinIO e do FastAPI, e às equipes responsáveis pelos modelos Qwen e Gemma. A generosidade deles tornou viável construir uma solução executada integralmente em infraestrutura local.

## RESUMO

Este trabalho apresenta o projeto e a implementação de um sistema baseado em Inteligência Artificial para automatizar a prospecção tecnológica no âmbito do Exército Brasileiro, desenvolvido em atendimento a uma demanda real da Agência de Gestão e Inovação Tecnológica (AGITEC). A partir de um tema fornecido pelo usuário em uma interface *web* guiada, o sistema conduz um *pipeline* de cinco fases — refinamento do tema, busca exploratória, extração de termos candidatos, busca final e geração do relatório — sobre as APIs *Open Patent Services* (OPS), do Escritório Europeu de Patentes, e Scopus, da Elsevier. Modelos de Linguagem de Grande Escala (LLMs), remotos ou executados localmente pela plataforma Ollama e configuráveis por ponto de uso, são direcionados por técnicas de engenharia de *prompt* para propor variações do tema e construir consultas booleanas na sintaxe de cada base. Os termos candidatos são extraídos dos resultados exploratórios por um *pipeline* local de Processamento de Linguagem Natural (PatternRank, BM25F, KeyBERT, fusão por RRF e C-value), sem uso de LLM nessa etapa, e cada decisão relevante é submetida à validação humana. Para evitar consultas excessivamente complexas, propõe-se uma função heurística de complexidade de consulta, empregada em um ciclo de autocorreção por métrica determinística que reinjeta no *prompt* os valores medidos na tentativa anterior. Os documentos da busca final são consolidados em um formato unificado e persistidos em PostgreSQL; a partir deles, geram-se automaticamente os indicadores bibliométricos previstos no padrão REPTEC e as curvas S de patentes e artigos, com a classificação do estágio do ciclo de vida da tecnologia pelos pontos GP/MP/SP, complementados por estimação de completude amostral (Chao1) e de estabilidade de *ranking* (*bootstrap*). O relatório é redigido seção a seção por um LLM com Geração Aumentada por Recuperação (RAG) sobre os documentos indexados no ChromaDB, enquanto números, figuras, seções de texto fixo, citações e bibliografia são produzidos de forma determinística, restringindo o modelo à redação do texto corrido e mitigando alucinações. O resultado é um documento LaTeX no padrão REPTEC, editável e compilável em PDF na própria interface, com os artefatos armazenados no MinIO. O sistema, estruturado em arquitetura hexagonal, foi validado de ponta a ponta com temas reais e consultas efetivamente submetidas às APIs, tanto com modelos de menor porte executados localmente quanto com o modelo hospedado no servidor interno do IME gerenciado pelo Lab MINDS, reduzindo um levantamento que manualmente consome dias de trabalho a um fluxo único, no qual o esforço humano se concentra nos pontos de decisão.



**Palavras-chave:** inteligência artificial; prospecção tecnológica; análise de patentes; modelos de linguagem de grande escala; geração aumentada por recuperação; curva S; Exército Brasileiro.

# Sumário


1 Introdução . . . 3
1.1 Motivação . . . 3
1.2 Caracterização do Problema . . . 4
1.3 Objetivo . . . 5
1.4 Metodologia . . . 6
1.5 Estrutura do Texto . . . 7
2 Fundamentação Teórica . . . 8
2.1 Prospecção Tecnológica . . . 8
2.2 Curva S de Maturidade Tecnológica . . . 11
2.2.1 Distinção entre fase de maturidade (curva S) e *Technology Readiness Level* (TRL) . . . 13
2.2.2 Formalização matemática e pontos de leitura (GP, MP, SP) . . . 13
2.2.3 Avaliação de aderência do modelo logístico . . . 14
2.2.4 Estimação de completude amostral e estabilidade de *ranking* . . . 15
2.3 *Large Language Models* (LLMs) . . . 15
2.4 Engenharia de *Prompt* . . . 17
2.5 *Retrieval-Augmented Generation* (RAG) . . . 17
2.6 Representações Vetoriais e Busca em Espaços Densos . . . 18
2.7 Recuperação de Informação e Extração Terminológica . . . 18
2.8 Princípios SOLID de Projeto de Software . . . 19
3 Solução Proposta . . . 20
3.1 Escopo . . . 20
3.2 Especificação de Requisitos . . . 25
3.2.1 Requisitos Funcionais . . . 25
3.2.2 Requisitos Não Funcionais . . . 27
3.3 Especificação da Arquitetura . . . 29
3.4 Configurações, Parâmetros e Heurísticas Adotadas . . . 32
3.4.1 Seleção e Configuração dos Modelos de Linguagem por Ponto de Uso . . . 33
3.4.2 Arquitetura Defensiva em Camadas para Saída Estruturada . . . 33
3.5 Métrica Proposta: Função de Complexidade de Consulta . . . 34
3.5.1 Autocorreção por Métrica Determinística . . . 34
3.5.2 Definição Matemática da Função de Complexidade . . . 34
3.6 Tecnologias Adotadas e Infraestrutura de Execução . . . 35
3.7 Modelagem do Banco de Dados . . . 36
3.8 Implementação Plenamente Desenvolvida . . . 38
4 *Pipeline* de Processamento . . . 40
4.1 Fase 1: Refinamento do Tema . . . 40
4.2 Fase 2: Busca Exploratória e Filtros Documentais . . . 40
4.3 Fase 3: Extração e Ranqueamento de Termos . . . 41
4.4 Fase 4: Busca Final e Inferência Estatística . . . 42
4.5 Fase 5: Geração e Revisão do Relatório Técnico . . . 42
5 Conclusão . . . 43
5.1 Síntese das Contribuições . . . 43

5.2 Atendimento aos Objetivos . . . 44
5.3 Limitações . . . 45
5.4 Trabalhos Futuros . . . 45
5.5 Considerações Finais . . . 46
Referências . . . 48
Apêndice A PROMPTS DE INTELIGÊNCIA ARTIFICIAL NO PIPELINE DE PROSPECÇÃO . . . 52
A.1 Organização dos *prompts* . . . 52
A.2 Sessão de exemplo . . . 53
A.3 Fase 1: Refinamento do tema . . . 53
A.4 Fase 2: Busca exploratória . . . 54
A.5 Fase 3: Extração de termos . . . 56
A.6 Fase 4: Busca final . . . 56
A.7 Fase 5: Geração do relatório (exemplo completo) . . . 58
Apêndice B CASO DE ESTUDO (CATALISADOR DE PETRÓLEO) . . . 62
B.1 Configuração dos Modelos e Auditoria da Sessão . . . 62
B.2 Parâmetros de Entrada da Pesquisa (*Intake*) . . . 63
B.3 Busca Exploratória e Análise Estrutural de Complexidade . . . 63
B.4 Extração e Pontuação de Termos por PLN Local . . . 65
B.5 Busca Final e Projeção das Curvas S no *Frontend* . . . 66
B.6 Relatório Técnico Final Consolidado (REPTEC 001/2026) . . . 67
B.7 Análise Crítica e Inconsistências Observadas no Relatório Gerado . . . 90
Apêndice C MANUAL VISUAL E TELAS DA INTERFACE GRÁFICA DO SISTEMA AGIA . . . 91
C.1 Gestão de Sessões e Parametrização Inicial . . . 91
C.2 Busca Exploratória e Triagem de Resultados . . . 92
C.3 Mineração de Termos e Sintaxe da Busca Final . . . 93
C.4 Indicadores Bibliométricos e Curvas S . . . 94
C.5 Geração Textual via RAG, Edição LaTeX e Revisão . . . 94
C.6 Configurações Globais e Ponto de Uso de Modelos . . . 96

# 1 Introdução

## 1.1 Motivação

No contexto do desenvolvimento tecnológico, profissionais e técnicos envolvidos em projetos de pesquisa e inovação frequentemente se deparam com um desafio recorrente: a necessidade de identificar, avaliar e validar tecnologias relevantes para suas áreas de atuação. Esse processo demanda um esforço considerável de busca em bases de dados de artigos científicos e registros de patentes [1], exigindo não apenas a localização das tecnologias pertinentes, mas também a verificação de sua atualidade — isto é, se a produção científica sobre o tema permanece ativa e se a tecnologia já atingiu maturidade [2].

A realização manual de um levantamento de prospecção tecnológica envolve, em geral, múltiplas etapas de trabalho: a definição de termos de busca adequados ao domínio investigado, a consulta a diferentes bases de dados com sintaxes e interfaces distintas, a triagem de centenas ou milhares de resultados, a verificação das instituições e pesquisadores mais relevantes no campo, a análise das tendências de publicação ao longo do tempo e, por fim, a consolidação dessas informações em um documento estruturado que possa subsidiar a tomada de decisão. Cada uma dessas etapas, realizada de forma isolada e manual, consome horas ou dias de trabalho de profissionais qualificados [28].

Esse trabalho consome tempo e recursos que poderiam ser direcionados às etapas mais criativas e estratégicas do projeto. A ausência de ferramentas integradas que automatizem esse fluxo de prospecção tecnológica representa um gargalo significativo no ciclo de desenvolvimento de soluções inovadoras. Adicionalmente, a qualidade do resultado depende fortemente da experiência do pesquisador, da abrangência das bases consultadas e da consistência metodológica adotada ao longo do processo — fatores que introduzem variabilidade e risco de viés nos levantamentos produzidos [24].

Diante desse cenário, surge a motivação para o desenvolvimento de uma ferramenta baseada em Inteligência Artificial capaz de integrar-se a *Application Programming Interfaces* (APIs) de bases de patentes e artigos científicos, realizando buscas direcionadas por meio de parâmetros-chave fornecidos pelo usuário. O sistema propõe um ciclo iterativo de validação, no qual o usuário refina progressivamente os critérios de busca, garantindo que os resultados obtidos sejam relevantes e alinhados às necessidades do projeto em questão. Esse ciclo iterativo, como será detalhado no Capítulo 2, é sustentado em boa parte por técnicas de engenharia de *prompt* — a forma como o sistema instrui os modelos de linguagem em cada etapa é, na prática, um dos pilares estruturais da solução, e não um detalhe de implementação secundário, razão pela qual lhe é dedicada uma seção própria da fundamentação teórica.

Ao final desse processo, a ferramenta consolida as informações coletadas em um relatório estruturado e editável, contendo os dados das patentes e artigos mais relevantes sobre o tema, bem como as curvas S que ilustram a evolução e o estágio de maturidade das tecnologias identificadas. Com isso, o usuário é capaz de, a partir da leitura de um único documento, inferir informações estratégicas essenciais — como o grau de consolidação de uma tecnologia, as tendências de pesquisa mais recentes e as lacunas ainda existentes na literatura — subsidiando de forma eficiente e embasada a tomada de decisão para a incorporação dessas tecnologias em seus projetos.

## 1.2 Caracterização do Problema

No âmbito do Exército Brasileiro, técnicos e engenheiros envolvidos em projetos de Pesquisa, Desenvolvimento e Inovação (PD&I) dedicam um tempo significativo à busca manual de tecnologias em bases de artigos científicos e registros de patentes relativas aos temas abordados nesses projetos. Além do esforço de localização, é necessário verificar se essas tecnologias ainda estão em desenvolvimento ativo — tarefa igualmente trabalhosa e sujeita a inconsistências quando realizada sem apoio de ferramentas adequadas.

O problema central não se resume à simples busca de documentos. A dificuldade reside em delimitar e consolidar, de forma coerente, informações provenientes de fontes heterogêneas — as diferentes APIs de patentes e artigos científicos possuem estruturas, campos, metadados e síntese de busca distintas — e transformar esses dados brutos em indicadores estratégicos úteis: quais instituições lideram o desenvolvimento de uma tecnologia, em que fase de maturidade ela se encontra, quais são as tendências recentes de publicação e quais lacunas ainda permanecem em aberto na literatura. Produzir esse panorama de forma confiável exige, além de esforço de pesquisa, critério metodológico rigoroso e capacidade de síntese analítica [28].

Agravando esse cenário, as informações coletadas ao longo do processo permanecem dispersas, sem um documento consolidado que permita ao responsável pelo projeto extrair conclusões de forma rápida e confiável, e construir gráficos baseados nas fontes de pesquisa que estão sendo utilizadas. Essas lacunas comprometem a qualidade das decisões e aumentam o risco de adoção de tecnologias obsoletas ou redundantes, impactando diretamente a eficiência dos projetos de defesa.

Especificamente, as organizações que realizam pesquisa de tecnologias emergentes enfrentam os seguintes desafios:

- A demanda em elaborar uma estratégia de busca coerente e sistemática, capaz de recuperar resultados mais fiéis, relevantes e alinhados aos objetivos da prospecção tecnológica.
- A necessidade de consolidar dados provenientes de múltiplas fontes heterogêneas (patentes e artigos científicos), cujas estruturas e campos diferem entre si, exigindo mapeamento e normalização antes de qualquer análise.
- A análise manual desses dados, que consome tempo e recursos humanos qualificados, sujeita a inconsistências e variações decorrentes da subjetividade do avaliador.
- A ausência de uma ferramenta integrada que combine, em um único fluxo automatizado, busca, análise e geração de relatórios.
- As limitações inerentes ao uso de APIs externas de busca científica e tecnológica: algumas exigem assinatura institucional ou chave de acesso, impõem limites ao número de resultados retornados por consulta, restringem os campos disponíveis para filtragem ou limitam a complexidade das consultas booleanas aceitas. Essas restrições precisam ser contornadas por estratégias de paginação, decomposição de consultas e tratamento de erros.
- O uso de Modelos de Linguagem de Grande Escala (LLMs) remotos pode oferecer qualidade textual elevada, mas implica custos recorrentes por *token*, limites de

contexto e dependência de infraestrutura externa [40], o que é problemático em contextos que exigem sigilo e controle de dados sensíveis. Já os modelos locais reduzem esses riscos, mas impõem requisitos computacionais que podem ser incompatíveis com máquinas comuns.

- A geração automática de relatórios por LLMs está sujeita ao fenômeno de alucinação [13], no qual o modelo produz informações plausíveis, porém factualmente incorretas. A adoção de técnicas como *Retrieval-Augmented Generation* (RAG) e a manutenção de etapas de validação humana são essenciais para mitigar esse risco.

No caso específico do Exército Brasileiro, soma-se a esses desafios a exigência de que os relatórios de prospecção sigam o padrão REPTEC (Relatório de Prospecção Tecnológica), definido pela AGITEC (Agência de Gestão e Inovação Tecnológica) [3], com estrutura e conteúdo mínimo próprios, o que implica trabalho adicional de formatação e organização.

Existe, portanto, um compromisso permanente entre qualidade, custo, privacidade e desempenho que precisa ser gerenciado ao longo de todo o projeto. Modelos remotos tendem a ser mais precisos e rápidos, porém dependem de limites externos e apresentam custo recorrente [5]. Modelos locais garantem controle e privacidade, mas podem ser mais lentos e menos precisos, especialmente em tarefas que exigem geração de texto técnico em português formal.

## 1.3 Objetivo

### Objetivo Geral

O objetivo geral do presente projeto é o desenvolvimento de um sistema inteligente baseado em Inteligência Artificial para automatizar o processo de prospecção tecnológica, por meio da consulta integrada a bases de artigos científicos e patentes, da análise dos resultados recuperados e da geração automática de um relatório técnico consolidado no padrão estabelecido pela AGITEC [3].

### Objetivos Específicos

Para a consecução do objetivo geral, estabeleceram-se os seguintes objetivos específicos:

i. Promover a integração com modelos de linguagem selecionados pelo usuário — remotos, como as famílias Claude, da Anthropic, e Gemini, do Google, ou locais, executados por meio da plataforma Ollama —, configuráveis individualmente para cada ponto de uso do sistema, de modo a viabilizar a geração assistida de estratégias de busca mais coerentes, estruturadas e aderentes ao tema investigado, a partir dos parâmetros fornecidos pelo usuário.

ii. Integrar o sistema às APIs *Open Patent Services* (OPS) do Escritório Europeu de Patentes (EPO) e Scopus da Elsevier, viabilizando a recuperação automatizada de patentes e artigos científicos a partir de parâmetros fornecidos pelo usuário.

iii. Implementar módulos de construção de consultas (*query builders*) capazes de transformar termos de busca em consultas estruturadas, compatíveis com a sintaxe de cada API, incluindo o uso de operadores booleanos, filtros temporais e campos específicos.

iv. Desenvolver um mecanismo de geração e refinamento de termos e consultas de busca por meio de LLMs, combinado a um pipeline de processamento de linguagem natural local para extração e pontuação de termos candidatos a partir dos resultados exploratórios, de modo a ampliar a cobertura temática e garantir a qualidade das consultas submetidas às APIs externas.

v. Implementar um ciclo iterativo de validação humana que permita ao usuário aprovar, ajustar ou rejeitar os termos e consultas gerados pelo modelo antes da execução das buscas definitivas.

vi. Consolidar os metadados heterogêneos retornados pelas diferentes APIs em um formato interno unificado, realizando agregações por ano, por depositante ou instituição, e por classificação tecnológica ou área de estudo, utilizando técnicas de inferência estatística, a fim de subsidiar a análise de tendências.

vii. Calcular automaticamente a fase de maturidade tecnológica de Ernst da área pesquisada com base na taxa de crescimento das publicações e patentes recuperadas, gerando a representação gráfica da curva S correspondente.

viii. Gerar automaticamente um relatório técnico consolidado no padrão REPTEC da AGITEC, editável, com embasamento factual garantido pelo uso de técnicas de Geração Aumentada por Recuperação (RAG), a partir dos documentos indexados no banco vetorial.

ix. Persistir de forma estruturada e rastreável os dados gerados ao longo do processo de prospecção, distribuindo-os entre diferentes sistemas de armazenamento conforme sua natureza: um banco de dados relacional (PostgreSQL) para os metadados estruturados de sessões, consultas, documentos de patente e artigo recuperados, e histórico de execução; um banco de dados vetorial (ChromaDB) para os *embeddings* utilizados na recuperação semântica via RAG; e um serviço remoto de armazenamento de objetos (MinIO) para os artefatos gerados, como os gráficos da curva S e o relatório final.

x. Desenvolver uma interface *web* para acompanhamento e auditoria do processo de prospecção, para edição do relatório gerado e exportação do documento final, e verificação de dados estatísticos acumulados de pesquisas realizadas ao longo do tempo, como custos, tempo de processamento etc.

## 1.4 Metodologia

O sistema proposto implementa um fluxo iterativo de prospecção tecnológica baseado em Inteligência Artificial, estruturado em torno de duas frentes paralelas e independentes: a busca em bases de patentes e a busca em bases de artigos científicos. Ambas seguem o mesmo ciclo de execução.

O processo se inicia com o fornecimento de parâmetros pelo usuário por meio de uma interface *web* dedicada: a etapa de *intake* é a primeira etapa do mesmo *wizard* que conduz o usuário por todo o fluxo de prospecção. A partir dessas entradas, o modelo de linguagem remoto escolhido, direcionado por técnicas de engenharia de *prompt*, gera um conjunto de variações temáticas relacionadas ao tema informado, que são apresentadas ao usuário para validação [39]. Nessa etapa, o usuário pode aprovar o tema, solicitar maior especificidade ou alterá-lo diretamente antes de prosseguir.

Com o tema validado, o sistema realiza uma busca exploratória inicial nas APIs selecionadas para patentes e artigos, utilizando a linguagem de consulta CQL (*Common Query Language*) no caso do OPS, e a sintaxe própria de campos no caso do Scopus, recuperando um conjunto preliminar de resultados. Os títulos e resumos desses resultados são então processados por um pipeline local de Processamento de Linguagem Natural (PLN) — e não por uma nova chamada ao modelo de linguagem remoto — que extrai e pontua os termos mais relevantes, apresentados ao usuário para seleção. Com os termos selecionados, o modelo de linguagem remoto constrói, a partir deles, opções de *queries* refinadas para a busca definitiva, novamente submetidas à validação do usuário, que deve selecionar uma opção ou retornar aos valores anteriores, podendo solicitar ajustes.

Após a aprovação, o sistema executa a busca final e recupera o conjunto definitivo de patentes e artigos. Os dados coletados alimentam, por um lado, o cálculo automático das curvas S da tecnologia pesquisada e, por outro, a indexação, em um banco de dados vetorial (ChromaDB), do título e do resumo dos documentos recuperados na busca final, por meio da técnica de RAG (*Retrieval-Augmented Generation*) [11, 16], que permite a um modelo de linguagem local gerar conteúdo factualmente embasado nos documentos recuperados, minimizando a ocorrência de alucinações [13]. A aderência ao padrão REPTEC é garantida por um *template* LaTeX e por seções de texto fixo extraídas de um relatório real [4]. Com esses dados, é gerado automaticamente um relatório consolidado em LaTeX, contendo os gráficos da análise, as referências efetivamente citadas e o quadro com as consultas de busca utilizadas, que o usuário pode editar, revisar e compilar em PDF diretamente na interface *web*.

## 1.5 Estrutura do Texto

O presente trabalho está organizado em mais quatro capítulos. O **Capítulo 2** aborda a fundamentação teórica necessária à compreensão dos conceitos mobilizados pelo projeto, tratando de prospecção tecnológica, ciclo de vida e curva S de maturidade, arquitetura de redes neurais e *Large Language Models* (LLMs), engenharia de *prompt*, *Retrieval-Augmented Generation* (RAG), representações vetoriais (*embeddings*) e algoritmos de recuperação de informação e mineração terminológica. O **Capítulo 3** apresenta a solução proposta: escopo, requisitos funcionais e não funcionais, especificação da arquitetura (incluindo a arquitetura hexagonal e os princípios SOLID que a sustentam), configurações e parâmetros operacionais adotados, a métrica de complexidade de consulta e o mecanismo de validação estruturada propostos, tecnologias empregadas, modelagem de dados e estado final de desenvolvimento. O **Capítulo 4** detalha o *pipeline* de processamento em suas cinco fases operacionais. O **Capítulo 5** traz a conclusão, com a síntese das contribuições, o atendimento aos objetivos, as limitações, os trabalhos futuros e as considerações finais.

# 2 Fundamentação Teórica

## 2.1 Prospecção Tecnológica

A prospecção tecnológica é um conjunto de métodos e ferramentas utilizado para identificar, analisar e monitorar tecnologias emergentes e suas tendências de desenvolvimento [28]. Seu objetivo é fornecer subsídios para a tomada de decisão estratégica em organizações de pesquisa, desenvolvimento e inovação, permitindo antecipar oportunidades e riscos associados à adoção de novas tecnologias. Segundo Mayerhoff [24], o propósito dos estudos de prospecção não é desvendar o futuro, mas sim delinear e testar visões possíveis e desejáveis para que sejam feitas, hoje, escolhas que contribuirão da forma mais positiva possível na construção do futuro.

No contexto brasileiro de defesa, essa atividade é formalizada por meio do padrão REPTEC, definido pela AGITEC, que estabelece estrutura, conteúdo mínimo e formato para os relatórios de prospecção tecnológica utilizados pelo Exército Brasileiro [3]. Um exemplo concreto e público dessa formalização é o Relatório de Prospecção Tecnológica 001/2023, elaborado pela AGITEC sobre a tecnologia *Terrestrial Trunked Radio* (TETRA) [4], que segue a estrutura em oito seções (Finalidade, Referências, Objetivo, Introdução, Metodologia, Resultados, Conclusão e Referências Bibliográficas) e emprega, nas subseções de Resultados, exatamente o tipo de indicador bibliométrico — distribuição temporal de publicações e patentes, *ranking* de instituições e depositantes, classificações CPC mais frequentes e curvas de extrapolação. Tais relatórios devem contemplar, entre outros elementos, análise de patentes, levantamento de artigos científicos, análise de tendências e representação gráfica do ciclo de vida das tecnologias investigadas. O cumprimento desse padrão exige que os dados coletados sejam organizados em seções específicas, como finalidade, referências institucionais, metodologia de busca, informações científicas e tecnológicas, tendências e ciclo de vida, e conclusão embasada nos dados apresentados.

A utilização de artigos científicos e patentes como fontes primárias de informação tecnológica é amplamente reconhecida na literatura [28]. Artigos científicos refletem o estado do conhecimento acadêmico e são indicadores do avanço teórico e experimental em um campo, geralmente associados aos estágios iniciais do ciclo de vida de uma tecnologia, quando a pesquisa básica e aplicada ainda predomina sobre a exploração comercial. Patentes, por sua vez, revelam tendências de inovação industrial e comercial, identificando as organizações mais ativas no desenvolvimento tecnológico, os inventores de destaque e as classificações tecnológicas predominantes, e tendem a acompanhar estágios de maturidade mais avançados, em que o interesse comercial pela proteção de propriedade intelectual se intensifica [4]. A análise combinada dessas duas fontes oferece, portanto, uma visão abrangente e multidimensional do panorama tecnológico de um determinado domínio do conhecimento.

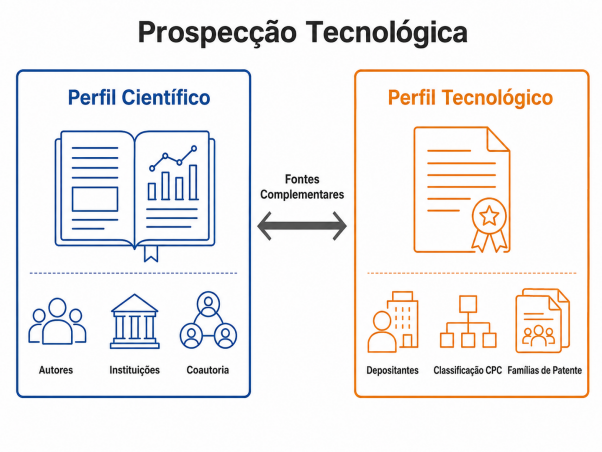
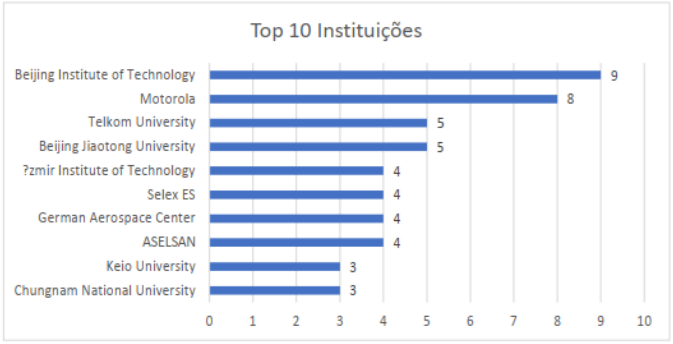



Figura 1: Perfil científico e perfil tecnológico como fontes complementares de prospecção.

da Motorola e do *Beijing Institute of Technology*, na quantidade de artigos, com 8 e 9 publicações, respectivamente, indica seu papel significativo na geração de conhecimento nesse setor.

Figura 5: Top 10 maiores instituições em quantidade de publicações científicas.




Fonte: O autor.

O Quadro 2 mostra os assuntos que foram abordados com maior frequência, dentre os quais, consecutivamente: Redes de computadores e comunicações (50 publicações), aplicações em ciência da computação (38 publicações), arquitetura a hardware (23 publicações), sistemas de informação (22 publicações) e software (18 publicações).

Quadro 2: Assuntos relacionados às pesquisas científicas.

| | | | | |
|---|---|---|---|---|
| 50 Computer Networks and Communications | 38 Computer Science Applications | 4 Control and Systems Engineering | 110 Electrical and Electronic Engineering | 16 General Computer Science |
| 23 Hardware and Architecture | 22 Information Systems | 11 Signal Processing | 18 Software | 7 Theoretical Computer Science |

Fonte: O autor, com auxílio gráfico da base Lens.org.

No Brasil há apenas duas publicações indexadas na base de dados Lens.org cujas instituições responsáveis pela publicação são a Agência Nacional de Telecomunicações, Universidade Federal do Paraná, Instituto Federal do Paraná, Universidade Federal do Tocantins e a Universidade de Brasília.

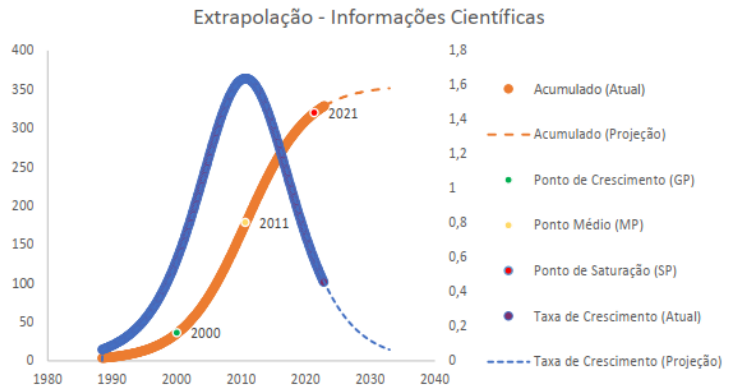


Figura 2: Exemplo de resultados da análise de dados em um relatório de prospecção: gráficos. Fonte: REPTEC 001/2023 — *Terrestrial Trunked Radio* (TETRA) [4].

quantidade de artigos quanto de patentes, indicando maior interesse e adoção da tecnologia, bem como a consolidação das pesquisas e desenvolvimentos iniciais.

Observou-se que os anos 2000 foram marcados pelo estágio de crescimento da tecnologia, cujos pontos de crescimento foram alcançados em 2000 (publicações científicas) e 2006 (depósitos de patentes), respectivamente nas curvas de artigos e patentes relacionados à tecnologia TETRA. Atribui-se esse crescimento à crescente aceitação e implantação prática dessa tecnologia, refletindo um ciclo de expansão em seu desenvolvimento. A figura 9 ilustra a curva-s relativa às informações científicas.

Figura 8: Curva-S relativa às informações científicas




Fonte: O autor.

A partir de meados da década de 2010, a quantidade de artigos relacionados ao TETRA apresentou uma estabilização em seu crescimento, sugerindo que a tecnologia atingiu o estágio de maturidade em termos de pesquisa acadêmica e desenvolvimento teórico, como pode ser visto na Figura 9 (MP = 2011). Esse fenômeno indica que a maioria das pesquisas fundamentais e importantes contribuições científicas já foram desenvolvidas, e novos avanços tentem a ser incrementais.

Ressalta-se que a queda consistente na quantidade anual de publicações científicas pós 2014 foi suficiente para que o modelo indique estágio de saturação em relação ao interesse acadêmico na tecnologia (SP=2021).



Figura 3: Exemplo de resultados da análise de dados em um relatório de prospecção: curva S. Fonte: REPTEC 001/2023 — *Terrestrial Trunked Radio* (TETRA) [4].

## 2.2 Curva S de Maturidade Tecnológica

A curva S é um modelo gráfico que descreve o ciclo de vida de uma tecnologia ao longo do tempo, relacionando o acúmulo de patentes ou publicações científicas com o grau de maturidade tecnológica [10]. Segundo Foster, toda tecnologia possui limites naturais de desempenho, e à medida em que esses limites são aproximados, o esforço necessário para obter novos avanços cresce exponencialmente — ao passo que uma nova tecnologia concorrente pode emergir a partir de um novo patamar de desempenho, iniciando sua

própria curva S [10]. Esse fenômeno de descontinuidade tecnológica é fundamental para a compreensão da dinâmica de substituição entre tecnologias e para a orientação estratégica de investimentos em PD&I.

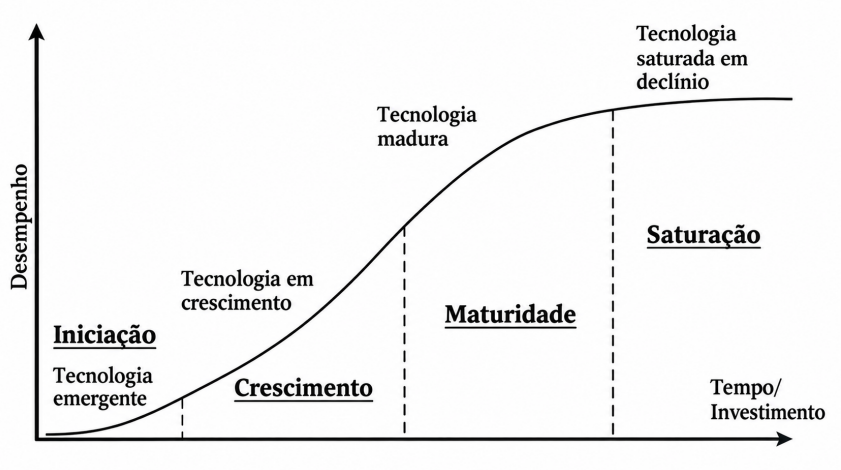



Figura 4: Curva S de maturidade tecnológica e seus estágios. Fonte: adaptado de Madeo (2019) [41].

O fundamento matemático mais difundido para a curva S aplicada à substituição tecnológica é o modelo de Fisher e Pry [9], que descreve a fração de substituição de uma tecnologia antiga por uma nova como uma função logística do tempo. Ernst [14] aplicou esse raciocínio à contagem *acumulada* de depósitos de patentes ao longo do tempo, propondo que o ciclo de vida de uma tecnologia, e não apenas a substituição de uma tecnologia por outra, pode ser descrito por quatro estágios sucessivos:

(i) **Emergente ou Iniciação**: caracterizada por baixo volume de resultados e crescimento inicial lento, típica de tecnologias recentemente introduzidas que ainda não atraíram atenção ampla da comunidade científica ou industrial.

(ii) **Crescimento**: marcada por expansão acelerada da produção científica e tecnológica, indicando que a tecnologia está sendo ativamente pesquisada e desenvolvida por um número crescente de atores.

(iii) **Maturidade**: correspondente à estabilização do crescimento, quando a tecnologia alcança um patamar de desenvolvimento consolidado e a taxa de novas publicações ou patentes se estabiliza.

(iv) **Declínio ou Saturação**: associada à obsolescência ou à substituição da tecnologia por soluções mais avançadas, refletindo uma redução no interesse e na produção científica e tecnológica [10].

Rogers [33] complementa essa perspectiva ao descrever como as inovações se difundem ao longo do tempo em uma população de adotantes, seguindo igualmente um padrão em curva S, o que reforça a robustez do modelo logístico como ferramenta de leitura de maturidade em domínios distintos (adoção de inovações, substituição tecnológica, difusão bibliométrica). Kucharavy e De Guio [15] revisam justamente essa recorrência do

padrão em curva S em campos tão diversos quanto epidemiologia, demografia e previsão tecnológica, reforçando que a escolha do modelo logístico para leitura de maturidade é a aplicação empírica de um padrão matemático formalmente estabelecido.

### 2.2.1 Distinção entre fase de maturidade (curva S) e *Technology Readiness Level* (TRL)

É importante não confundir a fase de maturidade tecnológica descrita nesta seção com o *Technology Readiness Level* (TRL), uma escala amplamente utilizada em engenharia de sistemas e gestão de programas de defesa e espaço. O TRL foi originalmente concebido pela NASA na década de 1970 e formalizado por Mankins [17] em nove níveis, do TRL 1 (princípios básicos observados) ao TRL 9 (sistema real comprovado em ambiente operacional). Trata-se de uma métrica de prontidão de engenharia, avaliada por critérios técnicos objetivos (ou por julgamento de especialistas) para *uma solução ou protótipo específico*, tipicamente no contexto de um único projeto de desenvolvimento.

A fase de maturidade obtida pela curva S, por outro lado, não avalia um protótipo específico, mas o estágio coletivo de uma *área tecnológica como um todo*, inferido estatisticamente a partir do volume acumulado de patentes e publicações científicas ao longo do tempo em toda uma comunidade de pesquisadores e empresas. Enquanto o TRL responde à pergunta "o quão pronta está *esta* solução para ser empregada?", a curva S responde a "em que estágio de seu ciclo de vida coletivo se encontra *este campo* tecnológico, considerando o esforço de P&D mundial documentado em patentes e artigos?". São instrumentos complementares e não substitutos.

### 2.2.2 Formalização matemática e pontos de leitura (GP, MP, SP)

O modelo logístico clássico assume que a taxa de variação do crescimento tecnológico acumulado $N(t)$ é proporcional tanto ao nível já atingido quanto à fração remanescente até uma capacidade limite $K$:

$$N(t) = \frac{K}{1 + e^{-r\cdot(t-t_0)}}$$

onde $N(t)$ representa o montante cumulativo no instante temporal $t$; $K$ é a capacidade de suporte ou platô de saturação assintótico; $r$ é a taxa intrínseca de crescimento; e $t_0$ é o ponto de inflexão temporal, instante no qual a taxa de incremento anual atinge o valor máximo e $N(t_0) = K/2$.

A partir dos parâmetros $K$, $r$ e $t_0$, a inversão algébrica da função logística permite mapear os instantes temporais em que frações arbitrárias $f = N(t)/K$ da saturação são atingidas:

$$t = t_0 - \frac{\ln\left(\dfrac{1}{f} - 1\right)}{r}$$

Na literatura de prospecção tecnológica e difusão de inovações, destacam-se três marcos característicos ao longo dessa trajetória, denominados Ponto de Crescimento

(*Growth Point* – GP), Ponto Médio (*Mid Point* – MP) e Ponto de Saturação (*Saturation Point* – SP) [4, 14], sintetizados formalmente na Tabela 1.

Tabela 1: Definição formal dos marcos de difusão na dinâmica logística

| **Marco** | **Definição Teórica** | **Fração de $K$ ($f$)** |
|---|---|---|
| GP | Instante em que o acúmulo documental supera a fase embrionária e inicia o regime de crescimento exponencial | 0,10 |
| MP | Instante de inflexão da função logística ($t_0$); ponto de derivada máxima na série temporal | 0,50 |
| SP | Instante em que a curva atinge desaceleração crítica, ingressando na maturidade avançada ou saturação | 0,90 |

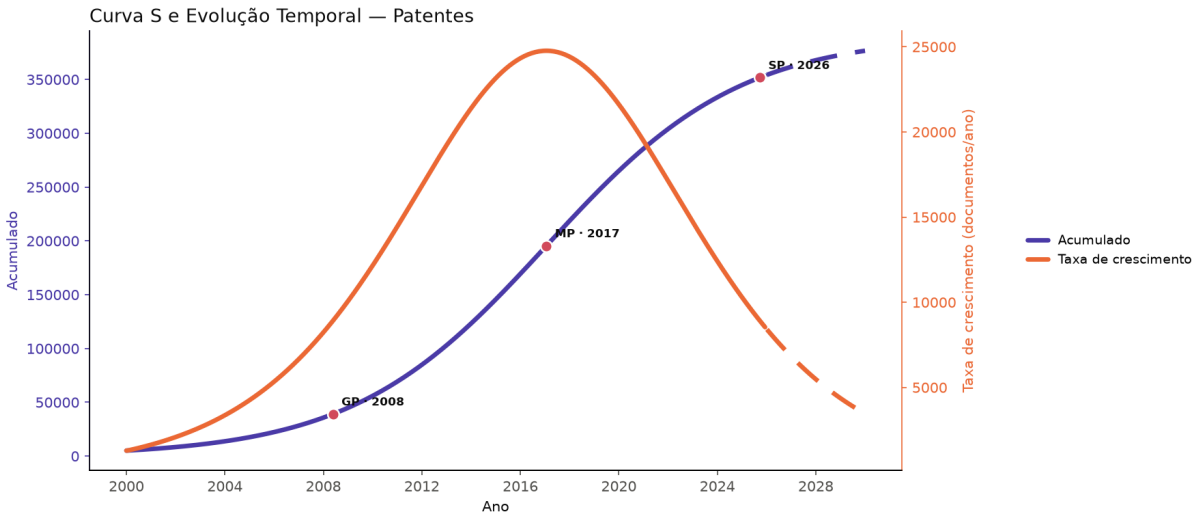



Figura 5: Curva S sintética anotada com os parâmetros $K$, $t_0$ e os pontos de leitura GP, MP e SP.

### 2.2.3 Avaliação de aderência do modelo logístico

A aderência do modelo logístico aos dados empíricos observados é quantificada pelo coeficiente de determinação $R^2$, calculado sobre os resíduos entre a função ajustada e a série temporal histórica:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

onde $y_i$ são os valores observados, $\hat{y}_i$ são os valores preditos pelo modelo ajustado e $\bar{y}$ é a média da série temporal. O $R^2$ mensura a proporção da variância dos dados que é explicada pela curva logística, servindo como base estatística para diagnósticos de qualidade de ajuste.

### 2.2.4 Estimação de completude amostral e estabilidade de *ranking*

Um limite inerente a qualquer indicador construído sobre amostras bibliográficas é que ele reflete o conjunto recuperado, não necessariamente o universo populacional irrestrito. Duas formulações estatísticas são tradicionalmente mobilizadas para qualificar esse tipo de dado.

O **estimador Chao1** [6] fundamenta-se na frequência de classes raras para inferir a riqueza total de categorias distintas em uma população. A formulação com correção de viés é dada por:

$$\hat{S}_{\text{Chao1}} = S_{\text{obs}} + \frac{f_1(f_1 - 1)}{2(f_2 + 1)}$$

onde $S_{\text{obs}}$ é o número de classes distintas observadas, $f_1$ é a contagem de classes observadas exatamente uma vez (*singletons*) e $f_2$ é a contagem de classes observadas exatamente duas vezes (*doubletons*). A razão $S_{\text{obs}}/\hat{S}_{\text{Chao1}}$ representa a estimativa assintótica de completude amostral da diversidade observada.

O **método de *bootstrap*** [7] fundamenta-se na reamostragem não paramétrica com reposição a partir da distribuição empírica original. Em problemas de ordenamento e ranqueamento categórico — como avaliação da consistência de posições no *ranking* de documentos relevantes — a reamostragem repetida permite estimar a variância amostral e quantificar a probabilidade de que documentos no topo da busca (p.ex., top-10) mantenham suas posições relativas mesmo sob pequenas variações nos dados. Com 1.000 iterações de reamostragem, o método fornece uma estimativa robusta dessa variância sem requerer pressupostos analíticos sobre a distribuição subjacente da população.

## 2.3 *Large Language Models* (LLMs)

A modelagem computacional de linguagem tem como objetivo inferir a probabilidade conjunta de sequências de palavras, viabilizando prever a continuidade de textos dado um contexto precedente [40]. A base estrutural dos modelos modernos reside nas redes neurais artificiais com múltiplas camadas, treinadas por algoritmos de gradiente descendente e retropropagação do erro (*backpropagation*) sobre grandes volumes de dados textuais [27].

Os *Large Language Models* (LLMs) são viabilizados pela arquitetura *Transformer*, introduzida por Vaswani et al. [36]. Ao superar o processamento estritamente recorrente

por meio de mecanismos de atenção intrínseca (*self-attention*), o Transformer permite que todas as posições de uma sequência textual sejam computadas simultaneamente. Formalmente, o mecanismo opera sobre projeções lineares dos vetores de entrada denominadas consultas ($Q$), chaves ($K$) e valores ($V$), calculando a atenção pelo produto escalar normalizado:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

onde $d_k$ representa a dimensionalidade das chaves. Essa formulação permite ao modelo capturar interdependências de longo alcance e nuances contextuais em profundidade.

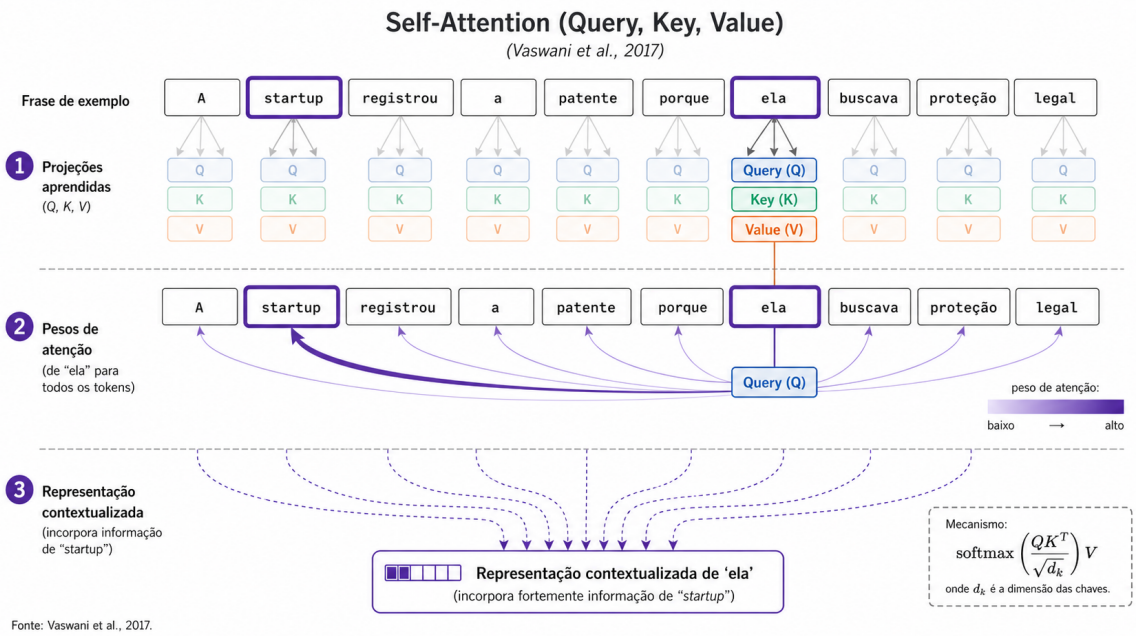



Figura 6: Mecanismo de *self-attention* (*query*/*key*/*value*) da arquitetura *Transformer*.

O aumento da escala dessas redes revelou propriedades emergentes, como o aprendizado a partir de poucos exemplos fornecidos diretamente no contexto (*few-shot learning*), dispensando atualizações de pesos para tarefas específicas [5]. No entanto, os LLMs apresentam limitações intrínsecas:

**Alucinações**: geração de enunciados gramaticalmente coerentes e persuasivos, porém factualmente infundados ou incorretos perante a realidade empírica [13]. Decorrem da natureza puramente probabilística da decodificação de *tokens*, exigindo mecanismos externos de ancoragem factual.

**Limites de Janela de Contexto**: restrição física na quantidade de *tokens* que o modelo consegue processar simultaneamente em uma única inferência, demandando estratégias de segmentação textual e seleção de trechos relevantes [40].

## 2.4 Engenharia de *Prompt*

A engenharia de instruções (*prompt engineering*) compreende o conjunto de metodologias para estruturar comandos textuais direcionados a um modelo de linguagem, orientando seu espaço de busca generativo para produzir saídas alinhadas com critérios de qualidade e formatação predefinidos [39].

Padrões consagrados na literatura técnica incluem:

- **Definição de Papel (*Persona Pattern*)**: atribuição explícita de uma identidade funcional ao modelo, delimitando o tom, o escopo de conhecimento e as restrições comportamentais da resposta [39].
- **Encadeamento de Raciocínio (*Chain-of-Thought*)**: indução do modelo à decomposição de uma tarefa complexa em etapas lógicas intermediárias sequenciais antes da entrega da resposta final, elevando significativamente a robustez do raciocínio analítico [38].
- **Exemplificação Guiada (*Few-Shot Prompting*)**: fornecimento de pares controlados de entrada e saída esperada no próprio preâmbulo da instrução, servindo como guia analítico de especificidade e sintaxe [5].

## 2.5 *Retrieval-Augmented Generation* (RAG)

A técnica de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* – RAG), proposta por Lewis et al. [16], combina a memória paramétrica de um LLM com uma memória não paramétrica externa baseada em recuperação documental. Em termos formais, diante de uma consulta de entrada $x$, um subsistema de busca recupera um subconjunto de passagens relevantes $z = \{z_1, \ldots, z_n\}$ de um corpus indexado; o modelo generativo produz então a saída condicionada ao par de entrada:

$$p(y|x) \approx \sum_{z} p(z|x)\, p(y|x, z)$$

Gao et al. [11] classificam os paradigmas de RAG em três gerações estruturais:

- **RAG Naive**: fluxo linear composto por indexação de fragmentos textuais, recuperação baseada em similaridade vetorial dos $k$ vizinhos mais próximos e concatenação direta dos trechos no contexto do prompt generativo.
- **RAG Avançado**: introduz etapas de pré-recuperação (expansão e reescrita de consultas) e de pós-recuperação (como reclassificação semântica via *rerankers* e compressão de contexto).
- **RAG Modular**: desacoplamento total em módulos especializados (roteamento dinâmico, memória operacional e ciclos iterativos de busca e geração).

## 2.6 Representações Vetoriais e Busca em Espaços Densos

*Embeddings* são representações vetoriais contínuas que mapeiam entidades linguísticas em espaços densos de dimensão fixa $\mathbb{R}^d$, onde a proximidade geométrica reflete afinidade semântica [25].

Reimers e Gurevych [30] desenvolveram o Sentence-BERT (SBERT), ajustando redes siamesas sobre arquiteturas Transformer para gerar vetores de sentenças diretamente comparáveis por medidas métricas, notadamente a similaridade de cosseno:

$$\mathrm{sim}(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\|\|\vec{v}\|}$$

Para coleções extensas de vetores, a busca linear exata torna-se computacionalmente custosa. Os métodos de Busca Aproximada de Vizinhos Mais Próximos (*Approximate Nearest Neighbor* – ANN) contornam essa barreira. Destaca-se a estrutura em grafos hierárquicos navegáveis de mundo pequeno (*Hierarchical Navigable Small World* – HNSW), que viabiliza trajetórias de busca em complexidade temporal sublinear com alta revocação estatística [11].

## 2.7 Recuperação de Informação e Extração Terminológica

A mineração automática de termos técnicos e a identificação de palavras-chave a partir de coleções documentais congregam métodos linguístico-estatísticos e abordagens vetoriais:

**PatternRank** [35]: método de extração não supervisionada que restringe candidatos a sequências morfossintáticas pré-definidas (frases nominais maximais que respeitam padrões de classes gramaticais, como adjetivo* substantivo+), garantindo completude semântica às expressões candidatas.

**BM25 e BM25F** [31,32]: o modelo BM25 formaliza o ordenamento probabilístico por relevância lexical, partindo das noções seminais de ponderação baseada em frequência inversa do termo (*Term Frequency–Inverse Document Frequency* – TF-IDF) formuladas por Salton e Buckley [34]. Introduz parâmetros para saturação não linear da frequência do termo ($k_1$) e normalização pelo comprimento relativo do texto ($b$). Sua extensão, o BM25F, opera sobre múltiplos fluxos ou campos heterogêneos de um documento estruturado (como título e resumo), ponderando linearmente as frequências nos campos antes da aplicação da função de saturação não linear.

**KeyBERT** [12]: técnica fundamentada no cálculo da similaridade de cosseno entre o vetor denso do documento completo e os vetores de termos candidatos gerados a partir de modelos neurais contextuais [30], priorizando a proximidade tópica global.

**Reciprocal Rank Fusion (RRF)** [22]: algoritmo de fusão tardia de múltiplos rankings independentes baseado exclusivamente na ordem posicional relativa dos elementos:

$$\mathrm{RRF}(t) = \sum_{m \in M} \frac{1}{k + r_m(t)}$$

onde $M$ é o conjunto de métodos de ranqueamento, $r_m(t)$ é a posição ordinal do item $t$ no método $m$, e $k$ é uma constante de estabilização. A fusão ordinal equaliza canais heterogêneos dispensando normalizações prévias de escalas numéricas absolutas.

**C-value** [23]: métrica projetada para mensurar o grau de autonomia lexical (*termhood*) de expressões compostas, ponderando a frequência global do termo contra a sua incidência aninhada no interior de sequências candidatas mais longas.

## 2.8 Princípios SOLID de Projeto de Software

Os princípios SOLID [18, 19] constituem um conjunto de cinco heurísticas para projeto de software orientado a objetos que visam aumentar a manutenibilidade, extensibilidade e robustez de sistemas complexos. A seguir, apresentam-se esses princípios com aplicação específica à arquitetura de prospecção tecnológica proposta, em dois níveis de análise: (i) nível de sistema (como os princípios sustentam a escolha arquitetural hexagonal) e (ii) nível de módulo (como se materializam em componentes concretos):

Tabela 2: Aplicação dos princípios SOLID na arquitetura do sistema de prospecção tecnológica

| **Princípio** | **Aplicação em Nível de Sistema** | **Aplicação em Nível de Módulo (Exemplo)** |
|---|---|---|
| **SRP** (Single Responsibility) | Separação entre camadas: domínio (tipos puros), portas (contratos), serviços (negócio), adaptadores (I/O externo). Cada camada tem uma única razão para mudar. | ReportService descomposto em: router (validação HTTP), report_service (orquestração gráfica), s_curve.py (ajuste estatístico). Mudança na fórmula Fisher-Pry não afeta renderização. |
| **OCP** (Open-Closed) | Sistema aberto para extensão (novos adaptadores de busca) mas fechado para modificação (ChatService intocado). Nova API de busca = novo par Adapter + QueryBuilder registrado no container. | ReportService define lista declarativa de especificações de gráfico (chart specs). Novo gráfico = item adicionado à lista, sem alterar orquestração. |
| **LSP** (Liskov Substitution) | Adaptadores de busca (OPS, Scopus, Lens) implementam contrato PatentSearchPort e ScholarlySearchPort. Intercambiáveis sem quebra de contrato. Fallback para MockSearchAdapter sem alterar lógica. | AnthropicLLMAdapter, GeminiLLMAdapter, MockLLMAdapter implementam LLMPort. ChatService desconhece qual provedor concreto está em uso. |
| **ISP** (Interface Segregation) | Portas são interfaces mínimas e segmentadas: LLMPort (chat), EmbeddingPort (embeddings), PatentSearchPort (busca patentes), sem métodos desnecessários. | Schemas Pydantic como GeneratedChart, SCurveFit, ReportGraphicsResponse são estreitos: expõem apenas campos que seu consumidor específico precisa. |
| **DIP** (Dependency Inversion) | ChatService depende de abstrações (Protocol/Port), não de SDKs concretos (Anthropic SDK, OPS client). Implementações concretas injetadas em build_container(). | Rotas HTTP recebem serviços via container em request.app.state.container, não instanciam diretamente. Inversão de controle permite mock em testes. |

# 3 Solução Proposta

## 3.1 Escopo

O sistema proposto implementa uma plataforma modular para automatização da prospecção tecnológica [24, 28], estruturada em torno de um *backend* desenvolvido em Python com o *framework* FastAPI, um banco de dados relacional para persistência das pesquisas e resultados, um banco de dados vetorial para indexação semântica dos docu-

mentos recuperados [11], e componentes de Inteligência Artificial para geração e refinamento de termos e redação analítica de relatórios [40].

Com base na fundamentação teórica de complementaridade entre a dinâmica científica e o desenvolvimento tecnológico (Seção 2.1), a solução implementa duas frentes paralelas e estruturalmente independentes de prospecção: o rastreamento da atividade patentária industrial via API OPS (*Open Patent Services*) e o levantamento da produção acadêmica revisada por pares via API Scopus.

A arquitetura do sistema desdobra-se nos seguintes módulos operacionais:

- **Interface web:** assistente guiado único (*wizard*) construído em React, Vite e Tailwind CSS, responsável por conduzir o usuário da parametrização inicial da prospecção até a validação das etapas, revisão do texto técnico e exportação dos relatórios finais compilados.
- **Módulo de Orquestração (ChatService):** coordena o fluxo de execução entre as fases do sistema, controlando a transição entre estados, as validações humanas e as retentativas orientadas por métricas determinísticas, sob os contratos formais da Arquitetura Hexagonal (Seção 3.3).
- **Módulo de IA:** adaptadores técnicos desacoplados responsáveis por materializar chamadas aos modelos de linguagem remotos (Claude, Gemini) ou locais (Ollama, servidor interno), incorporando a infraestrutura de validação defensiva contra erros de esquema sintático e alucinações.
- **Módulo de Extração de Termos:** esteira local determinística de processamento de texto que executa a geração, ponderação lexical, aferição semântica e deduplicação de palavras-chave a partir das amostras documentais exploratórias, sem a realização de chamadas a modelos de linguagem nessa etapa.
- **Módulo de Busca (QueryBuilders + SearchServices):** converte estruturas lógicas intermediárias em consultas formalmente compatíveis com a sintaxe das APIs externas (CQL para OPS e gramática booleana para Scopus), executando controle de taxa de requisições, paginação automática e mitigação de falhas de rede.
- **Módulo de Construção de Imagens (ReportService + s_curve.py):** processa agregações bibliométricas por ano, depositante, instituição e classificação, calcula os ajustes das curvas S segundo o modelo logístico de Fisher-Pry, mapeia os pontos GP, MP e SP e gera as figuras e quadros normalizados no padrão REPTEC.
- **Módulo de Geração Textual do Relatório (ReportWriterService):** orquestra a síntese das seções analíticas via RAG, ancorando a redação do modelo de linguagem estritamente nos trechos recuperados e limitando citações às obras efetivamente presentes na base de busca.
- **Módulo de Revisão de Texto:** atua sobre os trechos editados ou gerados por IA, articulando o analisador baseado em regras LanguageTool para correções ortográficas e gramaticais com uma revisão estilística orientada por LLM especializado em português formal.

- **Módulo de Inferência Estatística:** monitora e atesta a qualidade da busca final através do estimador de riqueza assintótica Chao1 com correção de viés e de testes não paramétricos de estabilidade top-10 por 1.000 iterações de reamostragem *bootstrap*.
- **Módulo de Persistência I (SQL / PostgreSQL):** gerencia o armazenamento transacional relacional de todas as entidades de negócio (sessões, parâmetros, consultas, patentes, artigos e manifestos de relatório) via SQLAlchemy assíncrono, operando deduplicação global por meio de uma chave de registro (`dedup_key`) estruturada formalmente por:

$$\text{dedup_key} = \begin{cases} \text{fonte} + \text{':'} + \text{publication_number}, & \text{para patentes;} \\ \text{DOI normalizado}, & \text{para artigos com identificador;} \\ \text{hash(título normalizado} + \text{ano)}, & \text{para artigos sem DOI.} \end{cases}$$

- **Módulo de Persistência II (ChromaDB):** banco de dados vetorial isolado em contêiner local, responsável pela indexação e busca aproximada por vizinhos mais próximos (HNSW) sobre representações densas derivadas dos títulos e resumos documentais para ancoragem do RAG local.
- **Módulo de Persistência III (MinIO):** serviço de armazenamento de objetos compatível com a API S3 da Amazon, encarregado de preservar de forma desacoplada os artefatos binários do sistema (imagens dos gráficos, ilustrações fixas, fontes em LaTeX e relatórios finais compilados em PDF).

A estrutura concreta do relatório REPTEC combina esses módulos conforme detalhado na Tabela 3, que discrimina as dez seções e o método de produção de cada uma:

Tabela 3: Estrutura das seções do relatório REPTEC e métodos de produção.

| **Seção** | **Método de Produção** |
|---|---|
| Capa, Sumário | Estáticos: renderizados por template Jinja2 (`report_latex_template.py`) |
| 1. Finalidade | Fixa: gerada por função determinística (`render_finalidade`) a partir do tema |
| 2. Referências (DIEx) | Dado administrativo inserido e validado pelo usuário |
| 3. Objetivo | Texto do usuário: campo de formulário, gravado como seção estática |
| 4. Introdução | **IA (RAG + LLM)**: síntese contextual do domínio tecnológico |
| 5. Metodologia | Fixa: não passa por LLM (descrição genérica + palavras-chave interpoladas) |
| 6. Informações Científicas | **IA (RAG + LLM)**: resumo de tendências em literatura acadêmica |
| 7. Informações Tecnológicas | **IA (RAG + LLM)**: sumário de avanços em patentes |
| 8. Tendências e Ciclo de Vida | **IA (RAG + LLM)**: análise de dinâmica temporal e maturidade |
| 9. Conclusão | **IA (RAG + LLM)**: síntese de achados e implicações estratégicas |
| 10. Referências Bibliográficas | Autogenerada: gerada a partir das fontes citadas no RAG em ABNT |

No total, seis seções passam pela orquestração do ReportWriterService via RAG (Introdução, Informações Científicas, Informações Tecnológicas, Tendências, Conclusão, mais o Objetivo do usuário), enquanto quatro seções (Capa, Sumário, Finalidade, Metodologia) são produzidas por templates ou dados estruturados, e a Bibliografia é autogenerada. Essa organização garante que partes estruturantes do documento sejam reproduzíveis e auditáveis, enquanto o núcleo analítico seja enriquecido por contexto semântico via RAG.

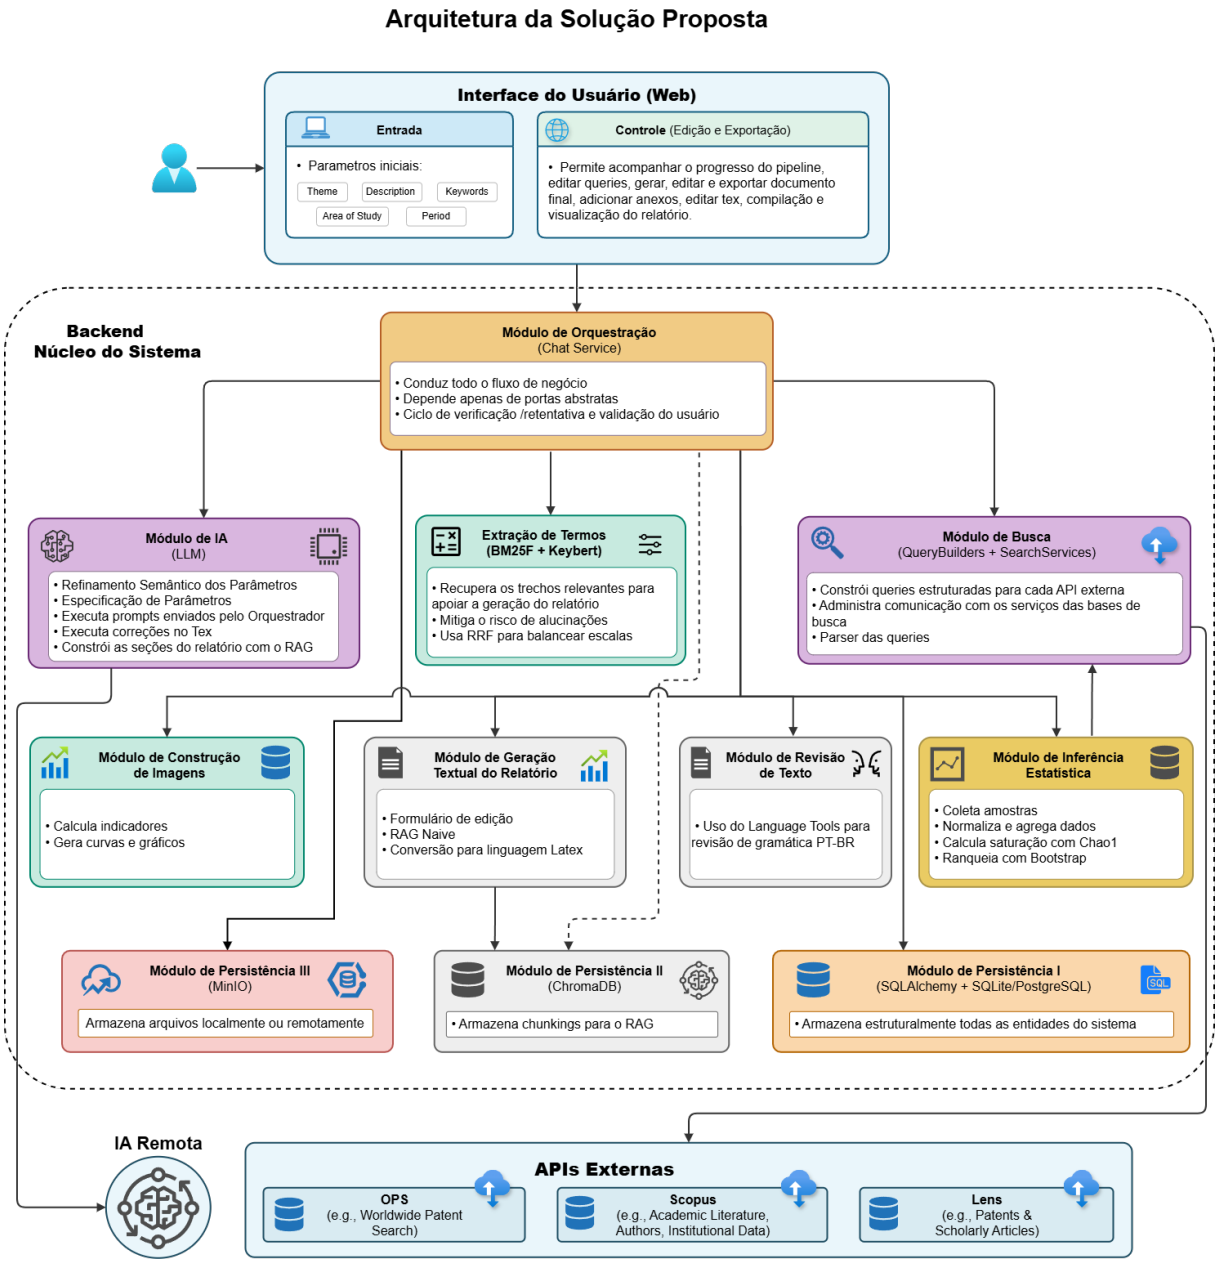



Figura 7: Arquitetura de módulos do sistema de prospecção tecnológica.

A Figura 7 ilustra a decomposição funcional do sistema em treze módulos especializados. No fluxo horizontal esquerdo-direito, o **Módulo de Orquestração** (ChatService) coordena as transições entre estados e as validações, enquanto **Adaptadores de Entrada** (HTTP/REST em FastAPI) recebem requisições do **Módulo de Interface** (React frontend). Os **Módulos de Busca** (QueryBuilders + SearchServices) convertem estruturas lógicas em sintaxe específica de cada API externa (OPS/CQL, Scopus/Booleano). O **Módulo de Extração de Termos** aplica uma esteira NLP local determinística (sem chamadas a LLM) sobre as amostras recuperadas. O **Módulo de IA** materializa as integrações com modelos de linguagem (Anthropic, Google, Ollama) com validação defensiva em camadas. O **Módulo de Construção de Imagens** gera as figuras e quadros REPTEC (curvas S, rankings) que alimentam o relatório. O **Módulo de Geração Textual**

orquestra a síntese analítica via RAG, enquanto o **Módulo de Revisão** corrige ortografia e gramática. Paralelos a esses fluxos, três **Módulos de Persistência** (SQL/PostgreSQL, ChromaDB vetorial, MinIO de objetos) preservam transações, indexação semântica e artefatos binários respectivamente, permitindo reprocessamento sem perda de informação.

## 3.2 Especificação de Requisitos

### 3.2.1 Requisitos Funcionais

A Tabela 4 especifica os doze requisitos funcionais que definem as capacidades do sistema:

| **Nº** | **Requisito** | **Descrição** |
|---|---|---|
| RF01 | Entrada de parâmetros | O sistema deve permitir que o usuário informe o tema de pesquisa e parâmetros complementares (período, área tecnológica, palavras-chave e descrição). |
| RF02 | Geração de termos de busca | O sistema deve gerar automaticamente, a partir do tema informado, um conjunto expandido de termos de busca relacionados, incluindo sinônimos e variações terminológicas em inglês. |
| RF03 | Validação iterativa pelo usuário | O sistema deve apresentar os termos e consultas gerados ao usuário para validação [39], permitindo aprovação, ajuste ou rejeição antes de prosseguir para a etapa seguinte. |
| RF04 | Consulta a bases de patentes | O sistema deve permitir a busca de patentes a partir dos termos validados, com filtros por campo (título, resumo e classificação tecnológica) e por período, retornando, para cada registro, número de publicação, título, resumo, depositantes, inventores, classificações, ano de publicação e situação legal, além das contagens agregadas por ano, por depositante e por classificação, quando disponíveis. |

| Nº | Requisito | Descrição |
|---|---|---|
| RF05 | Consulta a bases de artigos | O sistema deve permitir a busca de artigos científicos a partir dos termos validados, com filtros por campo (título, resumo, autores, periódico) e por período, retornando, para cada registro, título, autores e afiliações, resumo, ano de publicação, periódico ou conferência de origem, número de citações, DOI, palavras-chave e área de estudo. |
| RF06 | Consolidação de metadados | O sistema deve consolidar os dados retornados pelas diferentes APIs em um formato interno unificado, realizando deduplicação e normalização dos campos. |
| RF07 | Geração de indicadores | O sistema deve calcular indicadores de análise tecnológica: distribuição por ano, por depositante/autor, por classificação CPC e por área de estudo, conforme dados recuperados. |
| RF08 | Cálculo e geração de gráficos S | O sistema deve ajustar automaticamente uma curva logística à série acumulada de publicações e patentes recuperadas [9], calcular os pontos de leitura do ciclo de vida (GP, MP, SP) e um diagnóstico de confiabilidade do ajuste, e representar graficamente a curva S e as demais representações gráficas padronizadas pela AGITEC. |
| RF09 | Geração automática de relatório | O sistema deve gerar automaticamente um relatório técnico consolidado no padrão REPTEC da AGITEC [3, 4], com as oito seções numeradas do padrão, utilizando RAG [16] para embasamento factual das seções redigidas por LLM, com as figuras apresentadas e interpretadas no texto e com citações restritas aos documentos efetivamente recuperados. |
| RF10 | Edição e exportação | O sistema deve disponibilizar o relatório gerado para edição pelo usuário e permitir sua exportação em LaTeX (incluindo as imagens utilizadas) e em PDF. |
| RF11 | Rastreamento de métricas | O sistema deve registrar o consumo de *tokens*, o custo estimado por operação e o tempo de execução de cada fase do *pipeline*. |

| Nº | Requisito | Descrição |
|---|---|---|
| RF12 | Revisão do relatório | O sistema deve revisar o relatório editado, apontando erros de sintaxe LaTeX, de ortografia, de acentuação e de concordância nos trechos gerados por IA ou editados pelo usuário, e permitir que cada sugestão seja aplicada ou ignorada individualmente. |
| RF13 | Configuração em tempo de execução | O sistema deve permitir ao usuário cadastrar endpoints de LLM e escolher qual deles atende cada ponto de uso, bem como definir as APIs de busca ativas e os parâmetros operacionais, sem necessidade de reinicialização. |

Tabela 4: Requisitos Funcionais do Projeto

### 3.2.2 Requisitos Não Funcionais

A Tabela 5 especifica os oito requisitos não-funcionais que definem qualidades, restrições e atributos de qualidade do sistema:

| Nº | Requisito | Descrição |
|---|---|---|
| RNF01 | Modularidade | A arquitetura deve ser organizada em módulos com responsabilidades bem definidas, permitindo substituição ou atualização de componentes individuais sem impacto no restante do sistema. |
| RNF02 | Extensibilidade | O sistema deve ser projetado para permitir a integração futura de novas APIs de busca sem necessidade de reescrita significativa — requisito sustentado pela arquitetura hexagonal. |
| RNF03 | Desempenho aceitável | O sistema deve ser capaz de executar o *pipeline* completo em tempo satisfatório, sem dependência de GPU dedicada, salvo na etapa de geração do relatório, cujo tempo de execução é diretamente influenciado pelo hardware disponível. |

| Nº | Requisito | Descrição |
|---|---|---|
| RNF04 | Robustez | O sistema deve implementar três estratégias complementares de tolerância a falhas:<br>**(i) Retentativa Automática (Retry):** erros transientes de comunicação com APIs externas (timeouts, falhas de rede, indisponibilidade temporária) são automaticamente reiterados até três vezes, com intervalo crescente, sem qualquer exibição ao usuário. Se a tentativa bem-suceder em qualquer iteração, o fluxo prossegue transparentemente.<br>**(ii) Degradação Graciosa (Graceful Degradation):** a ausência de credenciais ou a indisponibilidade permanente de uma fonte de busca (OPS/Espacenet, Scopus, Lens Patente ou Lens Scholarly) não interrompe o fluxo de execução — o sistema simplesmente omite aquela fonte e prossegue com as demais disponíveis, registrando quais fontes foram excluídas e informando ao usuário no resumo de execução.<br>**(iii) Fail-Fast em Componentes Críticos:** a ausência de um modelo de linguagem configurado para um ponto de uso crítico (ex.: síntese de seções analíticas no ReportWriterService) deve produzir um erro explícito e imediato, interrompendo o fluxo. Em nenhuma circunstância o sistema deve preencher o componente crítico com um substituto silencioso (mock ou fallback) cujo resultado o usuário pudesse confundir com saída real de um LLM. |
| RNF05 | Rastreabilidade | O sistema deve registrar todas as etapas do processo de prospecção, incluindo os parâmetros fornecidos, os termos gerados, as consultas construídas e as validações realizadas pelo usuário. |
| RNF06 | Manutenibilidade | O código deve seguir convenções de estilo e documentação que facilitem sua manutenção por equipes distintas da que o desenvolveu originalmente. |

| Nº | Requisito | Descrição |
|---|---|---|
| RNF07 | Interoperabilidade com bases externas | A busca de patentes deve ser realizada por meio da API OPS/Espacenet, com consultas na linguagem CQL, e a busca de artigos, por meio da API Scopus (com complemento de resumos pela OpenAlex), respeitando a sintaxe, os limites de requisição e as estatísticas agregadas disponibilizados por cada serviço. |
| RNF08 | Uso de modelos de linguagem | A geração de termos e consultas de busca e a redação do relatório devem ser realizadas por LLMs [40], remotos ou locais, configuráveis por ponto de uso, de modo que a troca de provedor não exija alteração do código. |

Tabela 5: Requisitos Não Funcionais do Projeto

## 3.3 Especificação da Arquitetura

A arquitetura do sistema é estruturada sob o paradigma da **Arquitetura Hexagonal** (*Ports and Adapters*) [8]. Seu objetivo primordial é isolar as regras centrais de negócio de dependências de infraestrutura, protocolos de rede ou SDKs proprietários, permitindo que a camada de domínio comunique-se com o ambiente externo unicamente através de portas formais (*ports*) implementadas por adaptadores intercambiáveis (*adapters*). As camadas e responsabilidades dessa estrutura estão detalhadas na Tabela 6.

Tabela 6: Camadas da arquitetura hexagonal adotada no sistema

| Camada | Responsabilidade | Exemplos Concretos |
|---|---|---|
| Domínio | Tipos de dados e contratos sem I/O | Estruturas de resultado de busca, metadados de sessão, termos de PLN |
| *Ports* | Contratos abstratos do núcleo | Portas de chamadas a LLM, de busca de patentes e de artigos, de persistência |
| Serviços | Regras de negócio puras | Orquestrador de fluxo, validador de complexidade, ajustador da curva S |
| Adaptadores *driven* | Implementações de saída | Conectores para OPS, Scopus, MinIO, ChromaDB e clientes de inferência LLM |
| Adaptadores *driving* | Gatilhos de entrada | Controladores REST em FastAPI que expõem as rotas à interface *web* |

Essa organização materializa os princípios **SOLID** de projeto de software. Uma

análise detalhada de como cada um desses princípios (SRP, OCP, LSP, ISP, DIP) é aplicado tanto em nível de sistema quanto em nível de módulo específicos encontra-se na Tabela 2 (Seção 2.8).

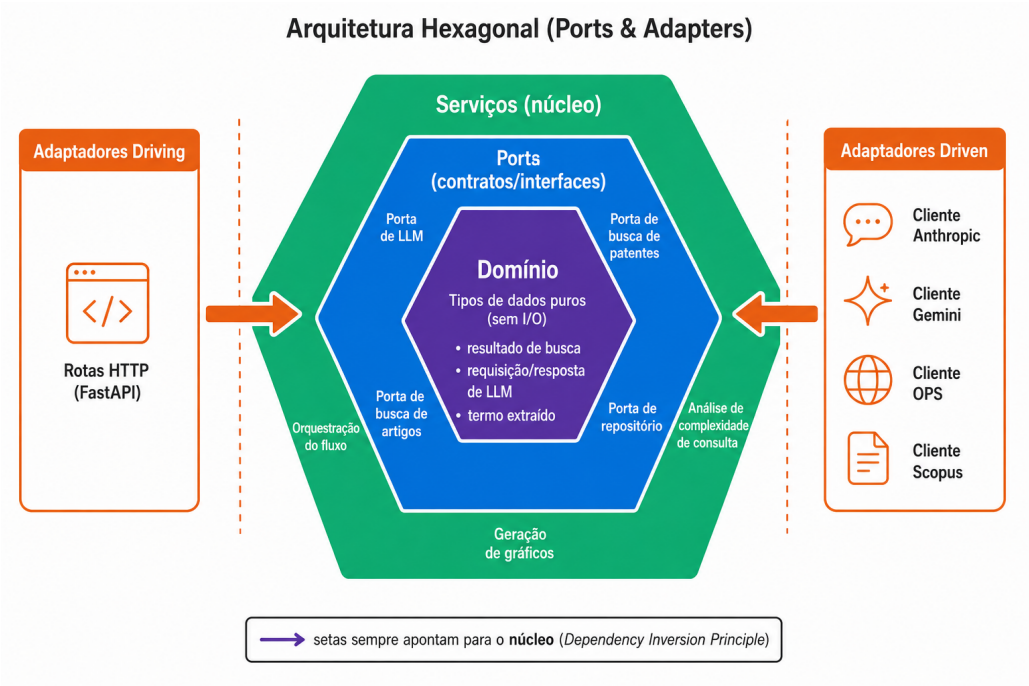



Figura 8: Camadas da arquitetura hexagonal: domínio, *ports*, serviços e adaptadores *driven*/*driving*.

A Figura 8 decompõe a arquitetura hexagonal em cinco camadas concêntricas. No núcleo (Domínio) residem tipos de dados puros e contratos sem efeitos colaterais de I/O: estruturas de resultado de busca, metadados de sessão, termos extraídos. A segunda camada (Portas) define interfaces abstratas — LLMPort, SearchPort, EmbeddingPort — que o núcleo depende mas não implementa. A terceira camada (Serviços) encapsula as regras de negócio puras: orquestrador de fluxo, validador de complexidade, ajustador de curva S. A quarta camada (Adaptadores *driven*) implementa as saídas: conectores para OPS, Scopus, MinIO, ChromaDB, clientes LLM. A camada exterior (Adaptadores *driving*) recebe estímulos do mundo externo: controladores REST em FastAPI que expõem as rotas à interface web. Essa estrutura em camadas garante que mudanças em APIs externas (OPS depreca um endpoint, Scopus altera limites) permanecem circunscritas aos adaptadores, nunca propague-se ao domínio de negócio.

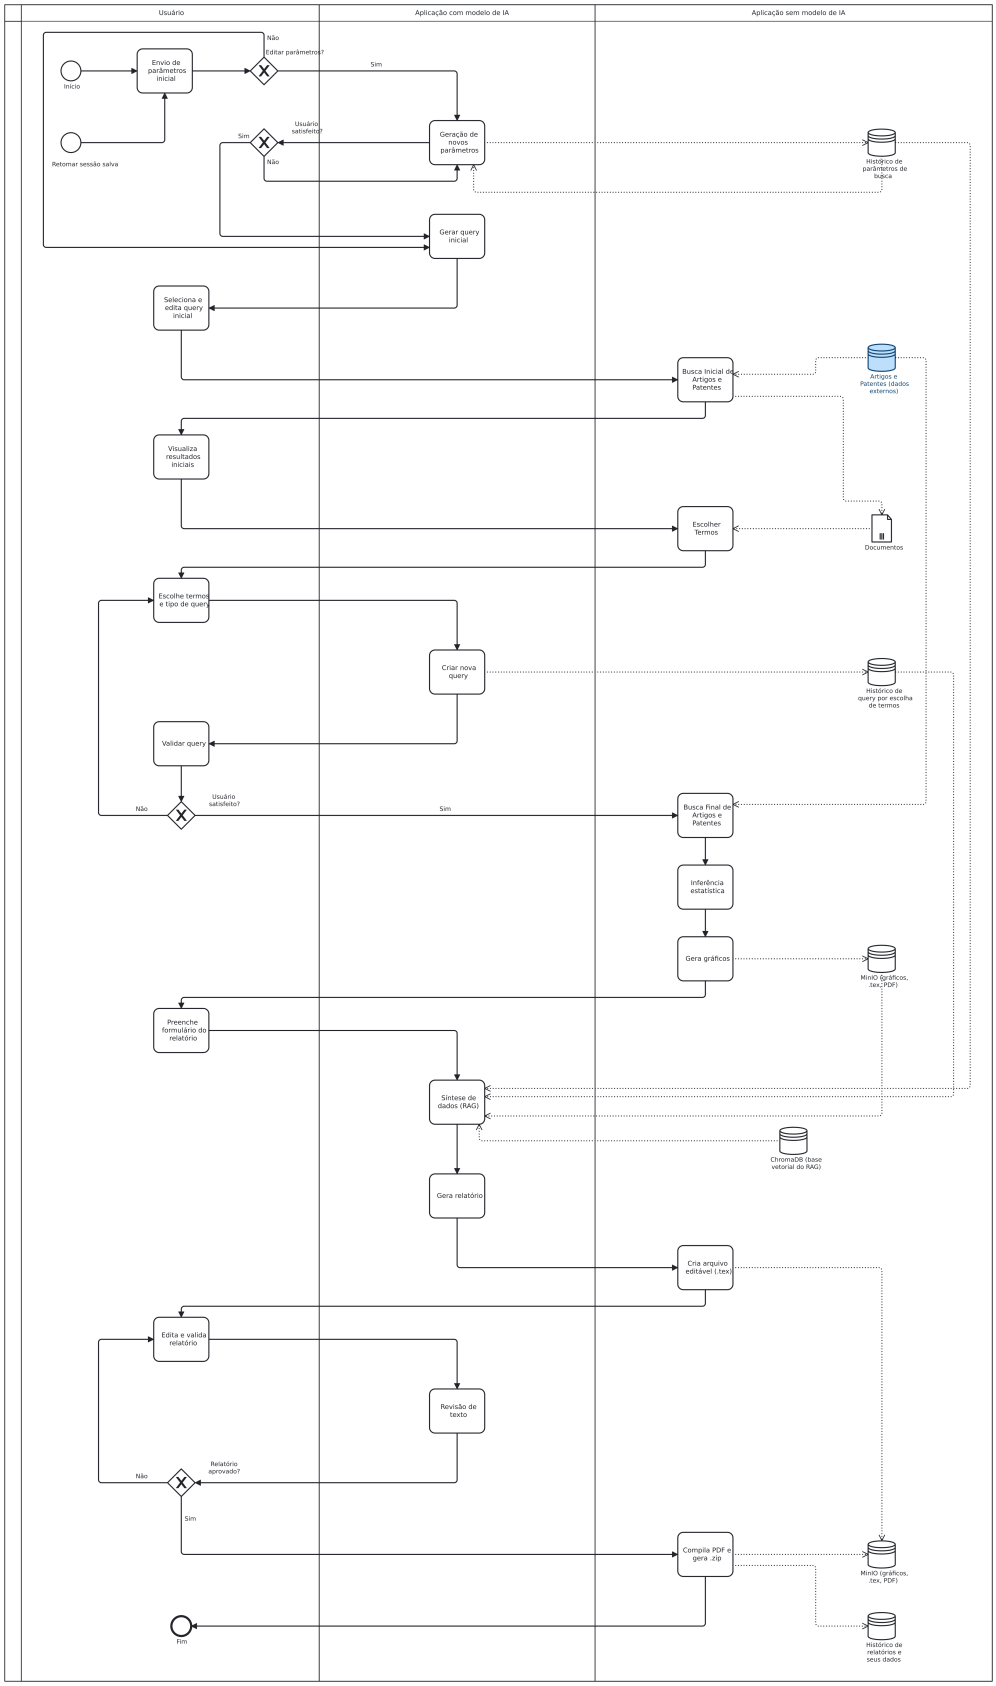



Figura 9: Fluxo geral do sistema de prospecção tecnológica.

A Figura 9 apresenta o fluxo sequencial de operações do sistema de ponta a ponta.

O processo inicia-se na etapa de **Intake** (parametrização do usuário), passa pela **Refinação de Tema** via LLM, seguida de **Geração de Queries Exploratórias** (múltiplas tentativas) e **Busca Exploratória** (com filtros) em OPS e Scopus. Uma vez recuperada a amostra inicial, o sistema executa **Extração de Termos** por esteira NLP local, permitindo que o usuário selecione e priorize termos por fonte. Na sequência, **Geração de Queries Finais** (em três graus de abrangência: Específica, Balanceada, Ampla) são construídas e apresentadas ao usuário para validação. A **Busca Final** em maior volume alimenta a **Análise Estatística** (Chao1, bootstrap), geração de **Gráficos e Indicadores** (curva S, rankings, distribuições) e, finalmente, a **Geração Textual do Relatório** via RAG com **Revisão** de ortografia, gramática e estilo. O relatório resultante é então **Exportado** em LaTeX e PDF. O feedback contínuo do usuário em cada etapa permite ajustes iterativos sem perda de contexto ou reprocessamento desnecessário.

## 3.4 Configurações, Parâmetros e Heurísticas Adotadas

As parametrizações operacionais do sistema decorrem de calibrações empíricas e restrições de robustez:

**Tratamento e Ajuste da Curva S**: As contagens de documentos recuperados são consolidadas em séries temporais cumulativas anuais. O ano calendário corrente, por estar computacionalmente incompleto, é descartado da série para prevenir a indução de falsas quedas na derivada temporal. Anos intermediários desprovidos de registros recebem contagem zero. Na regressão logística não linear executada via biblioteca *SciPy* [37], a estimativa da assíntota $K$ é inicializada heuristicamente como 1,5 vez o acumulado documental do último ano completo analisado.

**Critérios de Guarda da Confiabilidade da Curva S**: O ajuste logístico é automaticamente assinalado como não confiável quando qualquer um dos seguintes critérios é infringido:

(i) Coeficiente de determinação $R^2 < 0{,}90$;

(ii) Nível de saturação acumulada atual superior a 85% de $K$ com menos de 5 anos de observação temporal contínua (indicativo de sobreajuste aos dados);

(iii) Taxa de crescimento $r \leq 0$ (inconsistência física para séries cumulativas de inovação);

(iv) Taxa de crescimento $r > 5{,}0$ (indica descontinuidade funcional abrupta, em desacordo com dinâmicas históricas de difusão de C&T).

**Parâmetros do RAG Local**: Na geração analítica das seções, os títulos e resumos documentais indexados são fracionados em fragmentos textuais (*chunks*) de 1.000 caracteres com sobreposição deslizante (*overlap*) de 200 caracteres.

Os vetores de sentença densos são inferidos a partir do modelo multilíngue pré-treinado [30]: `distiluse-base-multilingual-cased-v2`.

Na etapa de recuperação semântica, o sistema recupera os $k = 5$ fragmentos de maior similaridade de cosseno contra a representação vetorial da sessão. Um corte relativo é aplicado, descartando-se quaisquer trechos cujo escore seja inferior a 75% do escore do fragmento mais relevante.

### 3.4.1 Seleção e Configuração dos Modelos de Linguagem por Ponto de Uso

O sistema desacopla a infraestrutura de LLM em cinco **pontos de uso** autônomos: (i) refinamento do tema inicial; (ii) síntese da consulta exploratória; (iii) montagem das variantes da consulta final; (iv) redação textual do relatório técnico via RAG; e (v) revisão ortográfica e linguística do relatório atualizado pelo usuário/operador do sistema.

Cada ponto de uso é dinamicamente associado a uma credencial e provedor persistido no banco de dados. Os pontos de busca (i, ii e iii) suportam provedores remotos como Claude (Anthropic) e Gemini (Google) ou endpoints locais. A redação analítica (iv) e revisão (v) operam prioritariamente sob endpoints compatíveis com o padrão REST de *chat completions* da OpenAI, possibilitando a execução de modelos locais via servidor Ollama ou infraestruturas computacionais fechadas, resguardando o sigilo de dados sensíveis da Força Terrestre.

### 3.4.2 Arquitetura Defensiva em Camadas para Saída Estruturada

Diante da suscetibilidade de modelos de linguagem violarem contratos rígidos de sintaxe, desenvolveu-se uma defesa de software em seis camadas sequenciais para recepção e tratamento das saídas das chamadas a LLM:

(a) **Imposição Nativa de Esquema**: emprego de modos forçados de JSON em provedores que oferecem suporte a gramáticas determinísticas em nível de decodificação.

(b) **Reparo Sintático Baseado em Expressões Regulares**: mecanismos automáticos que eliminam vírgulas órfãs residuais, formatam escapes inválidos e fecham listas truncadas.

(c) **Extração Tolerante com Contagem de Profundidade**: varredura determinística por contagem de chaves para recuperar itens válidos em listas de candidatos corrompidas pontualmente por truncamento de tokens.

(d) **Validação Estrita de Esquema**: verificação das estruturas geradas perante modelos formais de validação (Pydantic), rejeitando tipos disformes.

(e) **Validação Semântica de Conteúdo**: descarte de palavras vazias (*stopwords*), operadores booleanos inválidos ou cláusulas que apontem para campos inexistentes na API de destino.

(f) **Normalização e Mapeamento Final**: reconstrução do dicionário estrito de busca com base apenas nos campos ativamente suportados pela fonte consultada.

Essa arquitetura defensiva em camadas é uma **contribuição original deste trabalho**, adaptada especificamente aos pontos de uso de LLM no pipeline de prospecção tecnológica. A motivação reside na observação empírica de que modelos de linguagem atuais, mesmo quando instruídos a gerar JSON ou estruturas rígidas, frequentemente produzem saídas malformadas ou truncadas sob pressão de contexto. A estratégia em cascata — começando por validação nativa do provedor (quando disponível) e degradando graciosamente por camadas sucessivas de tolerância semântica e sintática — garante que o sistema recupere informação utilizável mesmo de respostas parcialmente corrompidas, sem sacrificar a auditoria de integridade dos dados críticos.

## 3.5 Métrica Proposta: Função de Complexidade de Consulta

### 3.5.1 Autocorreção por Métrica Determinística

A métrica de complexidade de consulta é uma função heurística original concebida pelos autores deste trabalho para prevenir a submissão de consultas booleanas que provoquem travamento ou respostas nulas por estouro de buffer nos analisadores léxicos das APIs externas (notadamente o analisador CQL da API OPS). Essa métrica especificamente mede **complexidade sintática** — isto é, características estruturais e formais da consulta — em oposição a aspectos semânticos (significado dos termos) ou de relevância topical (adequação ao tema de pesquisa).

Caso a consulta sintética gerada pelo LLM ultrapasse um limiar de corte calibrado, ativa-se o ciclo de autocorreção: o analisador determinístico calcula o número exato de operadores, profundidade de parênteses e contagem de termos, reinjetando esses indicadores matemáticos em uma nova instrução corretiva ao modelo de linguagem. Após três tentativas que excedam o limiar, o sistema adota automaticamente a tentativa mais simples do lote.

### 3.5.2 Definição Matemática da Função de Complexidade

A função sintetiza quatro fatores estruturais normalizados no intervalo $[0, 100]$:

$$\text{operator_score} = \min\left(100,\ \frac{n_{\text{operadores}}}{10} \times 100\right)$$

$$\text{nesting_score} = \min\left(100,\ \frac{d_{\text{aninhamento}}}{5} \times 100\right)$$

$$\text{term_score} = \min\left(100,\ \frac{n_{\text{termos}}}{20} \times 100\right)$$

$$\text{length_score} = \min\left(100,\ \frac{c_{\text{caracteres}}}{1000} \times 100\right)$$

onde $n_{\text{operadores}}$ é a contagem de operadores `AND`/`OR`/`NOT`; $d_{\text{aninhamento}}$ é a profundidade de parênteses não redundantes; $n_{\text{termos}}$ é a quantidade de expressões delimitadas por aspas; e $c_{\text{caracteres}}$ é o tamanho escalar do comando textual.

Os pesos foram calibrados empiricamente através de testes iterativos contra a API OPS, observando quais combinações de fatores melhor prediziam travamentos do analisador CQL. O *nesting_ score* e *term_ score* recebem peso 0,3 (maior) por impactarem mais significativamente na capacidade de parsing, enquanto *operator_ score* e *length_ score* recebem peso 0,2 por efeito secundário na complexidade estrutural.

A agregação ponderada dos fatores estabelece o escore final:

$$\text{score} = 0{,}2 \cdot \text{operator_score} + 0{,}3 \cdot \text{nesting_score} + 0{,}3 \cdot \text{term_score} + 0{,}2 \cdot \text{length_score}$$

Quando o escore ultrapassa o limiar de corte (padrão: 60, ajustável pelo usuário em tempo de execução), ativa-se o ciclo de autocorreção que reinjeita os indicadores

estruturais como contexto de retentativa ao modelo de linguagem. O escore resultante é mapeado em níveis de complexidade conforme apresentado na Tabela 7:

Tabela 7: Níveis de classificação da função de complexidade de consulta

| **Nível** | **Faixa de Escore** |
|---|---|
| Simples | score $< 25$ |
| Moderado | $25 \leq$ score $< 50$ |
| Complexo | $50 \leq$ score $< 75$ |
| Muito Complexo | score $\geq 75$ |

## 3.6 Tecnologias Adotadas e Infraestrutura de Execução

A sustentação operacional do sistema é estruturada sobre contêineres Docker Compose e serviços locais padronizados:

**Ecossistema de Busca e APIs Externas**: A obtenção dos dados primários apoia-se em duas fontes complementares, cujas características sintáticas e restrições operacionais orientam a construção dos adaptadores de busca do sistema:

- **OPS (Open Patent Services / Espacenet)**: API REST disponibilizada pelo Escritório Europeu de Patentes (EPO), cujas consultas operam sob a linguagem CQL (*Common Query Language*), com filtros direcionados a campos como título (`ti`), resumo (`ab`), depositante (`pa`) e classificações tecnológicas (CPC e IPC). A API impõe um teto de 2.000 registros por busca e limite operacional de aproximadamente 100 requisições por segundo. Como diferencial técnico, o serviço retorna estatísticas pré-agregadas por ano, depositante e CPC diretamente na resposta, simplificando o cômputo dos indicadores. Por outro lado, seu analisador léxico rejeita consultas booleanas com excessiva profundidade de operadores, motivando a métrica de complexidade proposta na Seção 3.5.

- **Scopus (Elsevier)**: API voltada à recuperação de literatura científica revisada por pares, autenticada por chave institucional e orientada por sintaxe própria de campos (`TITLE`, `ABS`, `KEY`). Suporta até 5.000 registros por consulta com um limite estrito de 9 requisições por segundo, o que exige mecanismos internos de controle de taxa (*rate limiting*) no cliente para prevenir bloqueios de acesso. Diferentemente do OPS, o Scopus não fornece estatísticas pré-agregadas nativas, cabendo ao módulo de consolidação computar as séries anuais e afiliações a partir da lista bruta de documentos recuperados.

- **OpenAlex** [29]: Base de metadados acadêmicos abertos, acionada como serviço auxiliar de contingência. Diante da ausência recorrente de resumos textuais em registros fornecidos pela Scopus — campo indispensável para a vetorização semântica e mineração terminológica —, o sistema executa requisições pontuais à API pública da OpenAlex indexadas pelo identificador digital (DOI) do documento, restaurando a completude dos dados antes das etapas analíticas.

**Serviços Locais em Contêineres**:

- **FastAPI e Python**: camada de controle assíncrono e aplicação de lógica de negócios.
- **PostgreSQL e SQLAlchemy**: persistência transacional dos dados relacionais e históricos de prospecção.
- **ChromaDB**: banco de dados vetorial isolado em contêiner local, empregando o índice hierárquico HNSW sobre distância de cosseno, com metadados de sessão em nível de registro.
- **MinIO**: repositório de objetos compatível com o protocolo S3 da Amazon para persistência desacoplada de figuras, relatórios em LaTeX e arquivos PDF compilados.
- **TeX Live e LanguageTool** [26]: contêiner com distribuição mínima de tipografia digital para geração de PDFs e verificador sintático-gramatical para suporte à revisão em português do Brasil.

## 3.7 Modelagem do Banco de Dados

O modelo de dados relacional foi desenvolvido com mapeamento assíncrono em SQLAlchemy e versionamento estrutural via Alembic, estruturado para acompanhar o fluxo de processamento descrito na Seção 4 (Pipeline de Processamento). Cada fase da prospecção interage com diferentes entidades: a Fase 1 (Refinamento de Tema) cria e atualiza variantes em `session_input`; a Fase 2 (Busca Exploratória) popula `session_probe_query` e registra chamadas de LLM em `session_ai_call` para auditoria; a Fase 3 (Extração de Termos) persiste `probe_query_term` com scores de relevância; a Fase 4 (Busca Final) agrupa `patent` e `article` recuperados com seus relacionamentos de relevância; a Fase 5 (Geração de Relatório) consolida fragmentos de texto em `session_report_section` e o documento final em `session_report`. A Tabela 8 sintetiza as entidades da modelagem relacional ativa.

Tabela 8: Entidades do esquema relacional ativo

| **Entidade** | **Papel no Domínio** |
|---|---|
| `research_session` | Hub central; mapeia cada execução do fluxo de prospecção com seu estado corrente |
| `session_input` | Parâmetros de entrada informados; auto-relacionada (original vs. variantes) |
| `session_probe_query` | Consultas de busca estruturadas; auto-relacionada (exploratórias vs. finais) |
| `session_ai_call` | Log transacional para auditoria de chamadas e controle de custos de inferência |
| `patent`/`article` | Registros de patentes e artigos, deduplicados globalmente por `dedup_key` |
| `probe_query_patent` `probe_query_article` | Entidades associativas com atributos do relacionamento (`relevance_score`) |
| `probe_query_term` | Termos candidatos extraídos pelo módulo de PLN local |
| `session_chart` | Metadados e resumos numéricos das figuras e curvas S salvas no MinIO |
| `session_report_section` | Fragmentos de texto gerados por seção, metadados do RAG e citações |
| `session_report` | Manifesto consolidado do documento técnico gerado |
| `app_settings` | Tabela de parâmetros e limiares operacionais configuráveis |
| `llm_provider_configs` | Cadastro de provedores, URLs de endpoints, chaves e identificadores de modelo |
| `llm_call_site_bindings` | Associação configurável entre o ponto de uso funcional e o endpoint cadastrado |
| `search_api_selection` | Definição da fonte ativa para patentes e artigos científicos |

A Tabela 9 abaixo mapeia cada fase do pipeline às entidades criadas ou atualizadas, fornecendo rastreabilidade completa da execução e permitindo auditar quais dados foram gerados em cada etapa:

Tabela 9: Mapeamento de fases do pipeline às entidades de persistência

| Fase | Entidades Criadas/Atualizadas |
|---|---|
| **Intake** | `research_session` (novo), `session_input` (tema, descrição, palavras-chave), `app_settings` (parâmetros do usuário) |
| **Fase 1: Refinamento** | `session_input` (variantes de tema), `session_ai_call` (log de chamada ao LLM para tema) |
| **Fase 2: Busca Exploratória** | `session_probe_query` (queries exploratórias), `patent`/`article` (documentos recuperados), `probe_query_patent`/`probe_query_article` (relacionamentos com scores de relevância), `session_ai_call` (auditoria) |
| **Fase 3: Extração de Termos** | `probe_query_term` (termos candidatos com scores de PLN: BM25F, KeyBERT, RRF, C-value) |
| **Fase 4: Busca Final** | `session_probe_query` (queries finais: específica, balanceada, ampla), `patent`/`article` (novos documentos deduplicados), `session_chart` (metadados de gráficos: curva S, rankings, distribuições), `session_ai_call` (auditoria) |
| **Fase 5: Relatório** | `session_report_section` (6 seções analíticas geradas por LLM + 4 estáticas), metadados de RAG e citações, `session_report` (manifesto consolidado com referência ao '.tex' compilado e PDF) |

Essa modelagem relacional garante que cada decisão do usuário e cada resultado intermediário sejam persistidos e rastreáveis. O hub central `research_session` liga todas as fases, permitindo que o usuário interrompa, volte atrás ou reinicie a partir de um ponto anterior sem perda de contexto. As entidades auto-relacionadas (`session_input`, `session_probe_query`) preservam histórico de variações e iterações, essenciais para auditoria e para estudos futuros de como decisões humanas em cada fase afetam a qualidade final do relatório.

## 3.8 Implementação Plenamente Desenvolvida

O protótipo encontra-se plenamente desenvolvido e validado de ponta a ponta:

- Conexão operacional com as APIs OPS, Scopus e OpenAlex com paginação automatizada e controle de requisições.
- Pipeline determinístico de extração de termos (PLN local) funcional sem chamadas de LLM nesta etapa.
- Geração de gráficos normalizados no padrão REPTEC e ajuste automatizado da curva S com cálculo dos pontos GP, MP e SP e avaliação do coeficiente $R^2$.
- Algoritmos de inferência estatística (Chao1 — estimador não-paramétrico de riqueza que projeta quantos documentos relevantes ainda não foram descobertos, validado por 1.000 reamostragens *bootstrap* para garantir estabilidade numérica com margem de erro $< 5\%$ e custo computacional viável) operantes na busca final.

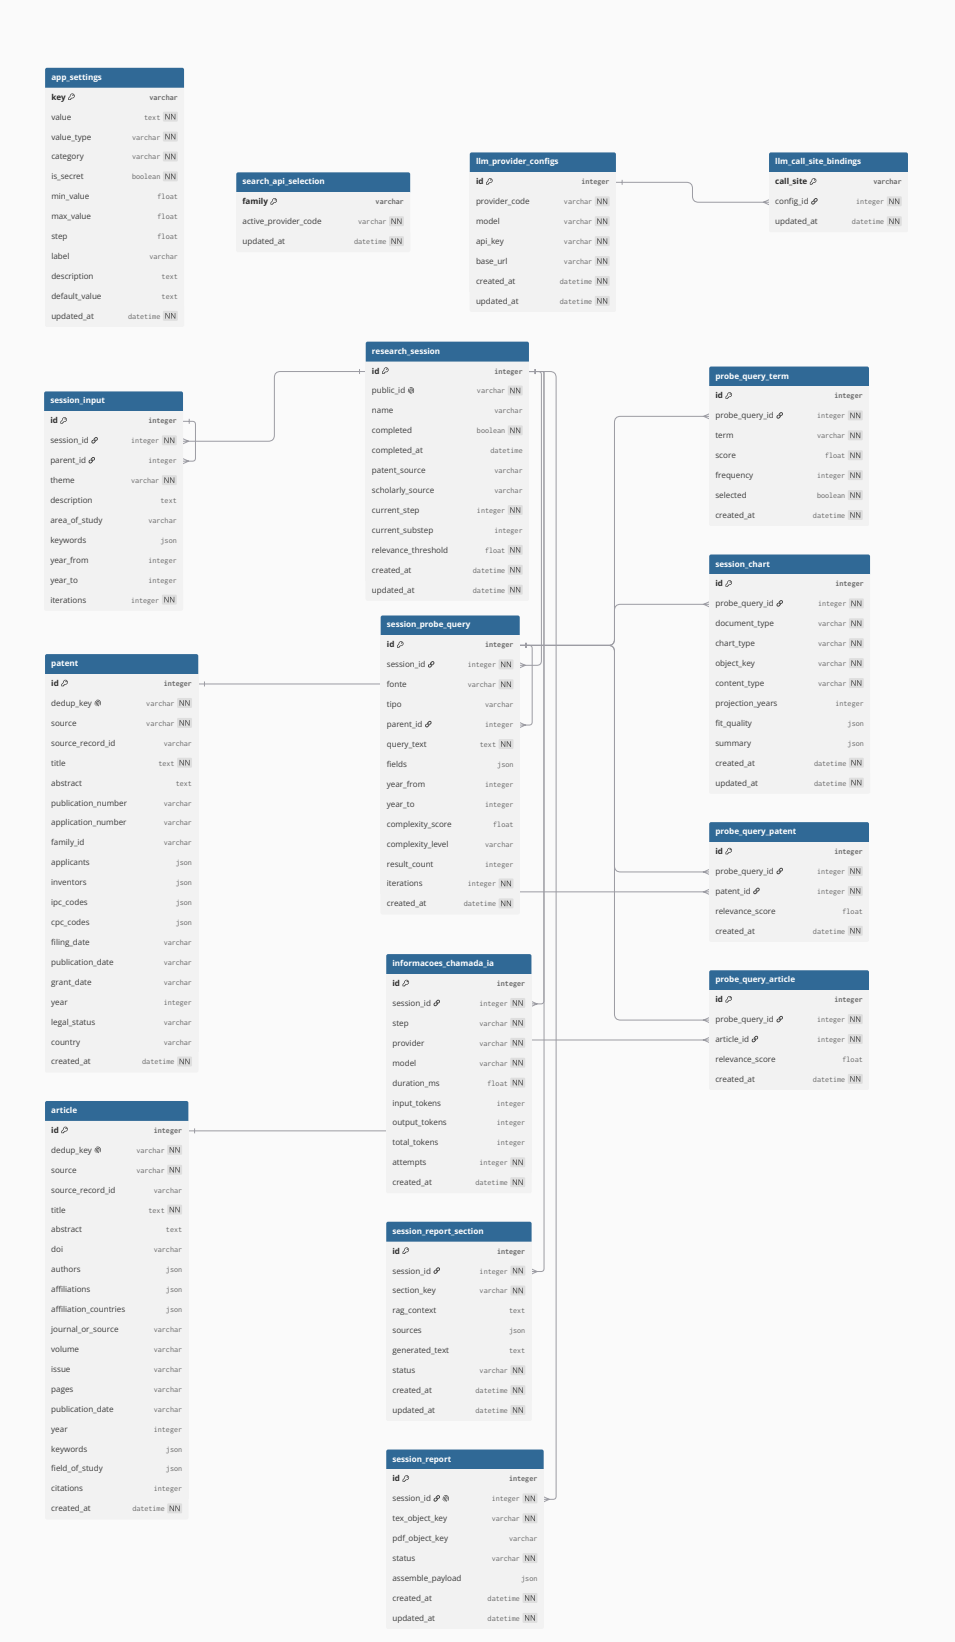



Figura 10: Diagrama entidade-relacionamento do esquema relacional ativo. Fonte: elaborado pelos autores com a ferramenta dbdiagram.io.

- Geração textual em RAG local ancorada em banco vetorial ChromaDB, com validação estruturada, controle de citações autor-data e compilação do documento em PDF no serviço TeX Live.

# 4 *Pipeline* de Processamento

O *pipeline* operacional de prospecção tecnológica desdobra-se em cinco fases consecutivas:




Figura 11: Visão geral das cinco fases do *pipeline* de prospecção tecnológica.

## 4.1 Fase 1: Refinamento do Tema

A fase de refinamento recebe os termos fornecidos pelo usuário no formulário inicial e aciona o LLM alocado ao ponto de uso correspondente. O modelo infere quatro variações do tema, expandindo o escopo terminológico com expressões correlatas em inglês técnico. A temperatura do modelo é configurada em 0,3. O usuário seleciona e, se necessário, ajusta a melhor variante através da interface gráfica antes de autorizar a exploração das bases.

## 4.2 Fase 2: Busca Exploratória e Filtros Documentais

Com o tema validado, o sistema executa buscas paralelas nas bases de patentes (OPS) e artigos (Scopus), restringindo o retorno a uma amostra de 10 documentos por base. Esse limiar foi determinado empiricamente como o mínimo necessário para manter estabilidade de termos extraídos entre execuções sucessivas, validado via reamostragem *bootstrap* (Seção 3.5). O parâmetro `probe_top_k` é ajustável em tempo de execução, permitindo que usuários adaptem a profundidade da exploração segundo suas necessidades. A complexidade sintática de cada consulta é verificada previamente pelo avaliador determinístico (Seção 3.5).

Os documentos brutos retornados são submetidos a dois portões de validação antes de seguirem para a extração terminológica:

(a) **Filtro de Idioma**: um classificador estatístico processa o título e resumo concatenados, descartando documentos cujo texto não seja classificado com confiança como língua inglesa.

(b) **Filtro de Relevância Documento-Tema**: calcula-se a similaridade de cosseno (Seção 2.6) entre o vetor denso do tema de pesquisa e o vetor do documento. Para maximizar a qualidade do embedding, aplica-se uma estratégia de composição

com fallback: (i) usa-se o resumo sozinho se robusto ($> 50$ caracteres); (ii) senão, combina-se título e resumo; (iii) senão, usa-se apenas o título; (iv) em último caso, primeiros 200 tokens do texto completo. Documentos cujo escore de similaridade seja inferior a 0,4 são rejeitados, garantindo que termos anômalos não ingressem na fase de mineração. O parâmetro `relevance_threshold` é ajustável; se nenhum documento da amostra probe atingir o limiar, a fase segue com documentos aprovados rejeitados, sinalizando ao usuário a necessidade de relaxar o critério ou refinar o tema.

## 4.3 Fase 3: Extração e Ranqueamento de Termos

A mineração de palavras-chave a partir da amostra validada é conduzida inteiramente por uma esteira local de Processamento de Linguagem Natural, baseada nos fundamentos da Seção 2.7:

**Passo 1. Limpeza Textual e Demarcação de Fronteiras**: normalização para caracteres minúsculos, supressão de URLs, pontuação padronizada para evitar que regras morfossintáticas agreguem falsos limites frasais.

**Passo 2. Extração Morfossintática (PatternRank)**: isolamento de frases nominais contíguas que atendam ao padrão *adjetivo* substantivo+*[1] [35], com extensão máxima de até 5 palavras.

**Passo 3. Filtro de Sobreposição Original**: remoção de unigramas idênticos às palavras-chave originalmente inseridas pelo usuário, preservando termos compostos que agreguem especificidade.

**Passo 4. Filtro de Qualidade Lexical**: poda de extremidades com palavras de parada (*stopwords*) e descarte integral de expressões que contenham jargões genéricos de redação patentária ou acadêmica (*wherein, comprising, method, framework*).

**Passo 5. Ponderação Lexical por Campos (BM25F)**: cálculo do escore com ponderação diferencial de campos ($w_{\text{tít}} = 3$ e $w_{\text{res}} = 1$ — priorizando termos em títulos), adotando saturação $k_1 = 1{,}2$ (reduz impacto de repetições excessivas) e normalização $b = 0{,}75$ (compensa diferenças de comprimento entre campos) [31].

**Passo 6. Aferição Semântica Vetorial (KeyBERT)**: vetorização contextual dos candidatos e mensuração da similaridade de cosseno contra a representação vetorial global da amostra [12].

**Passo 7. Primeira Fusão por Posição (Saliência)**: consolidação posicional dos canais BM25F e KeyBERT por Reciprocal Rank Fusion (RRF) com constante $k = 60$ (favorece termos bem classificados em **ambos** os canais sobre excelentes em apenas um; $k = 60$ é convenção em buscas híbridas, oferecendo relação $\approx 1{,}15$ entre primeira e décima posição) [22].

[1] $*$ = zero ou mais ocorrências; $+$ = uma ou mais ocorrências. Exemplos: *energia renovável* (adjetivo + substantivo), *sistemas avançados de aprendizado de máquina* (adjetivo + substantivo + prep. + substantivo + prep. + substantivo)

**Passo 8. Ponderação Estrutural de Comprimento**: ajuste fino posicional atribuindo penalidades para unigramas ($-0{,}4$ — palavras isoladas são menos específicas) e bonificações para trigramas ($+0{,}25$ — expressões compostas agregam semântica) e superiores, favorecendo termos compostos de qualidade.

**Passo 9. Segunda Fusão RRF (Escore Final)**: geração do ordenamento consolidado definitivo.

**Passo 10. Filtragem de Termos Aninhados (C-value)**: cálculo do grau de independência formal de expressões compostas, eliminando termos contidos cujo C-value seja nulo ou que estejam contíguos no interior de uma expressão com maior pontuação relativa [23].

**Passo 11. Corte por Limiar**: retenção de termos com escore final RRF $\geq 0{,}024$ (calibrado empiricamente), com garantia de mínimo 10 candidatos (mesmo que abaixo do limiar, para não descartar lotes pequenos) e máximo 60 (para controlar custo computacional e evitar ruído), resultando em uma lista balanceada para seleção pelo usuário.

Os termos resultantes são exibidos na interface, onde o analista humano seleciona os itens a incorporar e estipula a abrangência da busca definitiva: **Específica** (corte $\geq 0{,}4$ — conceitos centrais apenas), **Balanceada** ($\geq 0{,}3$ — equilíbrio cobertura–precisão) ou **Ampla** ($\geq 0{,}2$ — máxima cobertura de variantes). Cada estratégia reflete um trade-off entre recuperar documentos relevantes e descartar ruído.

## 4.4 Fase 4: Busca Final e Inferência Estatística

A consulta booleana final gerada pelo LLM e validada pelo usuário é submetida às APIs externas. Empregando paginação automática, os registros recuperados são consolidados e deduplicados por chave composta única no PostgreSQL.

A completude amostral da busca é monitorada pelo estimador com correção de viés de Chao1 ($\hat{S}_{\text{Chao1}}$) aplicado sobre a distribuição de depositantes e classificações CPC. A busca conclui sua iteração quando a completude atinge saturação $S_{\text{obs}}/\hat{S}_{\text{Chao1}} \geq 0{,}5$, a taxa de *singletons* cai para $f_1/S_{\text{obs}} \leq 0{,}7$ e registram-se pelo menos 5 *doubletons* ($f_2 \geq 5$). Paralelamente, processam-se 1.000 iterações não paramétricas de reamostragem *bootstrap* para calcular o índice percentual de permanência e estabilidade das entidades componentes do ranking top-10.

## 4.5 Fase 5: Geração e Revisão do Relatório Técnico

A geração do documento final estrutura-se em cinco macroetapas:

1. **Consolidação Gráfica**: processamento das séries anuais de patentes e artigos, mapeamento dos 10 principais atores e classificações tecnológicas, ajuste das curvas S via modelo logístico de Fisher-Pry, cálculo das coordenadas GP, MP e SP e gravação dos arquivos PNG no repositório MinIO.

2. **Indexação e Recuperação Vetorial via RAG Local**: particionamento de resumos e títulos dos documentos em fragmentos de 1.000 caracteres (sobreposição de 200), conversão em representações densas SBERT e armazenamento na coleção dedicada do ChromaDB. Para cada seção analítica do relatório, os $k = 5$ fragmentos de maior proximidade semântica são recuperados, aplicando-se o corte relativo de relevância de 75%.

3. **Redação Analítica Condicionada**: os trechos documentais aprovados são concatenados em texto plano no prompt do modelo de linguagem alocado para redação. O modelo redige o texto técnico corrido com a estrita obrigação de limitar suas citações às fontes recuperadas no formato "(SOBRENOME et al., ano)". Seções estruturais formais e metodológicas (Finalidade, Metodologia, Quadros de Busca e Assinaturas) são incorporadas deterministicamente por código.

4. **Montagem e Validação Determinística**: compilação do arquivo LaTeX mestre, inspeção automática de numerais para pontuação decimal brasileira e exclusão de citações inválidas perante o banco relacional.

5. **Revisão Gramatical e Compilação**: submissão do texto ao analisador LanguageTool executado localmente para correção ortográfica, facultando ao analista a aplicação de uma revisão estilística por LLM. O artefato LaTeX final é compilado no serviço TeX Live e disponibilizado em pacote '.zip' e formato PDF.

# 5 Conclusão

## 5.1 Síntese das Contribuições

O sistema desenvolvido cumpriu o objetivo de automatizar o percurso completo de uma prospecção tecnológica, da submissão do tema à exportação do relatório no padrão REPTEC. Um levantamento que, conduzido manualmente, consome dias de trabalho qualificado — definição de termos de busca, consulta a bases com sintaxes distintas, triagem de resultados, apuração de instituições e depositantes, análise temporal e consolidação em documento estruturado [24, 28] — passou a ser executado como um fluxo único, com o esforço humano concentrado nos pontos de decisão: validação do tema, seleção dos termos, escolha da consulta final e revisão do texto produzido. Essa redução libera tempo dos técnicos e engenheiros envolvidos em projetos de PD&I do Exército Brasileiro para atividades de maior valor estratégico.

Os relatórios gerados seguem a estrutura em oito seções do padrão REPTEC, com as figuras previstas apresentadas e interpretadas no texto, o quadro das consultas efetivamente submetidas, o estágio do ciclo de vida calculado a partir do ajuste da curva S e as referências restritas aos documentos recuperados na busca. A viabilidade metodológica do formalismo GP/MP/SP adotado para leitura da curva S já estava demonstrada na prática institucional da AGITEC com dados reais de patentes e publicações, como evidenciado em [4], e sua automação mostrou-se aderente a esse precedente.

A separação entre o que é produzido pelo modelo de linguagem e o que é produzido deterministicamente foi decisiva para esse resultado. Os números das figuras, o estágio do ciclo de vida, as seções de texto fixo, o posicionamento das figuras e a bibliografia não dependem do modelo, o que restringe a atuação dele à redação do texto corrido

— justamente onde o embasamento é garantido pelo contexto recuperado via RAG e verificado pelo filtro de citações. É importante ressaltar que o sistema não substitui o julgamento especializado do analista humano, mas fornece um documento estruturado e rastreável que torna esse julgamento mais eficiente e informado [13, 16].

Além do sistema em si, destacam-se como contribuições deste trabalho: a função heurística de complexidade de consulta e o padrão de autocorreção por métrica determinística (Seção 3.5); o *pipeline* local de extração e pontuação de termos (Seção 4.3), que dispensa o uso de LLM nessa etapa; a arquitetura defensiva de validação em camadas para saídas estruturadas (Seção 3.4.2); o emprego da estimação de completude amostral e de estabilidade de *ranking* para qualificar a confiabilidade dos indicadores apresentados; e a configuração dos modelos de linguagem por ponto de uso (Seção 3.4.1).

## 5.2 Atendimento aos Objetivos

O objetivo geral — automatizar a prospecção tecnológica por meio da consulta integrada a bases de artigos e patentes, da análise dos resultados e da geração de um relatório no padrão da AGITEC — foi atingido, conforme o estado de desenvolvimento descrito na Seção 3.8. Quanto aos objetivos específicos:

i. A integração com modelos de linguagem remotos e locais, configuráveis por ponto de uso, foi implementada e exercitada com modelos locais via Ollama e com o modelo do servidor interno do IME.

ii. A integração com as APIs OPS e Scopus foi implementada e validada com consultas reais, incluindo paginação, controle de taxa e novas tentativas em falhas de rede.

iii. Os construtores de consulta traduzem os termos selecionados para a sintaxe de cada base, com operadores booleanos, filtros temporais e campos específicos, e têm a complexidade estrutural verificada antes do envio.

iv. A geração de consultas por LLM foi combinada ao *pipeline* local de PLN para extração e pontuação de termos a partir dos resultados exploratórios.

v. O ciclo de validação humana está presente em todas as decisões do fluxo: validação do tema, seleção dos termos e escolha da consulta final.

vi. Os metadados das diferentes APIs são consolidados em formato unificado e agregados por ano, depositante ou instituição e classificação, complementados pela inferência estatística por Chao1 e *bootstrap*.

vii. A fase de maturidade tecnológica é calculada automaticamente a partir do ajuste da curva S, com os pontos GP/MP/SP e o diagnóstico de confiabilidade do ajuste.

viii. O relatório é gerado no padrão REPTEC, em LaTeX editável, com as seções redigidas por RAG sobre os documentos indexados no ChromaDB.

ix. A persistência foi distribuída entre PostgreSQL (metadados), ChromaDB (*embeddings*) e MinIO (gráficos, `.tex` e PDF).

x. A interface *web* foi implementada como assistente guiado, com auditoria do uso de IA, retomada de sessões, editor do relatório, compilação em PDF e exportação.

## 5.3 Limitações

O sistema apresenta algumas limitações que devem ser consideradas. A qualidade do texto produzido é diretamente proporcional à capacidade do modelo vinculado ao ponto de uso de redação [40]: em avaliações empíricas com modelos de menor porte executados localmente (como Qwen 2.5 3B e Gemma 3 4B), adequados a máquinas comuns mas de capacidade inferior à de modelos maiores [5], observaram-se falhas ocasionais de português formal — sobretudo desvios de concordância verbal em sentenças com sujeito posposto ou distante — e menor profundidade analítica. Modelos de maior porte, como o hospedado no servidor interno do Instituto Militar de Engenharia, atenuam substancialmente esse efeito, mas o deslocam para outra dependência: a disponibilidade da infraestrutura institucional e do acesso à rede interna. Em qualquer dos casos, a etapa de revisão (Seção 4.5) detecta boa parte dos erros de superfície, mas não substitui a leitura do especialista. O corpus do RAG é composto apenas por título e resumo dos documentos da busca final, e, como os resumos de artigos nem sempre são devolvidos pelas APIs, tende a ser majoritariamente de patentes, o que pode empobrecer a fundamentação das seções sobre a produção científica. O limiar de corte da extração de termos foi calibrado sobre um conjunto de teste, e não sobre histórico real de uso. Por fim, o sistema depende de chave de acesso institucional para a API Scopus, o que pode limitar sua disponibilidade em contextos sem convênio ativo com a Elsevier.

Adicionalmente, a heterogeneidade dos dados retornados pelas diferentes APIs impõe desafios de normalização que, apesar de tratados pelo módulo de consolidação, podem resultar em inconsistências pontuais quando as APIs alteram seus formatos de resposta. O fenômeno de alucinação dos LLMs [13], embora mitigado pela adoção do RAG [16], pela restrição das citações aos documentos recuperados e pela produção determinística das seções fixas, dos números dos gráficos e do estágio do ciclo de vida, não é completamente eliminado, o que reforça a necessidade de revisão humana dos relatórios gerados antes de sua utilização em decisões estratégicas.

## 5.4 Trabalhos Futuros

As limitações identificadas e as inconsistências observadas no caso de estudo prático (Apêndice B) apontam os principais desdobramentos para a continuidade e aprimoramento do trabalho:

- **Desambiguação e Normalização de Entidades:** Implementar algoritmos de agrupamento por similaridade textual (*fuzzy matching*) e integração com identificadores padronizados (como o *Research Organization Registry* – ROR) para unificar variantes de grafia de depositantes e vincular departamentos genéricos às suas respectivas universidades-mãe.
- **Sanitização Avançada de Metadados:** Incorporar modelos de Reconhecimento de Entidades Nomeadas (NER) dedicados à validação de autoria e afiliação, evitando que falhas de *parsing* ou fragmentos textuais descritivos de patentes sejam convertidos erroneamente em nomes de autores.
- **Diagnóstico Integrado do Ciclo de Vida (CVT):** Aprimorar a inferência automática do ciclo de vida da tecnologia para considerar a dinâmica combinada entre a

curva patentária e a produção científica, evitando conclusões unilaterais de saturação quando a pesquisa acadêmica de base ainda demonstrar regime de maturidade ativa.

- **Geração Automática de Ressalvas Metodológicas:** Ajustar os *templates* e *prompts* de redação para que o relatório explicite deterministicamente as razões de divergência entre o total indexado e a série analisada (descarte de anos incompletos), além de esclarecer a natureza não mutuamente excludente das áreas multidisciplinares.
- **Avaliação com Usuários Reais:** Conduzir, junto à AGITEC, uma avaliação comparativa entre relatórios elaborados manualmente e relatórios gerados pelo sistema sobre os mesmos temas, medindo o tempo de elaboração e a qualidade técnica percebida pelos analistas.
- **Ampliação do Corpus do RAG:** Incorporar o texto completo dos documentos, quando disponível, e integrar novas fontes complementares de literatura (como arXiv, PubMed ou Google Patents), reduzindo a dependência de assinaturas institucionais e equilibrando a fundamentação entre ciência e indústria.
- **Calibração Contínua de Heurísticas:** Recalibrar o limiar de corte da extração de termos e os pesos da função de complexidade a partir do histórico real de uso e validação humana registrado pelo próprio sistema.
- **Implantação Institucional:** Homologar o sistema na infraestrutura do Exército Brasileiro, com armazenamento de artefatos na instância corporativa do MinIO e controle granular de acesso por usuário.

## 5.5 Considerações Finais

Este trabalho demonstrou a viabilidade técnica e prática de automatizar, de ponta a ponta, a elaboração de relatórios de prospecção tecnológica no padrão exigido pelo Exército Brasileiro, integrando modelos de linguagem, recuperação de informação e módulos de processamento determinístico. A validação empírica realizada com um tema real de alta densidade técnica (o caso dos catalisadores de petróleo, documentado no Apêndice B) comprovou a capacidade da ferramenta em converter parâmetros elementares de busca em um documento analítico completo e estruturado.

O principal diferencial metodológico da solução residiu na criteriosa segregação de responsabilidades: coube aos modelos generativos a redação analítica estritamente condicionada aos fragmentos recuperados; aos algoritmos determinísticos e estatísticos, a computação confiável de números, ajustes de curva S, mapeamentos e citações bibliográficas; e ao analista humano, a tomada de decisão nos pontos críticos de validação intermediária e a revisão final. Essa arquitetura modular e executável em infraestrutura local não apenas resguarda o sigilo e a soberania sobre temas estratégicos de defesa, mas também mitiga expressivamente o risco de alucinações factuais.

Por fim, os experimentos práticos evidenciaram que, embora o sistema reduza um trabalho de dias para poucos minutos de processamento, a inteligência artificial não deve ser concebida como substituta do especialista, mas sim como um vetor de ampliação de sua capacidade analítica. As inconsistências pontuais observadas em ambiente real

reforçam a premissa de que a curadoria humana permanece indispensável. Espera-se que a plataforma desenvolvida contribua efetivamente para a modernização das rotinas da AGITEC, estabelecendo a prospecção tecnológica como uma prática ágil, metódica e contínua em apoio às decisões de PD&I e aos projetos estratégicos do Exército Brasileiro.

**Referências**


[1] RODRÍGUEZ-SALVADOR, Marisela; RIO-BELVER, Rosa María; GARECHANA-ANACABE, Gaizka. Scientometric and patentometric analyses to determine the knowledge landscape in innovative technologies: the case of 3D bioprinting. *PLOS ONE*, v. 12, n. 6, e0180375, 2017. DOI: 10.1371/journal.pone.0180375.

[2] LEZAMA-NICOLÁS, René; RODRÍGUEZ-SALVADOR, Marisela; RÍO-BELVER, Rosa; BILDOSOLA, Iñaki. A bibliometric method for assessing technological maturity: the case of additive manufacturing. *Scientometrics*, v. 117, n. 3, p. 1425–1452, 2018. DOI: 10.1007/s11192-018-2941-1.

[3] AGITEC — Agência de Gestão e Inovação Tecnológica do Exército Brasileiro. *Metodologia de Avaliação e Análise Tecnológica AVANTEC V2*. Manual Técnico. Departamento de Ciência e Tecnologia. Rio de Janeiro: Exército Brasileiro, 2024.

[4] GUIMARÃES, Ricardo Wagner Amorim; BALTHAZAR NETO, Antonio Victorino Pereira; GALANTE, Erick Braga Ferrão. *REPTEC 001/2023 — Relatório de Prospecção Tecnológica: Terrestrial Trunked Radio (TETRA)*. Rio de Janeiro: Agência de Gestão e Inovação Tecnológica (AGITEC), Exército Brasileiro, 2023.

[5] BROWN, T. B. et al. Language models are few-shot learners. *Advances in Neural Information Processing Systems*, v. 33, p. 1877–1901, 2020. Disponível em: `https://arxiv.org/abs/2005.14165`. Acesso em: 05 maio 2026.

[6] CHAO, Anne. Nonparametric estimation of the number of classes in a population. *Scandinavian Journal of Statistics*, v. 11, n. 4, p. 265–270, 1984.

[7] EFRON, Bradley. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, v. 7, n. 1, p. 1–26, 1979. DOI: 10.1214/aos/1176344552.

[8] COCKBURN, Alistair. *Hexagonal Architecture* (Ports and Adapters). HaT Technical Report 2005.02, 4 set. 2005. Disponível em: `https://alistair.cockburn.us/hexagonal-architecture/`. Acesso em: 10 ago. 2026.

[9] FISHER, J. C.; PRY, R. H. A simple substitution model of technological change. *Technological Forecasting and Social Change*, v. 3, p. 75–88, 1971. DOI: 10.1016/S0040-1625(71)80005-7.

[10] FOSTER, R. N. *Innovation: The Attacker's Advantage*. New York: Summit Books, 1986. 316 p.

[11] GAO, Y. et al. Retrieval-augmented generation for large language models: a survey. *arXiv*. arXiv:2312.10997, mar. 2024. Disponível em: `https://arxiv.org/abs/2312.10997`. Acesso em: 05 maio 2026.

[12] GROOTENDORST, Maarten. KeyBERT: Minimal keyword extraction with BERT. *Zenodo*, 2020. DOI: 10.5281/zenodo.4461265.

[13] JI, Z. et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, v. 55, n. 12, art. 248, 2023. DOI: 10.1145/3571730.

[14] ERNST, H. The use of patent data for technological forecasting: the diffusion of CNC-technology in the machine tool industry. *Small Business Economics*, v. 9, n. 4, p. 361–381, 1997.

[15] KUCHARAVY, D.; DE GUIO, R. Application of S-shaped curves. *Procedia Engineering*, v. 9, p. 559–572, 2011. DOI: 10.1016/j.proeng.2011.03.142.

[16] LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, v. 33, p. 9459–9474, 2020. Disponível em: `https://arxiv.org/abs/2005.11401`. Acesso em: 05 maio 2026.

[17] MANKINS, John C. *Technology Readiness Levels: A White Paper*. Washington, DC: Advanced Concepts Office, Office of Space Access and Technology, NASA, 6 abr. 1995.

[18] MARTIN, Robert C. *Agile Software Development: Principles, Patterns, and Practices*. Upper Saddle River: Prentice Hall, 2002.

[19] MARTIN, Robert C. *Clean Architecture: A Craftsman's Guide to Software Structure and Design*. Boston: Pearson, 2017.

[20] CHEN, Peter Pin-Shan. The entity-relationship model — toward a unified view of data. *ACM Transactions on Database Systems*, v. 1, n. 1, p. 9–36, 1976. DOI: 10.1145/320434.320440.

[21] CODD, Edgar F. A relational model of data for large shared data banks. *Communications of the ACM*, v. 13, n. 6, p. 377–387, 1970. DOI: 10.1145/362384.362685.

[22] CORMACK, G. V.; CLARKE, C. L. A.; BUETTCHER, S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In: INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 32., 2009, Boston. *Proceedings* [...]. New York: ACM, 2009. p. 758–759. DOI: 10.1145/1571941.1572114.

[23] FRANTZI, K.; ANANIADOU, S.; MIMA, H. Automatic recognition of multi-word terms: the C-value/NC-value method. *International Journal on Digital Libraries*, v. 3, n. 2, p. 115–130, 2000. DOI: 10.1007/s007999900023.

[24] MAYERHOFF, Z. D. V. L. Uma análise sobre os estudos de prospecção tecnológica. *Cadernos de Prospecção*, v. 1, n. 1, p. 7–9, 2008.

[25] MIKOLOV, T. et al. Distributed representations of words and phrases and their compositionality. *Advances in Neural Information Processing Systems*, v. 26, p. 3111–3119, 2013. Disponível em: `https://arxiv.org/abs/1310.4546`. Acesso em: 05 maio 2026.

[26] NABER, Daniel. *A Rule-Based Style and Grammar Checker*. 2003. 93 f. Dissertação (Mestrado em Engenharia da Computação) – Technische Fakultät, Universität Bielefeld, Bielefeld, Alemanha, 2003.

[27] NIELSEN, Michael A. *Neural Networks and Deep Learning*. Determination Press, 2015. Disponível em: `http://neuralnetworksanddeeplearning.com/`. Acesso em: 10 ago. 2026.

[28] PORTER, A. L. et al. Technology futures analysis: toward integration of the field and new methods. *Technological Forecasting and Social Change*, v. 71, n. 3, p. 287–303, mar. 2004. DOI: 10.1016/j.techfore.2003.11.004.

[29] PRIEM, Jason; PIWOWAR, Heather; ORR, Richard. OpenAlex: a fully-open index of scholarly works, authors, venues, institutions, and concepts. *arXiv*. arXiv:2205.01833, maio 2022. Disponível em: `https://arxiv.org/abs/2205.01833`. Acesso em: 05 maio 2026.

[30] REIMERS, N.; GUREVYCH, I. Sentence-BERT: sentence embeddings using siamese BERT-networks. In: *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2019, Hong Kong. *Proceedings...* Stroudsburg: Association for Computational Linguistics, 2019. p. 3982–3992. Disponível em: `https://arxiv.org/abs/1908.10084`. Acesso em: 05 maio 2026.

[31] ROBERTSON, S.; ZARAGOZA, H.; TAYLOR, M. Simple BM25 extension to multiple weighted fields. In: ACM INTERNATIONAL CONFERENCE ON INFORMATION AND KNOWLEDGE MANAGEMENT (CIKM), 13., 2004, Washington. *Proceedings* [...]. New York: ACM, 2004. p. 42–49. DOI: 10.1145/1031171.1031181.

[32] ROBERTSON, S.; ZARAGOZA, H. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, v. 3, n. 4, p. 333–389, 2009. DOI: 10.1561/1500000019.

[33] ROGERS, E. M. *Diffusion of Innovations*. 5. ed. New York: Free Press, 2003. 551 p.

[34] SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988. DOI: 10.1016/0306-4573(88)90021-0.

[35] SCHOPF, T.; KLIMEK, S.; MATTHES, F. PatternRank: leveraging pretrained language models and part of speech for unsupervised keyphrase extraction. In: INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND INFORMATION RETRIEVAL (KDIR), 14., 2022, Valletta. *Proceedings* [...]. Setúbal: SciTePress, 2022. p. 243–248. DOI: 10.5220/0011546600003335.

[36] VASWANI, A. et al. Attention is all you need. *Advances in Neural Information Processing Systems*, v. 30, 2017. Disponível em: `https://arxiv.org/abs/1706.03762`. Acesso em: 05 maio 2026.

[37] VIRTANEN, Pauli et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, v. 17, n. 3, p. 261–272, 2020. DOI: 10.1038/s41592-019-0686-2.

[38] WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, v. 35, p. 24824–24837, 2022. Disponível em: `https://arxiv.org/abs/2201.11903`. Acesso em: 05 maio 2026.

[39] WHITE, J. et al. A prompt pattern catalog to enhance prompt engineering with ChatGPT. *arXiv*. arXiv:2302.11382, fev. 2023. Disponível em: `https://arxiv.org/abs/2302.11382`. Acesso em: 05 maio 2026.

[40] ZHAO, W. X. et al. A survey of large language models. *arXiv*. arXiv:2303.18223, mar. 2023. Disponível em: `https://arxiv.org/abs/2303.18223`. Acesso em: 05 maio 2026.

[41] MADEO, F. C. B. *Prospecção tecnológica utilizando a análise multicritério e técnicas bibliométricas*: estudo de caso para o setor de Defesa. 144 p. 2019. Dissertação (Mestrado em Engenharia de Defesa) – Instituto Militar de Engenharia, Rio de Janeiro, 2019.

# APÊNDICE A – PROMPTS DE INTELIGÊNCIA ARTIFICIAL NO PIPELINE DE PROSPECÇÃO

## A.1 Organização dos *prompts*

Toda chamada a um LLM no sistema combina duas partes. A primeira é um *prompt* de sistema fixo, armazenado em arquivo no repositório (diretório `config/prompts/`) e idêntico para todas as sessões: ele define o papel do modelo, as regras obrigatórias e o formato exato da saída. A segunda é o conjunto de dados da sessão, inserido pelo código no momento da chamada: o tema e os parâmetros informados pelo usuário, os termos extraídos dos documentos, as métricas de complexidade da tentativa anterior ou os trechos recuperados pelo RAG, conforme a fase. Essa separação é o que permite que um mesmo conjunto de instruções, revisado e versionado junto com o código, seja reutilizado em qualquer prospecção. A Tabela 10 resume as chamadas a LLM ao longo das cinco fases do *pipeline*; o modelo usado em cada uma é definido pelo ponto de uso correspondente (Seção 3.4.1).

Tabela 10: Chamadas a LLM ao longo do *pipeline*

| **Fase** | **Ponto de uso** | ***Prompt* fixo** | **Dados da sessão inseridos** | **Saída** |
|---|---|---|---|---|
| 1 – Refinamento do tema | `theme_candidates` | `refine_topic_system_prompt.txt` | Tema, descrição, área de estudo, palavras-chave e campos a preservar | JSON com quatro variações do tema |
| 2 – Busca exploratória | `probe_query` | `probe_system_prompt.txt` e dica de campos da API | Tema escolhido, descrição, área e palavras-chave; na retentativa, as métricas de complexidade | JSON com os campos de busca |
| 3 – Extração de termos | – | Não usa LLM | – | – |
| 4 – Busca final | `final_query` | `final_system_prompt.md` | Variante, tipo de documento, termos extraídos com pontuação e códigos IPC/CPC observados; na retentativa, as métricas de complexidade | JSON com os campos de busca |
| 5 – Redação do relatório | `report_writing` | `REPORT_SYSTEM_PROMPT` e *prompt* da seção | Trechos recuperados pelo RAG com a citação, números das figuras, estágio do ciclo de vida e tema | Texto corrido da seção |
| 5 – Revisão do texto | `report_review` | `AI_REVIEW_SYSTEM_PROMPT` | Parágrafo gerado a revisar | JSON com as correções |

Nas listagens deste apêndice, os valores que vêm da sessão aparecem destacados em azul; todo o restante é texto fixo. Os *prompts* das Fases 1, 2 e 4 são redigidos em inglês, idioma das consultas submetidas às bases OPS e Scopus, e foram mantidos no original. Os da Fase 5 são redigidos em português, idioma do relatório. Os trechos omitidos dos *prompts* fixos estão indicados por [...].

## A.2 Sessão de exemplo

Para mostrar como os dados de uma sessão entram nos *prompts*, adota-se uma sessão ilustrativa, cujos valores são fictícios, mas estão no formato exato produzido pelo sistema. As listagens com dados da sessão foram geradas pelas próprias funções do código que montam os *prompts*, alimentadas com os valores abaixo.

- **Parâmetros informados pelo usuário:** tema "Drones para vigilância de fronteiras", área de estudo "Engenharia" e palavras-chave "UAV" e "sensoriamento", sem descrição.
- **Tema escolhido na Fase 1:** "Autonomous UAV-based surveillance systems for border monitoring", uma das quatro variações propostas pelo modelo, com a descrição gerada por ele.
- **Resultado da Fase 3:** oito termos extraídos dos documentos exploratórios, entre eles *unmanned aerial vehicle*, *border surveillance* e *drone detection*, e quatro códigos IPC observados nas patentes recuperadas.
- **Resultado da busca final:** 1.842 artigos (2005–2025) e 967 patentes (2008–2025), com as curvas S de artigos em estágio de maturidade e de patentes em estágio de crescimento.

## A.3 Fase 1: Refinamento do tema

O *prompt* fixo instrui o modelo a transformar o tema informado em quatro variações específicas e distintas entre si (Listagem 1). O código monta a mensagem com os campos preenchidos no formulário e acrescenta a lista dos campos que o modelo deve devolver, indicando os valores a preservar (Listagem 2). Os campos não informados pelo usuário, como a descrição neste exemplo, simplesmente não aparecem na mensagem. Mesmo com a instrução de preservação, o código sobrescreve a área de estudo e as palavras-chave da resposta com os valores originais.

Listagem 1: Trecho do *prompt* fixo da Fase 1 (`refine_topic_system_prompt.txt`)

```
You are a specialist in technology foresight and thematic refinement.

Your task is to receive a user-defined theme and refine it into 4 more specific,
distinct, and technically meaningful variations.

Your output MUST be a valid JSON object following the exact structure defined below.
[...]
2. FIELD PRESERVATION
- If "area_of_study" is provided → COPY EXACTLY in all candidates
- If "keywords" are provided → COPY EXACTLY in all candidates
```

```
- NEVER modify, translate, or expand provided keywords
[...]
5. DIVERSITY REQUIREMENT (CRITICAL)
Each generated theme MUST be substantially different from the others.

Each variation must introduce a distinct angle, such as:
- different application domain
- different technical approach or methodology
- different operational context
- different scale (tactical vs strategic)
- different constraints or environments
[...]
BAD EXAMPLE:
- "AI for drones"
- "Artificial intelligence in drones"
- "Machine learning for UAVs"

GOOD EXAMPLE:
- "Autonomous swarm coordination for military drones in contested environments"
- "Computer vision-based target recognition in low-visibility drone operations"
- "Energy-efficient flight optimization for long-endurance UAV missions"
- "Secure communication protocols for anti-jamming drone systems"
[...]
OUTPUT STRUCTURE

{
  "candidates": [
    {
      "theme": "...",
      "description": "...",
      (include "area_of_study" ONLY if provided in input),
      (include "keywords" ONLY if provided in input)
    },
    [...]
  ]
}
```

Listagem 2: Mensagem montada com os dados da sessão na Fase 1

```
Tema: Drones para vigilância de fronteiras
Área de Estudo: Engenharia
Palavras-chave: UAV, sensoriamento

Campos fornecidos pelo usuário (retorne APENAS estes):
- theme: SIM (sempre refine em 4 variações)
- description: SIM (gere sempre uma descrição nova para cada variação, mesmo que
nenhuma tenha sido informada)
- area_of_study: SIM (PRESERVE exatamente: 'Engenharia')
- keywords: SIM (PRESERVE exatamente: ['UAV', 'sensoriamento'])
```

## A.4 Fase 2: Busca exploratória

A Fase 2 é executada uma vez para cada base (OPS e Scopus). O *prompt* fixo (Listagem 3) define as regras de construção da consulta exploratória: separação entre conceitos centrais e secundários, tradução para o inglês e limite de complexidade. A

mensagem leva o tema escolhido na Fase 1 (Listagem 4), e o código acrescenta ao *prompt* de sistema uma dica com os campos relevantes para a base consultada (Listagem 5).

Listagem 3: Trecho do *prompt* fixo da Fase 2 (`probe_system_prompt.txt`), com o exemplo JSON compactado

````
You are a specialist in technology foresight and in building structured search queries
 for patent and scholarly databases.

Your task is to receive a natural language description and return a JSON with search
fields for a RESTRICTED probe search.
[...]
## MANDATORY RULES

1. Translate all terms to English.
2. Apply light semantic expansion only.
3. Do not invent CPC/IPC codes.
4. Balance precision and recall.
5. Reason briefly first (see REASONING STEP below), then return the final answer as
valid JSON wrapped in a ```json code fence. Nothing may follow the closing fence.
[...]
## CONCEPT PRIORITY (CRITICAL)

Concepts must be divided into:

1. CORE CONCEPTS (MANDATORY)
   * Represent the main domain
   * 1 or 2 concepts [...]
   * All CORE concepts MUST be combined using AND

2. SECONDARY CONCEPTS (FLEXIBLE)
   * Context, methods, or applications
   * MUST NOT all be required simultaneously
   * Used to enrich recall, not restrict it
[...]
## QUERY COMPLEXITY CONSTRAINT (CRITICAL)

The generated query must NOT exceed a complexity score of 0.6 (on a 0-1 scale).
[...]
## OUTPUT EXAMPLE
[...]
```json
{
"TITLE": {
"group_operator": "AND",
"groups": [
{ "operator": "OR", "terms": ["predictive maintenance", "condition-based maintenance"]
 },
{ "operator": "OR", "terms": ["machine learning", "artificial intelligence"] }
]
},
"ABSTRACT": { [...] },
"IPC": [], "CPC": [], "APPLICANT": [], "INVENTOR": []
}
```
````

Listagem 4: Mensagem montada com os dados da sessão nas Fases 2 e 4

```
Theme: Autonomous UAV-based surveillance systems for border monitoring
Description: Unmanned aerial vehicles equipped with electro-optical and thermal
sensors for persistent detection and tracking of illegal crossings along land borders.
Area of Study: Engenharia
Keywords: UAV, sensoriamento
```

Listagem 5: Dica de campos acrescentada ao *prompt* de sistema para a base OPS

```
## RELEVANT FIELDS FOR THIS SEARCH

This search targets PATENT documents. Populate TITLE, ABSTRACT, and IPC (technology
classification) based on the theme. Leave other fields (CPC, APPLICANT, INVENTOR,
AUTHORS, KEYWORDS, etc) empty unless explicitly mentioned in the input.
```

Se a consulta gerada ultrapassa o limite da função de complexidade (Seção 3.5), ou contém termos fora do inglês, o sistema repete a chamada acrescentando ao *prompt* de sistema o sufixo da Listagem 6, com os valores medidos na tentativa anterior. É esse o mecanismo de autocorreção por métrica determinística.

Listagem 6: Sufixo de retentativa com as métricas da tentativa anterior

```
[CRITICAL RETRY #2] Previous query was TOO COMPLEX (score: 71.4/100, max: 60).
Complexity breakdown:
- OR operators: 9
- AND operators: 4
- Nesting depth: 3
- Total terms: 16

MUST simplify by:
- Use ONLY 1-2 most important concepts (reduce terms)
- Minimize OR operators within groups
- Remove nesting: avoid complex AND/OR combinations
- Use broader, more general search terms
- Maximum 2 groups per field, 2-3 terms per group
Keep it simple and focused!

[LANGUAGE ERROR] The previous query contained non-English terms: "vigilância de
fronteira". MANDATORY RULE 1 requires ALL terms to be in English - translate every
concept to its standard English technical term. Never copy a term directly from the
user's input if it is not already in English.
```

## A.5 Fase 3: Extração de termos

A Fase 3 não faz chamadas a LLM. Os termos candidatos são extraídos e pontuados pelo *pipeline* local de PLN descrito na Seção 4.3, e o resultado, depois da seleção feita pelo usuário, alimenta o *prompt* da Fase 4.

## A.6 Fase 4: Busca final

O *prompt* fixo da Fase 4 (Listagem 7) orienta a construção da consulta definitiva a partir dos termos extraídos, com regras distintas para cada variante (específica, equilibrada e genérica). A mensagem enviada é a mesma da Fase 2 (Listagem 4); os dados

novos desta fase entram como um bloco de contexto acrescentado ao *prompt* de sistema (Listagem 8): o tipo de documento, a variante, os termos extraídos acima do limiar da variante, com a pontuação normalizada e a frequência, e os códigos de classificação observados nas patentes da busca exploratória, únicos que o modelo pode usar. O sufixo de retentativa da Listagem 6 também se aplica a esta fase.

Listagem 7: Trecho do *prompt* fixo da Fase 4 (`final_system_prompt.md`)

```
You are a specialist in technology foresight and in building structured search queries
 for patent and scholarly databases.

Your task is to receive a search topic AND a curated list of extracted terms
discovered during a probe search, and return a JSON with search fields for a
COMPREHENSIVE FINAL SEARCH.

This search must maximize recall while maintaining precision. Prioritize extracted
terms over the original topic keywords - they were discovered from real documents and
carry higher domain specificity.

## MANDATORY RULES

1. Translate all terms to English.
2. Prioritize extracted terms over original keywords when building groups.
3. Do not invent CPC/IPC codes - if a "PROBE-DISCOVERED CLASSIFICATION CODES" list is
provided below, you may ONLY use codes from that list; if none is provided, leave IPC/
CPC empty.
[...]
## SEARCH VARIANT GUIDANCE

The search variant (SPECIFIC, BALANCED, or GENERIC) will be specified in the context
below.
[...]
## HOW TO USE EXTRACTED TERMS

Extracted terms are already semantically ranked. Use them to populate your groups:

1. Identify 2-4 main semantic concepts from the topic and the extracted terms
2. Create ONE group per concept
3. Fill each group with extracted terms that belong to that concept
4. Add synonyms or closely related expressions if they strengthen the group
5. DO NOT mix different concepts in the same group
6. DO NOT split multi-word technical expressions (e.g. "machine learning")
[...]
| Variant  | TITLE groups | ABSTRACT groups | Terms per group |
|----------|--------------|-----------------|-----------------|
| SPECIFIC | 2-3          | 3-4             | 3-4             |
| BALANCED | 2            | 2-3             | 4-6             |
| GENERIC  | 1-2          | 1-2             | 6-10            |
[...]
```

Listagem 8: Bloco de contexto da Fase 4 para a variante equilibrada na base OPS

```
## DOCUMENT TYPE

PATENT

## SEARCH VARIANT: BALANCED
```

```
Build a BALANCED query with good recall and precision. Use mid-range scoring extracted
 terms. Allow broader OR groups (4-6 terms). Limit AND combinations to 1-2.

## EXTRACTED TERMS (score > 0.3)

- unmanned aerial vehicle (score: 1.000, freq: 42)
- border surveillance (score: 0.866, freq: 27)
- aerial surveillance system (score: 0.711, freq: 21)
- drone detection (score: 0.599, freq: 18)
- object tracking (score: 0.415, freq: 15)

## PROBE-DISCOVERED CLASSIFICATION CODES

- B64C 39/02
- G06V 20/17
- H04N 7/18
- G08B 13/196
```

## A.7 Fase 5: Geração do relatório (exemplo completo)

Na Fase 5, cada seção redigida por IA resulta de uma chamada com o *prompt* de sistema fixo da Listagem 9, comum a todas as seções, e de um *prompt* específico da seção, montado pelo código com os dados da sessão. A Listagem 10 reproduz na íntegra o *prompt* montado para a subseção 6.3 do REPTEC, "Tendências e Ciclo de Vida da Tecnologia", a que mais concentra dados da sessão. A Tabela 11 indica a origem de cada bloco destacado.

Listagem 9: *Prompt* de sistema da redação do relatório (`REPORT_SYSTEM_PROMPT`), na íntegra

```
Você é um especialista em redação de relatórios de prospecção tecnológica no estilo
REPTEC/AGITEC do Exército Brasileiro.

REGRAS OBRIGATÓRIAS:
1. Português formal, técnico e IMPESSOAL ("observa-se", "recomenda-se" - nunca "
observamos", "recomendamos").
2. Use APENAS os fatos e documentos fornecidos no pedido. NÃO invente números, datas,
normas, regulamentos, mercados, empresas ou autores.
3. Citações: somente no formato (SOBRENOME et al., ano), exatamente como indicado em "
citar como" de cada documento. Documento marcado "não citar" não pode ser citado.
Nunca escreva "Fonte:", "N/A" ou percentuais de relevância/similaridade.
4. Nunca mencione o material de apoio ("contexto fornecido", "dados fornecidos", "
documentos recuperados"). Escreva como se o conhecimento fosse seu.
5. Se um dado não existir, simplesmente não trate daquele ponto - nunca escreva "[
Informação não disponível]" nem frases sobre ausência de dados.
6. Mantenha o foco no TEMA do relatório. Documentos sobre assuntos periféricos servem
só como exemplo pontual, nunca como assunto central.
7. Números em formato brasileiro: vírgula decimal (17,3%) e ponto de milhar (1.800).
8. Não inclua título/cabeçalho da seção (ex.: "## Seção") - comece direto pelo
primeiro parágrafo.
9. Parágrafos corridos, sem listas com marcadores e sem Markdown.
```

Listagem 10: *Prompt* montado para a subseção 6.3 do relatório, na íntegra

```
DOCUMENTOS DE APOIO (use só o que for pertinente ao tema):
```

```
## Documentos recuperados sobre o tema (Resultados - Tendências e Ciclo de Vida da
Tecnologia)

Documento 1 - citar como (SILVA et al., 2021)
Persistent border surveillance with fixed-wing UAVs and thermal cameras

This work presents a surveillance architecture based on fixed-wing unmanned aerial
vehicles carrying thermal imaging payloads for night-time detection of border
crossings.

Documento 2 - citar como (NGUYEN et al., 2023)
Multi-UAV path planning for wide-area border monitoring

A cooperative path planning method is proposed for fleets of drones covering long land
 borders, reducing revisit time by 34% in simulated scenarios.

Documento 3 - sem autoria identificada (não citar)
Aerial surveillance apparatus with automatic target tracking

An apparatus comprising an unmanned aircraft, a gimbal-mounted camera and an onboard
processing unit that tracks moving targets and transmits alerts to a ground station.


FIGURAS E QUADROS DESTA SEÇÃO (os números abaixo são os mesmos desenhados em cada
imagem):
- id: article_s_curve | Figura: Curva S relativa às informações científicas.
  Dados: 1.842 documentos acumulados entre 2005 e 2025; GP = 2014, MP = 2024, SP =
2033; saturação atual estimada em 61,3% do nível de saturação (3.004)
- id: patent_s_curve | Figura: Curva S relativa às informações tecnológicas.
  Dados: 967 documentos acumulados entre 2008 e 2025; GP = 2017, MP = 2026, SP = 2034;
 saturação atual estimada em 38,9% do nível de saturação (2.486)

COMO APRESENTAR CADA FIGURA/QUADRO (padrão do REPTEC - obrigatório para TODOS os itens
 da lista acima):
1. Um parágrafo que APRESENTA a figura e cita pelo marcador [[REF:id]], precedido da
palavra Figura ou Quadro. Ex.: "A Figura [[REF:article_s_curve]] mostra a distribuição
 das publicações científicas ao longo do tempo."
2. Na linha seguinte, sozinho, o marcador [[FIG:id]] - é onde a imagem entra.
3. Logo depois, um parágrafo que INTERPRETA os dados da figura: cite os números dela (
totais, pico e ano do pico, primeiros colocados e suas quantidades), descreva a tendê
ncia (crescimento, estabilização, queda) e o que isso indica sobre o tema.
Exemplo de estrutura:
"No total, foram identificadas 321 publicações científicas entre 1992 e 2022. A Figura
 [[REF:article_yearly_volume]] mostra a distribuição dessas publicações ao longo do
tempo.

[[FIG:article_yearly_volume]]

Entre 1993 e 2013, observa-se crescimento gradual, com o pico de 25 publicações em
2013; a partir de então, nota-se queda sustentada, chegando a 2 publicações em 2022, o
 que sugere redução do interesse acadêmico pela tecnologia."
Regras: use cada figura exatamente uma vez; nunca coloque duas figuras seguidas sem
texto entre elas; nunca termine a seção com figuras; não invente ids; todo número
sobre uma figura deve vir dos "Dados" dela.

ESTÁGIO DO CICLO DE VIDA (calculado a partir das curvas S - use exatamente estes está
gios e anos, sem reinterpretar):
- Publicações científicas (artigos): estágio de MATURIDADE (GP = 2014, MP = 2024, SP =
```

```
 2033).
- Depósitos de patentes: estágio de CRESCIMENTO (GP = 2017, MP = 2026, SP = 2034).
GP = ponto de crescimento (10% da saturação), MP = ponto médio (50%), SP = ponto de
saturação (90%).

Escreva a subseção 6.3 TENDÊNCIAS E CICLO DE VIDA DA TECNOLOGIA do relatório de
prospecção sobre: Autonomous UAV-based surveillance systems for border monitoring

No estilo do REPTEC, em 3 a 5 parágrafos: descreva a evolução das publicações e dos
depósitos ao longo do tempo; discuta SEPARADAMENTE a curva S dos artigos e a curva S
das patentes, informando o estágio de cada uma e os anos GP/MP/SP acima (ex.: "MP =
2011"); interprete o que isso indica sobre o interesse acadêmico e comercial pela
tecnologia.
```

Tabela 11: Origem dos dados da sessão no *prompt* da subseção 6.3

| **Bloco** | **Origem** |
|---|---|
| Documentos de apoio | Busca por similaridade no ChromaDB entre o tema mais a descrição da seção e o título e resumo dos documentos da busca final, com corte relativo de relevância (Seção 3.4). A citação "(SOBRENOME et al., ano)" é calculada a partir dos autores ou inventores; documentos sem autoria identificada são marcados para não serem citados. |
| Dados das figuras | Resumo numérico de cada gráfico, persistido na tabela `session_chart` no momento em que o gráfico é gerado. São os mesmos números desenhados na imagem. |
| Estágio do ciclo de vida | Ajuste das curvas S (Seção 2.2): o estágio resulta da comparação do último ano completo com os anos GP, MP e SP de cada curva. |
| Tema | Tema escolhido pelo usuário na Fase 1. |

O texto devolvido pelo modelo passa por verificações determinísticas: citações que não correspondem a nenhum documento recuperado são removidas, números são convertidos para o formato brasileiro e marcas proibidas, como menções ao material de apoio ou uso da primeira pessoa, são detectadas. Se alguma marca proibida for encontrada, a seção é regenerada uma vez com o acréscimo da Listagem 11, que lista os problemas identificados.

Listagem 11: Acréscimo ao *prompt* da seção na regeneração

```
ATENÇÃO: a versão anterior deste texto foi rejeitada pelos seguintes problemas:
- citação no formato "(Fonte: ...)"
- referência ao material de apoio ("contexto fornecido", "dados apresentados"...)
- primeira pessoa do plural (use a forma impessoal: "recomenda-se")
Reescreva o texto inteiro sem nenhum desses problemas, seguindo as regras obrigatórias
.
```

Por fim, na etapa de revisão, cada parágrafo gerado por IA pode ser enviado a um modelo revisor, com o *prompt* de sistema da Listagem 12 e a mensagem "Texto a revisar:"

seguida do parágrafo. As correções sugeridas são apresentadas ao usuário, que decide se as aplica.

Listagem 12: *Prompt* de sistema da revisão do texto (`AI_REVIEW_SYSTEM_PROMPT`), na íntegra

```
Você é revisor de língua portuguesa (norma culta do Brasil) de relatórios técnicos.
Corrija SOMENTE erros de: concordância verbal, concordância nominal (número e gênero),
 acentuação e ortografia.
NÃO reescreva estilo, NÃO troque palavras corretas por sinônimos, NÃO altere números,
siglas, nomes próprios, citações "(AUTOR, ano)" nem comandos LaTeX (\textit{...}, \ref
{...}, \%, \&).
Responda APENAS com JSON no formato:
{"correcoes": [{"original": "<trecho EXATO copiado do texto, curto, contendo o erro>",
 "corrigido": "<o mesmo trecho corrigido>", "motivo": "concordância verbal|concordâ
ncia nominal|acentuação|ortografia"}]}
Se não houver erros, responda {"correcoes": []}.
```

# APÊNDICE B – CASO DE ESTUDO (CATALISADOR DE PETRÓLEO)

## B.1 Configuração dos Modelos e Auditoria da Sessão

Para a execução do caso de estudo real sobre o tema "Catalisador de petróleo", realizado sob supervisão desta pesquisa, o sistema foi configurado distribuindo os modelos de linguagem conforme os requisitos operacionais de cada etapa. Os pontos de uso voltados à geração de temas, elaboração de consultas exploratórias, redação textual e revisão do relatório foram atribuídos ao modelo local `gemma4:12b` (do laboratório Minds do IME) servido via plataforma Ollama, enquanto a geração da consulta final foi vinculada à API remota `gemini-2.5-flash` (Google). A Figura 12 documenta a interface de vinculação dinâmica dos modelos.




Figura 12: Painel de configuração e vinculação de modelos de linguagem por ponto de uso.

Ao término do ciclo prospectivo completo, o módulo de auditoria registrou o consumo consolidado de 245.204 *tokens*, computados entre todas as requisições de inferência realizadas ao longo das cinco fases, conforme ilustrado no cabeçalho da sessão da interface (Figura 13).

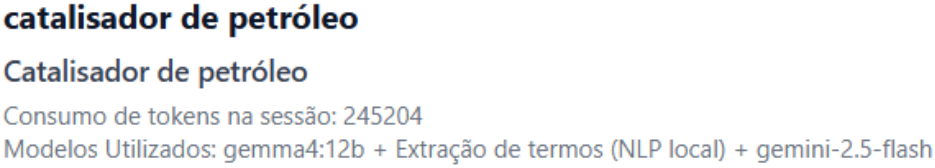



Figura 13: Registro de auditoria da sessão: tema pesquisado, consumo total de *tokens* e modelos alocados.

## B.2 Parâmetros de Entrada da Pesquisa (*Intake*)

A sessão foi iniciada submetendo-se unicamente o termo central no formulário inicial (*wizard*), mantendo-se os campos complementares (descrição, palavras-chave adicionais e área de estudo) vazios para testar a capacidade de expansão autônoma das ferramentas de PLN e IA (Figura 14).

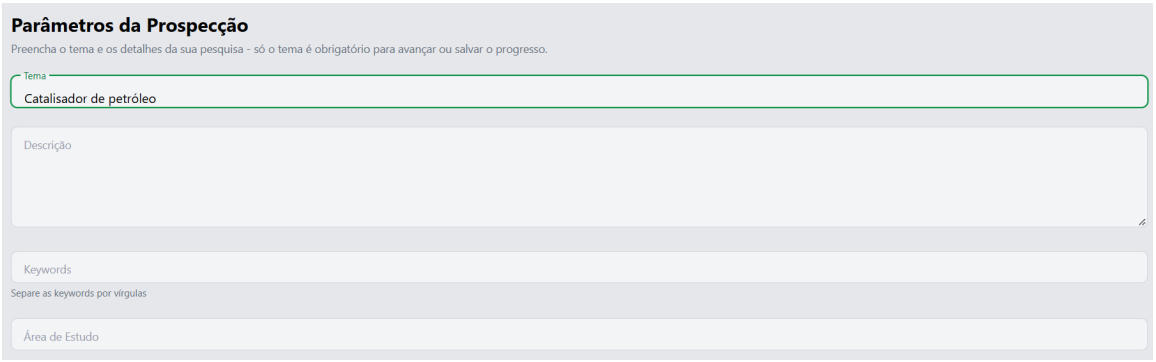



Figura 14: Formulário de parametrização inicial da prospecção preenchido na interface *web*.

## B.3 Busca Exploratória e Análise Estrutural de Complexidade

A partir do tema validado, o sistema sintetizou as consultas booleanas exploratórias (*probe queries*) para as bases OPS e Scopus. Cada consulta gerada foi submetida à função heurística de complexidade determinística (Seção 3.5) antes de seu envio às APIs externas:

- **OPS (Patentes) – Variante Exploratória 1:**

```
((((ti = "petroleum catalyst" OR ti = "hydrocarbon catalyst" OR ti = "refining
catalyst")) OR ((ab = "petroleum catalyst" OR ab = "hydrocarbon catalyst" OR ab = "
refining catalyst") AND (ab = "fluid catalytic cracking" OR ab = desulfurization OR
ab = hydrocracking)))) AND (pd within "20100101 20261231")
```

*Escore de Complexidade:* **54,1/100** (Nível: Complexo).

- **OPS (Patentes) – Variante Exploratória 2:**

```
((((ti = "petroleum catalyst" OR ti = "hydrocarbon catalyst" OR ti = "refining
catalyst")) OR ((ab = "petroleum catalyst" OR ab = "hydrocarbon catalyst" OR ab = "
refining catalyst") AND (ab = hydroprocessing OR ab = "cracking process" OR ab = "
catalytic cracking")))) AND (pd within "20100101 20261231")
```

*Escore de Complexidade:* **55,6/100** (Nível: Complexo).

- **Scopus (Artigos) – Variante Exploratória 1:**

```
(((TITLE(("petroleum catalyst" OR "hydrocarbon catalyst" OR "refining catalyst")))
OR (ABS(("petroleum catalyst" OR "hydrocarbon catalyst" OR "refining catalyst")) AND
 ABS(("hydrocracking" OR "catalytic cracking" OR "fluid catalytic cracking"))))) AND
 (PUBYEAR > 2009 AND PUBYEAR < 2027) AND (DOCTYPE(ar))
```

*Escore de Complexidade:* **57,6/100** (Nível: Complexo).

- **Scopus (Artigos) – Variante Exploratória 2:**

```
(((TITLE(("petroleum catalyst" OR "oil refining catalyst" OR "hydrocarbon cracking
catalyst"))) OR (ABS(("petroleum catalyst" OR "oil refining catalyst" OR "
hydrocarbon cracking catalyst")) AND ABS(("catalytic process" OR "refining system"
OR "cracking method"))))) AND (PUBYEAR > 2009 AND PUBYEAR < 2027) AND (DOCTYPE(ar))
```

*Escore de Complexidade:* **58,0/100** (Nível: Complexo).

A submissão exploratória recuperou uma amostra de 29 patentes (de um universo inicial indexado de 197), abrangendo 112 classificações CPC distintas em 2 jurisdições (2018–2026); para artigos, foram amostrados 15 documentos (de 61 indexados), cobrindo 10 países e 14 periódicos (2010–2026), conforme ilustra a Figura 15.




Figura 15: Painéis de resultados preliminares da busca exploratória para patentes (OPS) e artigos (Scopus).

As Figuras 16 e 17 exibem os registros documentais obtidos nessa triagem, servindo como corpus de entrada para o algoritmo de mineração terminológica.

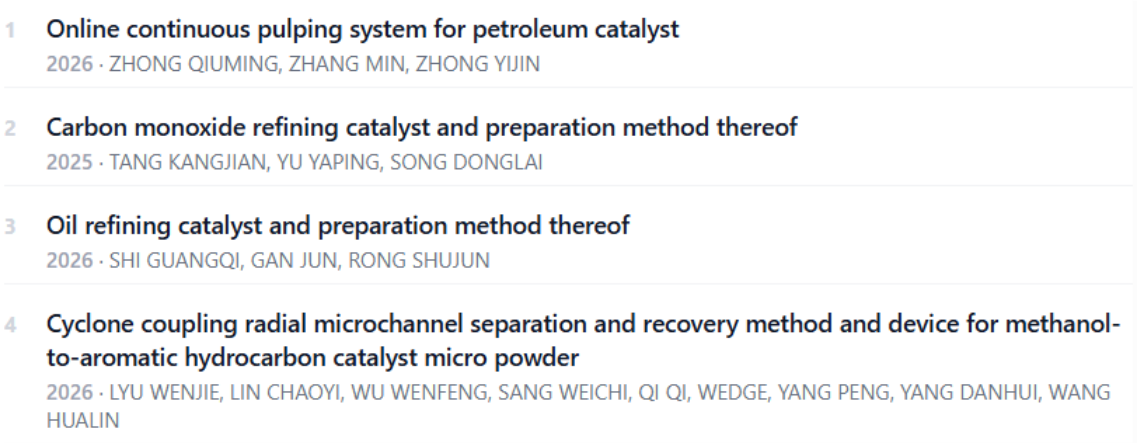



Figura 16: Amostra de documentos de patentes recuperados via API OPS na exploração inicial.

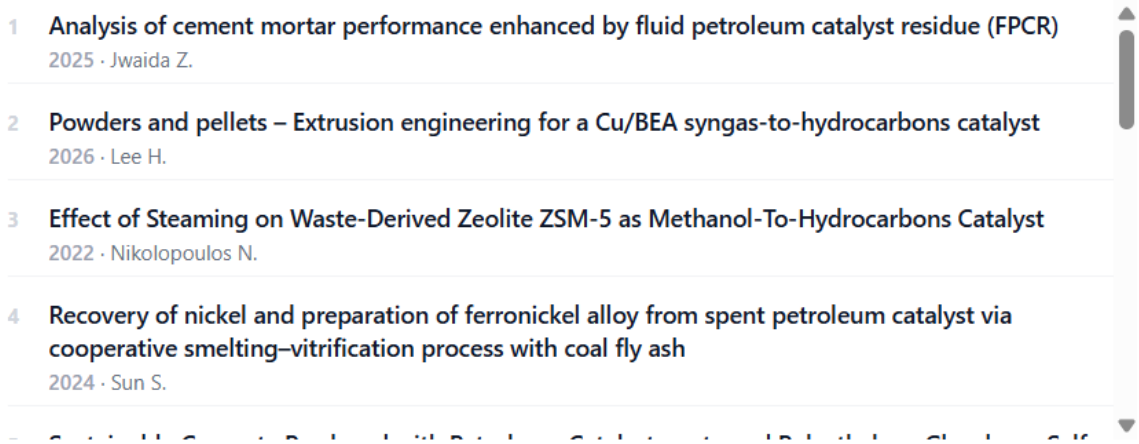



Figura 17: Amostra de publicações científicas recuperadas via API Scopus na exploração inicial.

## B.4 Extração e Pontuação de Termos por PLN Local

Aplicando-se a esteira determinística de PLN (PatternRank, BM25F, KeyBERT e RRF), os termos candidatos foram extraídos dos resumos e títulos da amostra sem o emprego de LLMs. A Tabela 12 apresenta as principais palavras-chave pontuadas e disponibilizadas para seleção na interface.

Tabela 12: Termos técnicos extraídos pelo pipeline de PLN local e respectivos escores RRF

| **Termo Minerado (Patentes)** | **Escore RRF** | **Termo Minerado (Artigos)** | **Esc** |
|---|---|---|---|
| *oil refining catalysts* | 0,0239 | *oil refining catalysts* | |
| *hydrocarbons catalyst* | 0,0239 | *hydrocarbons catalyst* | |
| *petroleum catalyst residue* | 0,0227 | *petroleum catalyst residue* | |
| *petroleum catalysts* | 0,0216 | *petroleum catalysts* | |
| *heterogeneous catalyst supports* | 0,0214 | *heterogeneous catalyst supports* | |
| *heavy petroleum feedstock* | 0,0209 | *heavy petroleum feedstock* | |
| *petroleum residue upgrading technologies* | 0,0209 | *petroleum residue upgrading technologies* | |
| *domestic metallic raw materials* | 0,0207 | *domestic metallic raw materials* | |
| *oil refining catalyst auxiliaries* | 0,0206 | *heterogeneous refining catalysts* | |
| *heterogeneous refining catalysts* | 0,0201 | *coal fly ash* | |
| *aromatic hydrocarbon refining catalyst* | 0,0201 | – | |
| *coal fly ash* | 0,0201 | – | |

## B.5 Busca Final e Projeção das Curvas S no *Frontend*

Apoiando-se nos termos aprovados, o modelo `gemini-2.5-flash` formulou as consultas definitivas sob o perfil de abrangência Amplo. A consulta final de patentes atingiu escore de complexidade de **60,6/100** (*Complexo*), enquanto a consulta científica alcançou **77,8/100** (*Muito Complexo*), operando no limiar máximo tolerado pelos adaptadores:

- **Consulta Final de Patentes (OPS):**

```
((((ti = "waste oil refining catalyst" OR ti = "petroleum refining catalyst" OR ti =
 "refining catalyst" OR ti = "catalyst additive" OR ti = "oil refining catalyst"))
OR ((ab = "waste oil refining catalyst" OR ab = "petroleum refining catalyst" OR ab
= "refining catalyst" OR ab = "aromatic hydrocarbon refining catalyst" OR ab = "
catalyst additive" OR ab = "oil refining catalyst" OR ab = "catalyst micro powder"))
)) AND (pd within "20100101 20261231")
```

- **Consulta Final de Artigos (Scopus):**

```
(((TITLE(("coal fly ash" OR "petroleum catalysts" OR "hydrocarbons catalyst" OR "
heterogeneous refining catalysts" OR "petroleum residue upgrading technologies" OR "
heavy petroleum feedstock" OR "petroleum catalyst residue" OR "oil refining
catalysts"))) OR (ABS(("coal fly ash" OR "petroleum catalysts" OR "hydrocarbons
catalyst" OR "heterogeneous refining catalysts" OR "heavy petroleum feedstock" OR "
petroleum residue upgrading technologies" OR "petroleum catalyst residue" OR "
domestic metallic raw materials" OR "heterogeneous catalyst supports" OR "oil
refining catalysts"))))) AND (PUBYEAR > 2009 AND PUBYEAR < 2027) AND (DOCTYPE(ar))
```

A submissão definitiva recuperou 399 patentes (318 depositantes e 96 classificações CPC) e 3.543 publicações científicas (amostra analisada de 425 artigos, distribuídos entre 294 instituições e 27 áreas de estudo). A Figura 18 documenta as curvas S geradas e parametrizadas na interface, exibindo as projeções de 5 anos para patentes (saturação em SP = 2023) e 15 anos para artigos (projeção assintótica com saturação estimada em SP = 2030).

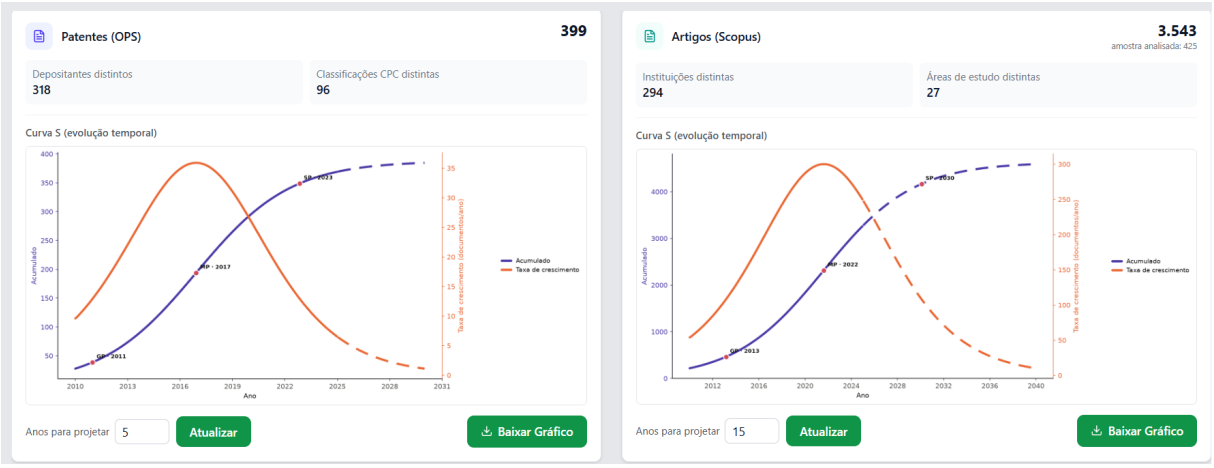



Figura 18: Painel da busca final na interface *web* exibindo as métricas consolidadas e as curvas S para patentes (OPS) e artigos (Scopus).

## B.6 Relatório Técnico Final Consolidado (REPTEC 001/2026)

A seguir, apresenta-se na íntegra o Relatório de Prospecção Tecnológica gerado automaticamente pelo sistema a partir dos dados coletados e redigido via RAG local com o modelo `gemma4:12b`, compilado no formato padrão da AGITEC.

# RELATÓRIO DE PROSPECÇÃO TECNOLÓGICA

## 001/2026 – AGITEC

## CATALISADOR DE PETRÓLEO

**Sumário**

1 FINALIDADE . . . . . 3

2 REFERÊNCIAS . . . . . 3

3 OBJETIVO . . . . . 3

4 INTRODUÇÃO . . . . . 3

5 METODOLOGIA . . . . . 3

6 RESULTADOS . . . . . 11

7 CONCLUSÃO . . . . . 18

8 REFERÊNCIAS BIBLIOGRÁFICAS . . . . . 18

## 1 FINALIDADE

Apresentar o relatório de Prospecção Tecnológica sobre Catalisador de petróleo a fim de fornecer informações de tendências e ciclo de vida da tecnologia para AGITEC.

## 2 REFERÊNCIAS

- DIEx Nº 001/TESTE, de 25 de setembro de 2026

## 3 OBJETIVO

O presente trabalho consiste em realizar um estudo de prospecção tecnológica sobre catalisador de petróleo.

## 4 INTRODUÇÃO

A tecnologia de catalisadores de petróleo envolve a utilização de substâncias químicas para acelerar reações essenciais em processos de refino, como a pré-hidrogenação e o refinamento por hidrogenação. Estes componentes são fundamentais na produção de diesel, nafta e bases lubrificantes a partir do processamento de óleo sintético ou matérias-primas brutas (AI et al., 2019). Através da aplicação desses catalisadores em reações de hidroisomerização, é possível alcançar uma fracionação mais eficiente e direcionada dos produtos petroquímicos.

A relevância desta tecnologia decorre da necessidade de otimizar a qualidade dos lubrificantes e combustíveis produzidos por meio de métodos simplificados. O uso de catalisadores com alta seletividade permite que o processo de produção obtenha simultaneamente diversos produtos, como óleo combustível de alta qualidade e bases lubrificantes de variadas viscosidades (WANG et al., 2020). A eficácia desses agentes é um fator determinante para a especificação técnica dos derivados do petróleo.

O estado atual da tecnologia abrange tanto processos químicos quanto métodos físicos de preparação dos catalisadores de refino. Destacam-se técnicas que utilizam sistemas de moagem primária e secundária para processar as matérias-primas do catalisador, garantindo propriedades adequadas ao seu funcionamento (THE, 2019). Adicionalmente, a aplicação desses materiais em zonas de refinação suplementar possibilita o fracionamento de produtos por meio de torres atmosféricas ou de vácuo (WANG et al., 2020).

Este relatório busca fornecer uma análise técnica detalhada sobre os catalisadores no setor petrolífero, com foco em suas propriedades e métodos de preparação. A investigação visa subsidiar a compreensão dos avanços tecnológicos que possibilitam o aumento da produtividade e do refino de componentes críticos para a indústria petroquímica.

## 5 METODOLOGIA

Os estudos de prospecção tecnológica, também chamados de estudos de futuro, ou *forecast(ing)*, *foresight(ing)* ou *future studies*, fornecem as principais tendências no contexto mundial, sendo possível segmentar estas tecnologias por setor da economia. Estes estudos auxiliam a

identificação de tecnologias promissoras, úteis para determinada organização, bem como apontam para possibilidades de negócios e parcerias. A sistematização da prática de monitoramento tecnológico, a ser coberta pela prospecção tecnológica e de inovação, visa congregar a busca de soluções adequadas para a identificação e priorização de uma agenda de P&D, articulada com instituições de pesquisa, que possa inclusive influenciar a agenda de P&D nacional e criar demandas para a cadeia inovativa do setor (BORSCHIVER; LEMOS, 2016).

Estudos de Prospecção Tecnológica são elementos essenciais de informações que se propõem a auxiliar processos decisórios de organizações complexas e de capilaridade como o Exército Brasileiro, face aos desafios impostos pelo cenário de instabilidades internacional e nacional e seus reflexos para as expressões do poder nacional. O desenvolvimento de estudos dessa natureza mormente contempla informações técnicas e quantitativas, em que são empregadas ferramentas bibliométricas, e as informações qualitativas, nas quais a participação de especialistas é fundamental para coletar, reunir e codificar (registrar) o conhecimento tácito que integra o capital humano da organização, muitas vezes, pulverizado por integrantes nas mais diversas OM do país.

Entre os óbices da fase inicial dos estudos de prospecção elaborados pelo EB, pode-se citar a dificuldade de identificar profissionais ou OM mais apropriados a contribuírem com o tema. Esse esforço inicial é superado com a participação de pesquisadores que compõem o *networking* dos analistas de prospecção. Esses profissionais das Instituições Científico-Tecnológicas (ICT) militares auxiliam a otimizar o estudo preliminar aclarando aspectos que podem ser explorados, evitando o envolvimento prematuro de um amplo rol de profissionais. Superada essa etapa inicial, segue-se uma pesquisa externa à AGITEC, em que são coletadas informações de especialistas de profissionais dedicados ao tema, ainda que dispersos por inúmeras OM do Brasil, o que se mostra promissor, em razão de integrar conhecimentos de especialistas ou técnicos versados no assunto com o rol de ferramentas e capacidades de analistas de prospecção tecnológica.

O recrutamento assertivo do capital humano para os temas propostos é essencial para o estudo prospectivo, pois colabora na identificação dos desafios institucionais impostos pelo tema e a complexidade tecnológica envolvida, permitindo criar um canal de acesso direto e fluência de competências técnicas de que o Exército dispõe, no entanto, face à sua distribuição pelo continente nacional, não é trivial reunir e considerar as visões complementares entre especialistas de Órgãos de Direção Setorial e Operacional, e de analistas de prospecção tecnológica.

O Método de Prospecção Tecnológica busca explorar o conhecimento explícito, acessado a partir de registros e repositórios diversos como fontes de notícias, informações científicas e informações tecnológicas; e o conhecimento tácito, por meio da contribuição dos especialistas integrantes do Exército.

Pretende-se revelar o estado atual referente ao ciclo de vida da tecnologia. Para isso, por intermédio da bibliometria de patentes, da literatura científica (artigos, capítulos de livros, anais de congressos etc.) e de fontes ostensivas de informações atuais, buscam-se evidências que colaborem com a área em questão. Para tanto, são empregadas bases de dados de patentes e de

literatura científica, além de refinamentos sucessivos de modo a produzir novos conhecimentos acerca do tema alvo.

Estudos bibliométricos a partir de artigos, patentes e fontes ostensivas têm sido cada vez mais empregados como técnicas de monitoramento de capacidades tecnológicas em Setores do Governo, Indústria e Academia. Entende-se que os artigos científicos são ativos que denotam o conhecimento técnico que resulta do esforço de Instituições Científico-Tecnológicas (ICT) e também de Empresas de Base Tecnológica (EBT). Deste modo, serão analisadas informações bibliométricas sobre Catalisador de petróleo com o propósito de aclarar o cenário tecnológico, no mundo e no Brasil, e verificar o estado atual da tecnologia em relação ao seu ciclo de vida.

Cabe ressaltar a necessidade de estabelecer estratégias de buscas adequadas e assertivas que permitam explorar o tema com a abrangência e profundidade requeridas. O uso de palavras-chave inicialmente válidas pode indexar conteúdo não pretendido pelo pesquisador, ou ainda, termos técnicos devidamente justificados podem apresentar mais de uma semântica e se aplicar a mais de uma área do conhecimento, fora do escopo a ser investigado. Desse modo, a interação é fundamental para reduzir o ruído no retorno das informações impróprias, ou seja, resultados que prejudiquem a coleta de dados e sua posterior análise. Ao modelar as estratégias de busca é possível acessar o conjunto de documentos mais assertivos como ostensivos, artigos científicos e patentes, de modo a produzir elementos essenciais de informação sobre o tema.

Como principal consequência do método, pode-se listar a elaboração mais consistente do Estado da arte, da escolha do repositório de artigos científicos, de patentes, de fontes de notícias, além da melhor estruturação de taxonomias e as curvas de extrapolação que auxiliam a visualizar perspectivas da evolução tecnológica futura. Nas Seções a seguir, serão detalhadas as etapas percorridas na execução do presente estudo prospectivo.

## 5.1 Informações Científicas

A informação científica é o conhecimento que constituiu, em certo momento da evolução da ciência, um acréscimo ao entendimento universal então existente sobre algum fato ou fenômeno, tendo-se tornado disponível como resultado de uma pesquisa científica, ou seja, de um trabalho de investigação conduzido segundo o método científico (BORSCHIVER; LEMOS, 2016).

O elemento primordial para o desempenho da atividade científica reside na informação que se encontra codificada de maneira verbal, manifesta em fontes como periódicos científicos e registros de conferências acadêmicas. Por conseguinte, o produto fundamental gerado por essa atividade, ou seja, o artigo científico veiculado em uma revista especializada, também assume esse viés. Tal produto desempenha um papel fundamental como matéria-prima para investigações científicas subsequentes, formando, dessa forma, um ciclo contínuo (BORSCHIVER; LEMOS, 2016).

O Perfil Científico reflete a visão da academia sobre o assunto, envolvendo resultados preponderantemente de pesquisa básica e aplicada. Neste caso, geralmente, nos níveis iniciais de uma escala de maturidade tecnológica (FRANÇA JR.; GALDINO, 2019). Ainda, permite

analisar informações contidas nas publicações científicas, como: produção de instituições e a produtividade de autores em função do tempo; autores mais relevantes; coautorias; instituições com desenvolvimento destacado; colaborações existentes entre instituições e países; fontes de financiamento; entre outros indicadores ou sinais que contemplem informações passadas, mas possibilitem amparar, elucidar e constituir visão futura.

Em amplo senso, entende-se que no início do ciclo de geração de uma nova tecnologia, o artigo científico é uma das primeiras expressões de codificação do conhecimento, período que usualmente reflete a baixa maturidade da tecnologia analisada. Ademais, a publicação de artigos acompanha grande parte do ciclo de vida de tecnologias em seus diferentes estágios de maturidade tecnológica, o que permite estabelecer interessantes associações e extrapolações, restritas às áreas que dependem de pesquisa básica e aplicada (LINDEN; BARBOSA; DIGIAMPIETRI, 2017; ERNST, 1997; NIETO; LÓPEZ; CRUZ, 1998).

### 5.2 Informações Tecnológicas

As patentes apresentam-se como excelentes indicadores de inovação, na medida em que servem para mensurar o resultado de P&D, a produtividade, a estrutura e o desenvolvimento de uma tecnologia/indústria específica (BORSCHIVER; LEMOS, 2016).

A busca em repositório estruturado que proporcione o acesso a informações de patentes, sobre a qual recai a expectativa de maior potencial para converter a pesquisa em produto, ou ainda, se constitui em forte indício de aplicação comercial, é uma estratégia essencial para direcionar a inovação e maximizar as oportunidades de desenvolvimento de novos produtos e tecnologias. Através desse tipo de busca em um repositório estruturado de patentes, é possível identificar padrões, tendências e *gaps* no mercado, permitindo uma análise mais precisa das oportunidades e ameaças presentes no cenário tecnológico. Com base nessa abordagem, é possível tomar decisões assertivas sobre investimentos em P&D, parcerias estratégicas e ações de propriedade intelectual, visando tanto o crescimento operacional quanto a consolidação de uma posição estratégica.

Integram essa fonte as patentes indexadas em bases de abrangência internacional, que espelham jurisdições da maior parte dos países. O Perfil Tecnológico permite analisar informações contidas em portfólio de empresas e áreas de atuação de *startups*, recursos voltados para P&D e depósitos de patentes (fontes mais vocacionadas à geração de inovação), tais como produção e interesse pela tecnologia, depositantes, possíveis parcerias, tecnologias associadas entre outros. Há robusto pressuposto de que o aumento do interesse por novas tecnologias reflete-se no aumento da atividade de P&D que, por sua vez, acarreta o aumento de depósito de patentes (DAIM; RUEDA; MARTIN, 2005; PORTER, 2005). Pode-se inferir também que as tecnologias que figuram neste repositório, em amplo senso, já atingiram um nível de maturidade tecnológica mais elevado, portanto, mais propensas, na iminência, ou mesmo já se encontram em uso ou em operação no mercado (ANDRADE; MOURA; BORSCHIVER, 2018; LEZAMA-NICOLÁS et al., 2018).

### 5.3 Análise de Tendências e o Ciclo de Vida (CVT) de uma Tecnologia

A análise de tendências se baseia no pressuposto de que os comportamentos do passado serão mantidos no futuro. Esta análise utiliza técnicas matemáticas e estatísticas para extrapolar séries temporais para o futuro (BORSCHIVER; LEMOS, 2016).

A extrapolação por meio de regressão logística abarca métodos de previsão a partir de robustas ferramentas matemáticas e estatísticas, como Loglet[1] e Sigmaplot[2]. Permitem, ainda, acompanhar, em grande medida a evolução científico-tecnológica, e gerar curvas S, para avaliar o desempenho de tecnologias, prever mudanças populacionais, analisar a penetração de mercado, elaborar estudos micro e macroeconômicos, verificar mecanismos de difusão de invenções tecnológicas e sociais, processos de modelagem ecológica, entre outros fins, o que fora confirmado por outros autores (KUCHARAVY; DE GUIO, 2011; LEZAMA-NICOLÁS et al., 2018; NIETO; LÓPEZ; CRUZ, 1998).

Ernst foi um dos precursores em evidenciar a relação entre o desenvolvimento de pedidos de patentes ao longo do tempo e o processo de difusão tecnológica, empregando para tanto, um controle numérico computadorizado (CNC) (ERNST, 1997, p. 363). O autor descreve os quatro estágios do ciclo de vida da tecnologia que abarcam o seu desenvolvimento:

a. **estágio emergente**: caracterizado por um crescimento relativamente baixo do desempenho tecnológico em comparação com a quantidade de esforços de P&D;

b. **estágio de crescimento**: no qual o progresso tecnológico marginal sobre os gastos cumulativos de P&D é positivo;

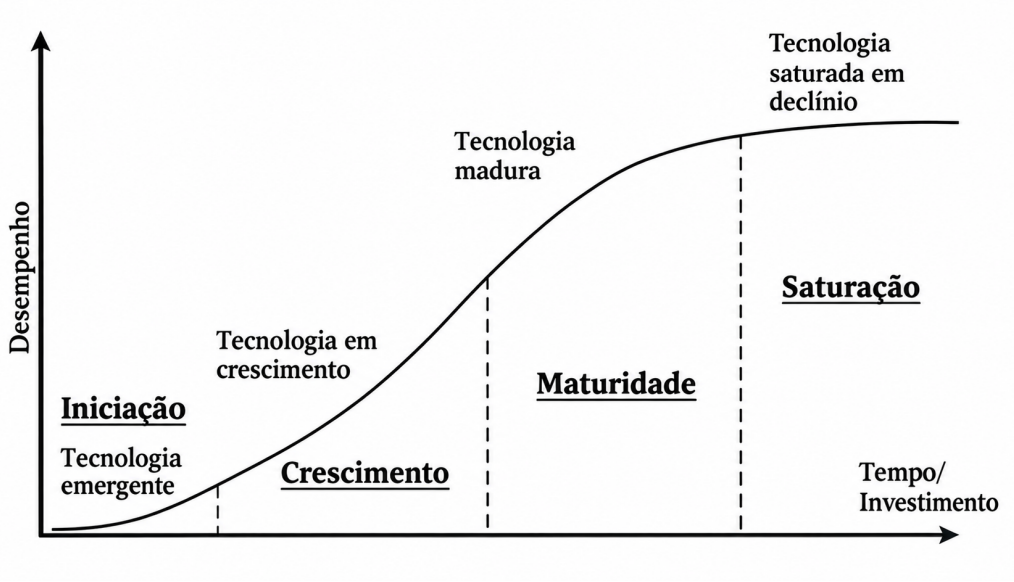
c. **estágio de maturidade**: onde a relação anterior torna-se negativa; e o

d. **estágio de saturação**: no qual pequenas melhorias de desempenho tecnológico são obtidas por meio de esforços de P&D muito elevados.

A Figura 1 apresenta os quatro estágios do ciclo de vida de uma tecnologia.

[1]Disponível em `https://logletlab.com/loglet/documentation/index`.
[2]Disponível em `https://osbsoftware.com.br/produto/sigmaplot/`.

Figura 1: Estágios do ciclo de vida de uma tecnologia.



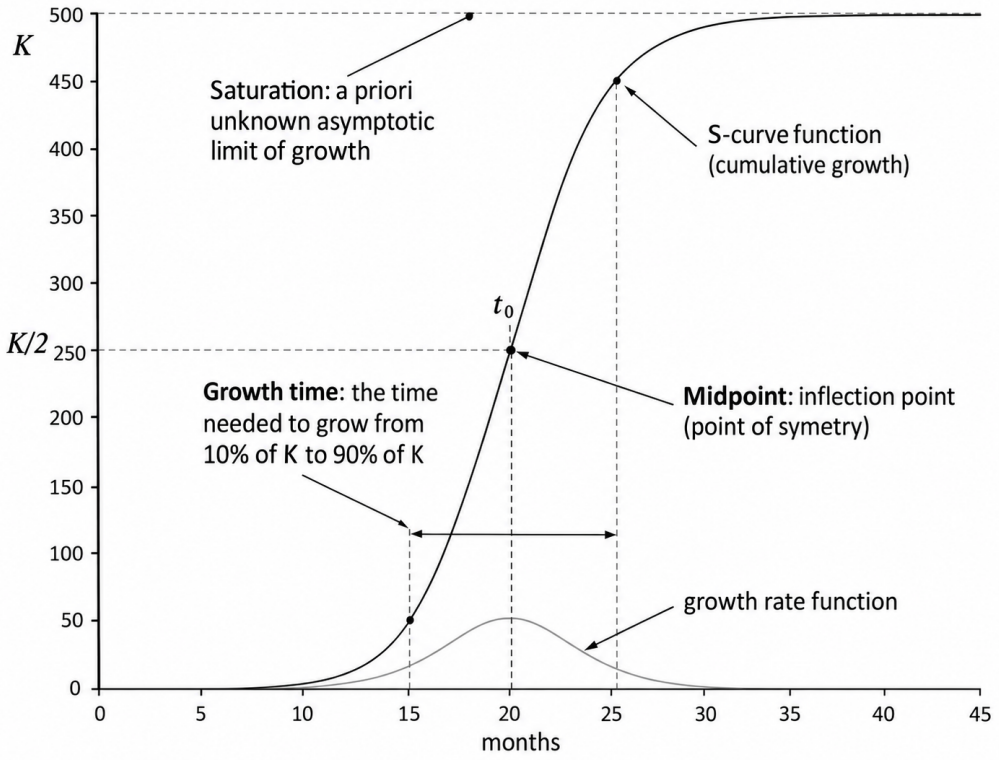

Fonte: MADEO, 2019, p. 37. Adaptado de Ernst (1997).

Em síntese, o desempenho da tecnologia é diretamente proporcional ao tempo de investimento, e a difusão do conhecimento codificado afeto a um tema repercute nos indicadores bibliométricos. Na fase embrionária, percebem-se poucas publicações de artigos e patentes, normalmente espaçadas ao longo do tempo. Na fase de crescimento, o aumento de interesse da comunidade científico-tecnológica no tema provoca uma rápida evolução numérica de registros, caracterizada por uma curva ascendente do gráfico, que corresponde, normalmente, ao aumento de produtividade do setor acadêmico, ou ainda de expectativas comerciais de setores competitivos que ambicionam proteger nichos por intermédio de patentes, ou seja, há proeminência ou protagonismo do setor privado no desenvolvimento da área tecnológica analisada.

Na fase de maturidade a produção anual científica ou dos depósitos de patentes apresentam sinais de arrefecimento e passam a ocorrer em menor intensidade, sinalizando que as evoluções técnicas se tornam mais espaçadas. Finalmente, o ciclo tecnológico atinge sua fase de saturação: a inflexão da curva à direita prenuncia um platô, em que os novos depósitos estabilizam, sofrem pequenas oscilações ou mesmo decaem.

Essa fase, contudo, pode ser sucedida por um novo ciclo de inovações incrementais, o que possibilitará alongar a vida útil da aludida tecnologia, ensejando novo avanço da Curva S, ou ainda, perder competitividade para uma tecnologia emergente, que pode superar a tecnologia dominante, substituí-la e ensejar a mobilização científico-tecnológica. Como resultado final, a tecnologia em saturação sinaliza o desinteresse comercial ou que a tecnologia segue para a obsolescência, o que pode ser caracterizado por declínio abrupto de publicações, prenúncio ou evidência de sua descontinuidade.

Figura 2: Diagrama esquemático de uma curva logística incluindo seus estágios do ciclo de vida e os parâmetros relacionados.




Fonte: KUCHARAVY; DE GUIO, 2011, p. 3.

Como apresentado brevemente, o ciclo de vida da tecnologia pode ser monitorado, e suas perspectivas de desenvolvimento futuro podem ser visualizadas por métodos matemáticos de extrapolação, proporcionando análises que compreendem a antevisão de comportamentos na produção científica e patentária de determinado tipo de tecnologia e a comparação entre tecnologias concorrentes.

O conjunto de dados entabulado, acumulado até 2026 (a partir de 2010) para patentes e artigos, obtido das bases de dados Espacenet (EPO/OPS) e Scopus, se constitui nos dados de entrada para o cálculo das Curvas S correspondentes à tecnologia alvo deste estudo. Para este estudo foi utilizado o modelo logístico, cuja taxa relativa de crescimento decresce linearmente com o tempo.

### 5.4 Apoio Computacional e Processamento de Linguagem Natural na Redação

A elaboração e redação analítica deste relatório foram executadas com o apoio de ferramentas computacionais avançadas baseadas em Inteligência Artificial (IA) e Processamento de Linguagem Natural (PLN). Essas técnicas atuaram de forma integrada desde a mineração e refinamento de termos técnicos até a síntese textual dos dados bibliométricos, garantindo rigor factual e redução de vieses. O fluxo metodológico adotado envolveu os seguintes pilares conceituais:

a. **Modelos de Linguagem de Grande Porte (*Large Language Models* – LLM):** Redes neurais profundas fundamentadas na arquitetura *Transformer* (VASWANI et al., 2017), treinadas sobre vastos corpus textuais para inferir relações semânticas e sintáticas complexas (BROWN et al., 2020; ZHAO et al., 2023). Neste trabalho, os LLMs foram empregados de maneira restrita e supervisionada para: (i) estruturar as primeiras consultas booleanas de busca; (ii) filtrar dados brutos retornados pelas bases; e (iii) apoiar a redação preliminar das seções analíticas a partir de um arranjo de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* – RAG) (LEWIS et al., 2020; GAO et al., 2024), no qual o modelo sintetiza estritamente os fatos contidos nos documentos locais recuperados, mitigando o risco de alucinações factuais (JI et al., 2023).

b. **Engenharia de Instruções (*Prompt Engineering*):** Conjunto sistemático de princípios para formular comandos e contextos que maximizam a acurácia e a objetividade das respostas geradas pelo LLM (WHITE et al., 2023). Na condução deste relatório, foram estabelecidas diretrizes estritas: atribuição de papel profissional (*persona* de analista de prospecção e patentes); decomposição do raciocínio analítico em etapas encadeadas (*Chain-of-Thought*) (WEI et al., 2022); delimitação de escopo através de exemplos guiados (*Few-Shot Prompting*) (BROWN et al., 2020); e estipulação de formatos de saída estruturada em esquemas controlados de dados, assegurando que o texto final mantivesse conformidade com a terminologia técnica da indústria petroquímica.

c. **BM25F (*Best Matching 25 with Fields*):** Algoritmo determinístico de recuperação de informação baseado em frequência lexical e pesos estatísticos ponderados por campos de documentos estruturados (como título, resumo e reivindicações) (ROBERTSON; ZARAGOZA; TAYLOR, 2004). O BM25F avalia a relevância direta e a raridade estatística dos termos ao longo da base, impedindo que termos frequentes porém pouco específicos dominem a seleção e garantindo a identificação precisa de palavras-chave exatas relacionadas a catalisadores de refino.

d. **KeyBERT:** Método de extração não supervisionada de palavras-chave baseado em aprendizado profundo que opera por meio de representações vetoriais densas de sentenças (*embeddings*) geradas por arquiteturas BERT (GROOTENDORST, 2020; REIMERS; GUREVYCH, 2019). Ao contrário de métodos puramente baseados em contagem de ocorrências, o KeyBERT mede a similaridade de cosseno entre o vetor do documento inteiro e os vetores de frases candidatas, identificando expressões conceituais e sinônimos que compartilham afinidade temática profunda com o tema, mesmo sem a exata repetição formal de palavras.

e. **Fusão Recíproca de Postos (*Reciprocal Rank Fusion* – RRF):** Técnica algorítmica de combinação de rankings com base na posição relativa de itens provenientes de diferentes sistemas de busca, sem a necessidade de normalização prévia de escores numéricos absolu-

tos (CORMACK; CLARKE; BUETTCHER, 2009). Empregou-se o RRF para harmonizar o ordenamento lexical gerado pelo BM25F com o ordenamento contextual-semântico fornecido pelo KeyBERT. Esse cruzamento resultou em uma taxonomia robusta e balanceada de termos tecnológicos, que alimentou as equações finais de busca bibliométrica e serviu de base temática para orientar os prompts de redação do presente documento.

Todo o material sintetizado via LLM passou por verificação paramétrica automatizada (como saturação de riqueza Chao1 e estabilidade de rankings via *bootstrap*) e pela validação final, revisão textual e controle técnico do analista humano responsável.

## 6 RESULTADOS

As estratégias de busca utilizadas para identificar a produção científica e tecnológica sobre o tema podem ser vistas no Quadro 1.

Quadro 1: Estratégias de busca.

| **Depósito de Patentes** | **Publicações Científicas** |
|---|---|
| Patentes (399) = ((((ti = "waste oil refining catalyst"OR ti = "petroleum refining catalyst"OR ti = "refining catalyst"OR ti = "catalyst additive"OR ti = "oil refining catalyst")) OR ((ab = "waste oil refining catalyst"OR ab = "petroleum refining catalyst"OR ab = "refining catalyst"OR ab = "aromatic hydrocarbon refining catalyst"OR ab = "catalyst additive"OR ab = "oil refining catalyst"OR ab = "catalyst micro powder")))) AND (pd within "20100101 20261231") | Artigos (3.543) = (((TITLE(("coal fly ash"OR "petroleum catalysts"OR "hydrocarbons catalyst"OR "heterogeneous refining catalysts"OR "petroleum residue upgrading technologies"OR "heavy petroleum feedstock"OR "petroleum catalyst residue"OR "oil refining catalysts"))) OR (ABS(("coal fly ash"OR "petroleum catalysts"OR "hydrocarbons catalyst"OR "heterogeneous refining catalysts"OR "heavy petroleum feedstock"OR "petroleum residue upgrading technologies"OR "petroleum catalyst residue"OR "domestic metallic raw materials"OR "heterogeneous catalyst supports"OR "oil refining catalysts"))))) AND (PUBYEAR > 2009 AND PUBYEAR < 2027) AND (DOCTYPE(ar)) |

Fonte: O autor.

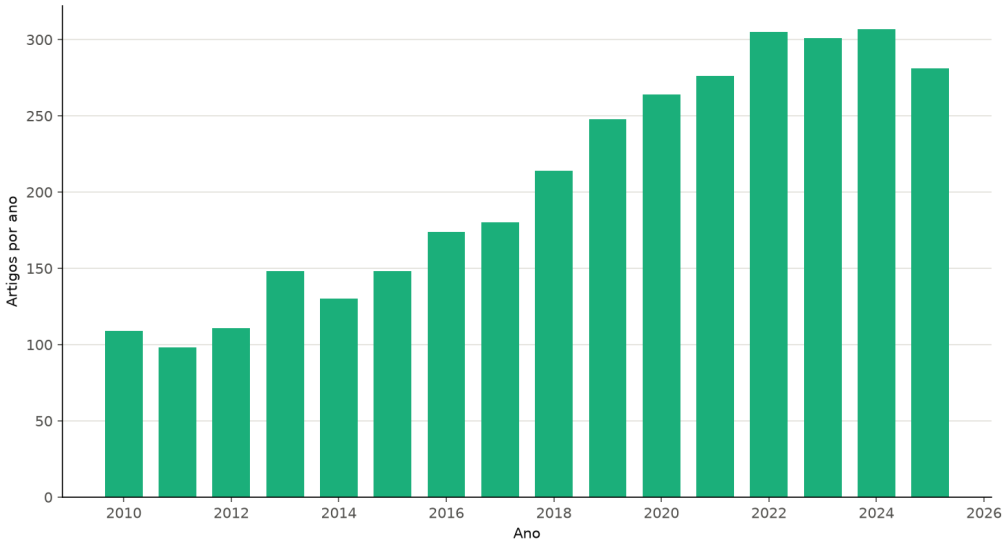
### 6.1 Informações Científicas

Identificou-se um total de 3.543 publicações científicas relacionadas ao tema catalisador de petróleo no período analisado. A produção científica abrange o desenvolvimento de fórmulas e métodos para a fabricação de pelotas de catalisadores (LUO, 2020), sistemas inteligentes voltados

à fabricação de agentes auxiliares (LI, 2022) e dispositivos inovadores para a preparação desses materiais (YOU, 2022). Adicionalmente, investigam-se misturas de peneiras moleculares com metais preciosos, como platina e paládio (XIA et al., 2019), bem como processos em reatores de pós-refino voltados à obtenção de óleos brancos com especificações técnicas rigorosas (AI et al., 2024).

A Figura 3 mostra a distribuição das publicações científicas ao longo do tempo.

Figura 3: Histórico de publicações científicas (artigos por ano).

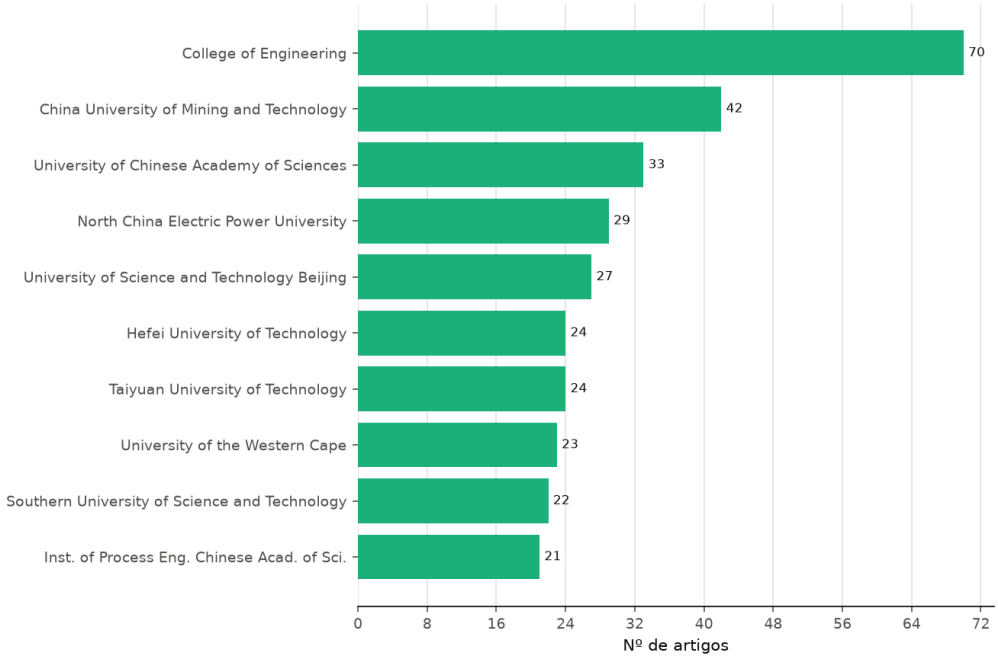



Fonte: O autor.

No total, foram identificadas 3.294 publicações científicas entre os anos de 2010 e 2025. Observa-se um crescimento na produção científica com o pico atingido em 2024, com 307 publicações no respectivo ano, seguidas por 281 publicações em 2025, o que indica uma manutenção do interesse acadêmico pelo tema nos anos recentes.

A Figura 4 apresenta as principais instituições responsáveis pela produção científica na área.

Figura 4: Top 10 maiores instituições em quantidade de publicações científicas.

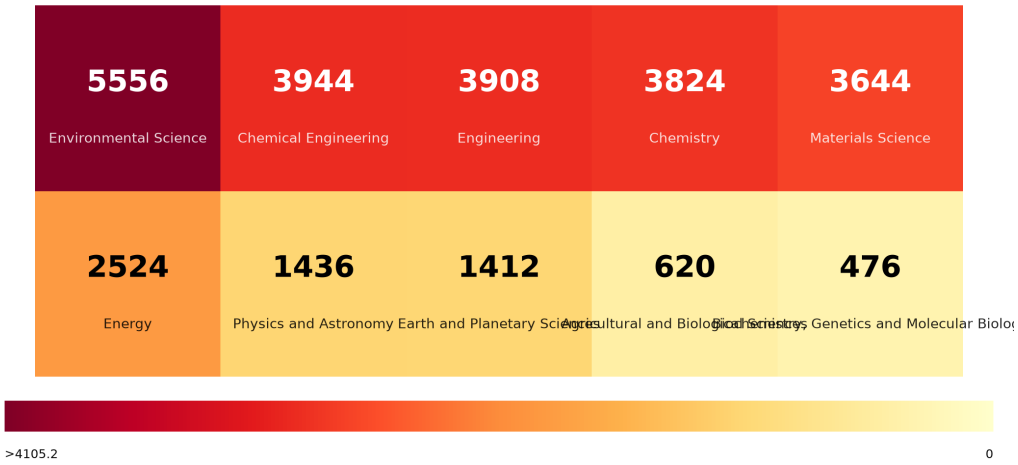



Fonte: O autor.

O ranking das instituições é liderado pela College of Engineering, com 70 publicações, seguida pela China University of Mining and Technology (42), University of Chinese Academy of Sciences (33), North China Electric Power University (29) e University of Science and Technology Beijing (27). Completam a lista de destaque a Hefei University of Technology (24), Taiyuan University of Technology (24), University of the Western Cape (23), Southern University of Science and Technology (22) e Institute of Process Engineering Chinese Academy of Sciences (21).

O Quadro 2 detalha as áreas de estudo relacionadas às pesquisas científicas sobre o tema.

Quadro 2: Áreas de estudo relacionadas às pesquisas científicas.



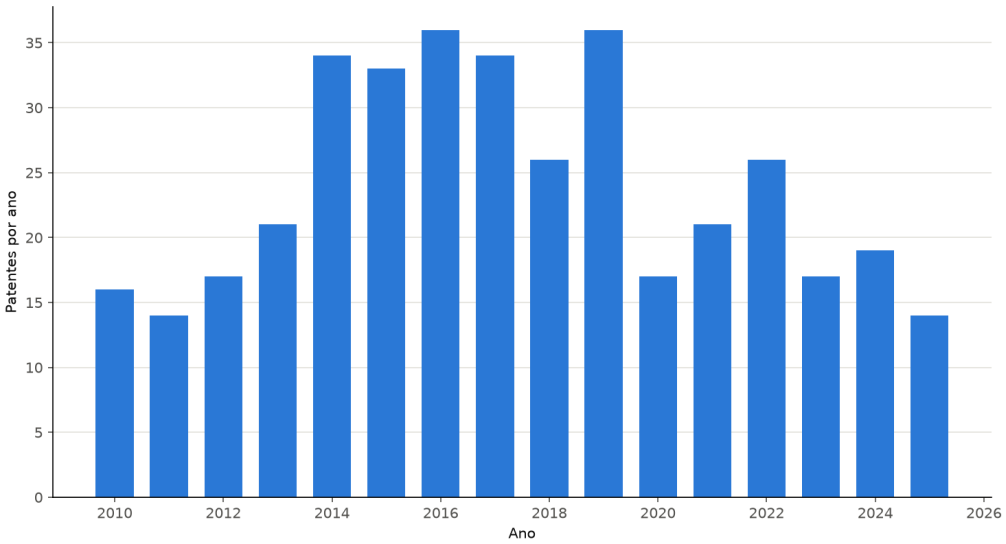

Fonte: O autor.

A área predominante é a Environmental Science, com 5.556 ocorrências, seguida por Chemical Engineering (3.944), Engineering (3.908) e Chemistry (3.824). Outras áreas com volume relevante de citações temáticas incluem Materials Science (3.644), Energy (2.524), Physics and Astronomy (1.436), Earth and Planetary Sciences (1.412), Agricultural and Biological Sciences (620) e Biochemistry, Genetics and Molecular Biology (476). Ressalta-se que esses totais superam o número líquido de publicações, haja vista que um mesmo artigo pode abranger múltiplas áreas do conhecimento.

## 6.2 Informações Tecnológicas

Foi identificado um total de 399 patentes no âmbito do tema catalisador de petróleo. A Figura 5 mostra a distribuição dos depósitos de patentes ao longo do tempo.

Figura 5: Histórico de depósitos de patentes (patentes por ano).

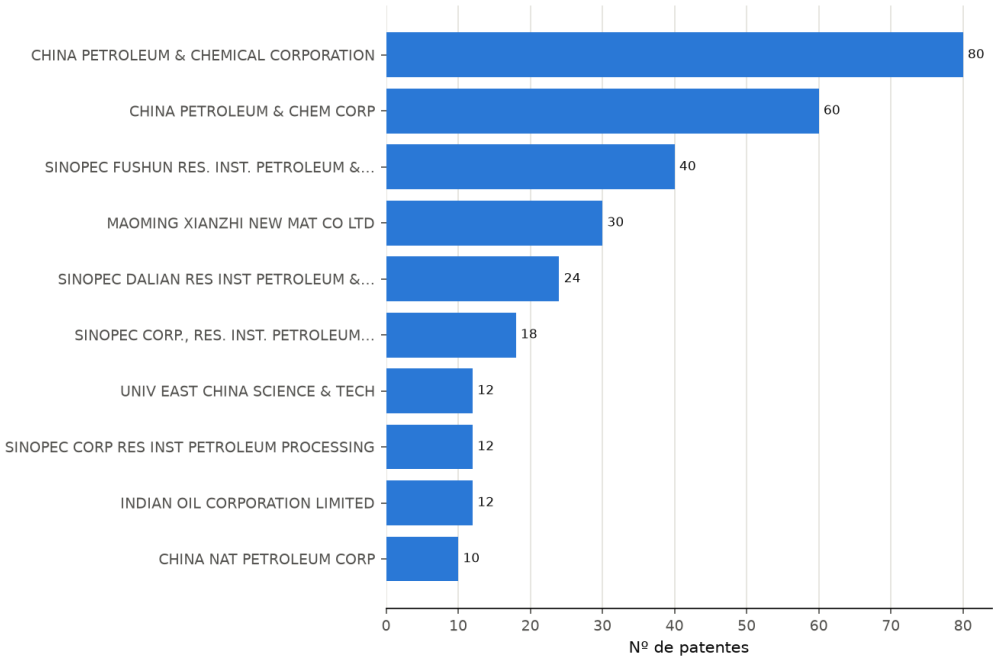



Fonte: O autor.

No recorte entre os anos de 2010 e 2025, identificaram-se 381 depósitos; observa-se um pico em 2019 com 36 registros, seguido por uma tendência que culminou em 14 depósitos no ano de 2025, o que indica a continuidade do interesse tecnológico na área.

A Figura 6 apresenta os principais depositantes de patentes no campo tecnológico pesquisado.

Figura 6: Top 10 depositantes de patentes.




Fonte: O autor.

O ranking de depositantes é liderado pela CHINA PETROLEUM & CHEMICAL CORPORATION, com 80 patentes; seguem-se as entidades CHINA PETROLEUM & CHEM CORP (60), SINOPEC FUSHUN RESEARCH INSTITUTE OF PETROLEUM & PETROCHEMICALS (40) e MAOMING XIANZHI NEW MAT CO LTD (30); completam a lista os depositantes SINOPEC DALIAN RES INST PETROLEUM & PETROCHEMICALS (24), SINOPEC CORP., RESEARCH INSTITUTE OF PETROLEUM PROCESSING (18), INDIAN OIL CORPORATION LIMITED (12), SINOPEC CORP RES INST PETROLEUM PROCESSING (12), UNIV EAST CHINA SCIENCE & TECH (12) e CHINA NAT PETROLEUM CORP (10).

O Quadro 3 detalha as classificações CPC mais frequentes relacionadas ao desenvolvimento de catalisadores de petróleo.

Quadro 3: 10 classificações (CPC) mais encontradas.



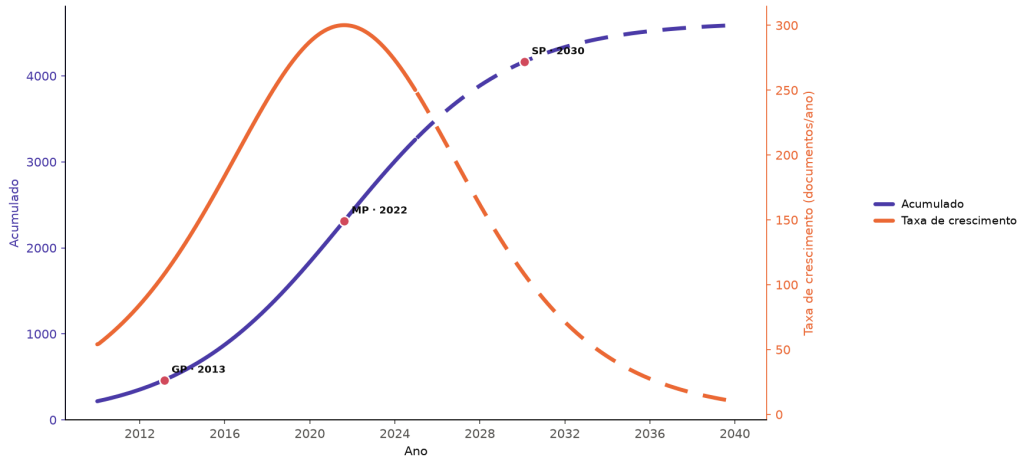

Fonte: O autor.

As classificações predominantes são B01J (CHEMICAL OR PHYSICAL PROCESSES, e.g. CATALYSIS OR COLLOID CHEMISTRY; THEIR RELEVANT APPARATUS), com 902 registros; C10G (CRACKING HYDROCARBON OILS; PRODUCTION OF LIQUID HYDROCARBON MIXTURES), com 430; C07C (ACYCLIC OR MACROCYCLIC COMPOUNDS) com 214; B01D (SEPARATION) com 122; B01F (MIXING, e.g. DISSOLVING, EMULSIFYING OR DISPERSING) com 102; C08G (MACROMOLECULAR COMPOUNDS OBTAINED OTHERWISE THAN BY REACTIONS ONLY INVOLVING UNSATURATED CARBON-TO-CARBON BONDS) com 82; C07D (HETEROCYCLIC COMPOUNDS) com 76; C08F (MACROMOLECULAR COMPOUNDS OBTAINED BY REACTIONS ONLY INVOLVING CARBON-TO-CARBON UNSATURATED BONDS) com 54; C22B (PRODUCTION AND REFINING OF METALS; PRETREATMENT OF RAW MATERIALS) com 54 e B32B (LAYERED PRODUCTS) com 42.

### 6.3 Tendências e Ciclo de Vida da Tecnologia

A Figura 7 mostra a distribuição das publicações científicas sobre catalisadores de petróleo ao longo do tempo.

Figura 7: Curva S relativa às informações científicas.

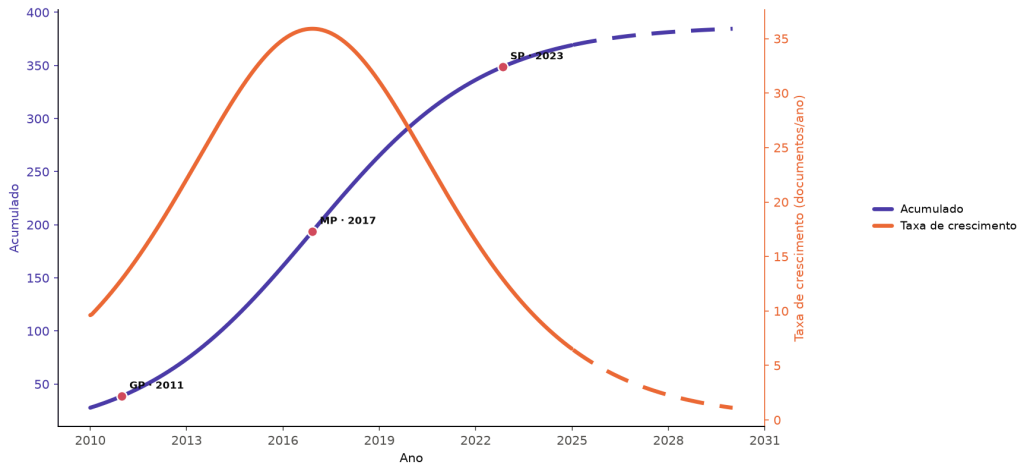



Fonte: O autor.

No total, foram identificadas 3.294 publicações científicas entre os anos de 2010 e 2025. A curva S indica que a tecnologia se encontra no estágio de maturidade (GP = 2013, MP = 2022, SP = 2030). O montante observado corresponde a 71,2% do platô estimado de 4.629 publicações científicas, o que denota um sólido interesse acadêmico e uma base teórica consolidada no desenvolvimento de soluções para a indústria petroquímica.

A Figura 8 apresenta os dados referentes aos depósitos de patentes relacionados à tecnologia de catalisadores de petróleo.

Figura 8: Curva S relativa às informações tecnológicas.




Fonte: O autor.

Nesse período, foram contabilizados 381 depósitos de patentes entre os anos de 2010 e

2025. A curva S identifica que a tecnologia está no estágio de saturação (GP = 2011, MP = 2017, SP = 2023). O total observado representa 98,3% do platô estimado de 388 patentes depositadas, o que indica que as soluções tecnológicas para o mercado já atingiram um alto nível de maturidade e proteção comercial.

A análise conjunta das curvas demonstra uma transição do foco científico para a aplicação prática e refinamento industrial. Enquanto a produção científica ainda percorre caminhos rumo à maturidade plena, a área de patentes confirma a consolidação de inovações tecnológicas no domínio comercial. Observa-se que as tendências atuais envolvem o desenvolvimento de sistemas para melhoria da vida útil dos catalisadores (LI et al., 2023), métodos avançados de preparação por moagem e processamento (THE, 2019) e a implementação de sistemas inteligentes no gerenciamento de aditivos (LI, 2022). Tais fatores apontam para uma busca contínua pela otimização de processos existentes, incluindo o tratamento de óleos sintéticos e produtos derivados do processo Fischer-Tropsch (AI et al., 2019; LIU et al., 2023).

## 7 CONCLUSÃO

A tecnologia de catalisador de petróleo encontra-se no estágio de SATURAÇÃO em seu ciclo tecnológico-industrial (patentes), coexistindo com um estágio de MATURIDADE avançada em sua vertente acadêmico-científica.

Os resultados da prospecção indicam um volume significativo de produção, com a identificação consolidada de 3.543 publicações científicas e 399 patentes depositadas. Observa-se uma evolução constante das publicações até o ano de 2024, enquanto os depósitos de patentes registraram pico em 2019. Identifica-se como principais atores a instituição College of Engineering na produção científica e a organização CHINA PETROLEUM & CHEMICAL CORPORATION no registro de patentes, com foco técnico nas áreas de Environmental Science e na classificação CPC B01J.

No âmbito nacional, não foram identificados depósitos de patentes no Brasil nem publicações científicas com afiliação brasileira na amostra analisada. Esse cenário aponta para uma carência de participação direta do país nas frentes protegidas internacionalmente.

A análise das curvas S projeta o ponto de saturação para as informações científicas no ano de 2030 e para os depósitos de patentes no ano de 2023. Diante da maturidade tecnológica, recomenda-se o monitoramento tecnológico contínuo e atenção a inovações de transição energética e reciclagem catalítica.

## 8 REFERÊNCIAS BIBLIOGRÁFICAS

AI, J. et al. Method and system for producing diesel oil and lubricant base oil through processing of Fischer-Tropsch synthetic oil. Depositante: SHENHUA GROUP CORP LTD. Patente, 2019.

AI, J. et al. Process for producing high-quality light white oil and diesel oil. Depositante: CHN ENERGY INVEST GROUP CO LTD. Patente, 2024.

ANDRADE, J. L.; MOURA, D. F. C.; BORSCHIVER, S. Estudo pré-prospectivo para Roadmap tecnológico sobre rádio cognitivo: evolução científico-patentária entre 1970-2017. Cadernos de Prospecção, v. 11, n. 3, p. 861, 2018.

BORSCHIVER, S.; LEMOS, A. Technology Roadmap: planejamento estratégico para alinhar mercado-produto-tecnologia. Rio de Janeiro, RJ: Ed. Interciência, 2016.

BROWN, T. B. et al. Language models are few-shot learners. Advances in Neural Information Processing Systems, v. 33, p. 1877-1901, 2020. Disponível em: https://arxiv.org/abs/2005.14165.

CHAO, A. Nonparametric estimation of the number of classes in a population. Scandinavian Journal of Statistics, v. 11, n. 4, p. 265-270, 1984.

CORMACK, G. V.; CLARKE, C. L. A.; BUETTCHER, S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In: INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 32., 2009, Boston. Proceedings. New York: ACM, 2009. p. 758-759.

DAIM, T. U.; RUEDA, G. R.; MARTIN, H. T. Technology forecasting using bibliometric analysis and system dynamics. Technology Management: A Unifying Discipline for Melting the Boundaries, 2005. Disponível em: https://ieeexplore.ieee.org/document/1509681.

EFRON, B. Bootstrap methods: another look at the jackknife. The Annals of Statistics, v. 7, n. 1, p. 1-26, 1979.

ERNST, H. The use of patent data for technological forecasting: the diffusion of CNC-technology in the machine tool industry. Small business economics, v. 9, n. 4, p. 361-381, 1997.

FISHER, J. C.; PRY, R. H. A simple substitution model of technological change. Technological Forecasting and Social Change, v. 3, p. 75-88, 1971.

FRANTZI, K.; ANANIADOU, S.; MIMA, H. Automatic recognition of multi-word terms: the C-value/NC-value method. International Journal on Digital Libraries, v. 3, n. 2, p. 115-130, 2000.

FRANÇA JR., J. A.; GALDINO, J. Gestão de sistemas de material de emprego militar. Coleção Meira Mattos: revista das ciências militares, v. 13, n. 47, p. 155-176, 2019.

GAO, Y. et al. Retrieval-augmented generation for large language models: a survey. arXiv, arXiv:2312.10997, 2024. Disponível em: https://arxiv.org/abs/2312.10997.

GROOTENDORST, M. KeyBERT: minimal keyword extraction with BERT. Zenodo, 2020. DOI: 10.5281/zenodo.4461265.

JI, Z. et al. Survey of hallucination in natural language generation. ACM Computing Surveys, v. 55, n. 12, art. 248, 2023.

KUCHARAVY, D.; DE GUIO, R. Application of S-shaped curves. Procedia Engineering, v. 9, p. 559-572, 2011.

LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, v. 33, p. 9459-9474, 2020. Disponível em: https://arxiv.org/abs/2005.11401.

LEZAMA-NICOLÁS, R. et al. A bibliometric method for assessing technological maturity: the case of additive manufacturing. Scientometrics, v. 117, n. 3, p. 1425-1452, 2018.

LI, W. et al. Regeneration method of aromatic hydrocarbon refining catalyst, regenerated catalyst and application. Depositante: CHINA PETROLEUM & CHEM CORP. Patente, 2023.

LI, Y. Intelligent production system for oil refining catalyst auxiliary agent. Depositante: MAOMING XIANZHI NEW MAT CO LTD. Patente, 2022.

LINDEN, R.; BARBOSA, L. F.; DIGIAMPIETRI, L. A. “Brazilian style science”: an analysis of the difference between Brazilian and international Computer Science departments and graduate programs using social networks analysis and bibliometrics. Social Network Analysis and Mining, v. 7, p. 1-19, 2017.

LIU, S. et al. Catalytic cracking light cycle oil refining catalyst system and application thereof. Depositante: CHINA PETROLEUM & CHEM CORP. Patente, 2023.

LUO, Y. Formula, manufacturing process and device of catalyst pellets for oil refining. Depositante: YANGZHOU MENGFEI ENVIRONMENTAL PROTECTION TECH CO LTD. Patente, 2020.

MADEO, F. C. B. Prospecção tecnológica utilizando a análise multicritério e técnicas bibliométricas: estudo de caso para o setor de Defesa. 2019. 144 p. Dissertação (Mestrado em Engenharia de Defesa) - Instituto Militar de Engenharia, Rio de Janeiro, 2019.

NIETO, M.; LÓPEZ, F.; CRUZ, F. Performance analysis of technology using the S curve model: the case of digital signal processing (DSP) technologies. Technovation, v. 18, n. 6-7, p. 439-457, 1998.

PORTER, A. L. QTIP: Quick technology intelligence processes. Technological Forecasting and Social Change, v. 72, n. 9, p. 1070-1081, 2005.

REIMERS, N.; GUREVYCH, I. Sentence-BERT: sentence embeddings using siamese BERT-networks. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE

PROCESSING (EMNLP), 2019, Hong Kong. Proceedings. Stroudsburg: Association for Computational Linguistics, 2019. p. 3982-3992.

ROBERTSON, S.; ZARAGOZA, H.; TAYLOR, M. Simple BM25 extension to multiple weighted fields. In: ACM INTERNATIONAL CONFERENCE ON INFORMATION AND KNOWLEDGE MANAGEMENT (CIKM), 13., 2004, Washington. Proceedings. New York: ACM, 2004. p. 42-49.

SCHOPF, T.; KLIMEK, S.; MATTHES, F. PatternRank: leveraging pretrained language models and part of speech for unsupervised keyphrase extraction. In: INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND INFORMATION RETRIEVAL (KDIR), 14., 2022, Valletta. Proceedings. Setúbal: SciTePress, 2022. p. 243-248.

THE, I. H. W. T. R. T. B. C. Petroleum refining catalyst preparation technology. Depositante: ZHANG JIAJUN. Patente, 2019.

VASWANI, A. et al. Attention is all you need. Advances in Neural Information Processing Systems, v. 30, 2017. Disponível em: https://arxiv.org/abs/1706.03762.

WANG, C. et al. High-viscosity lubricating oil base oil and preparation method thereof. Depositante: DALIAN INST CHEM & PHYSICS CAS. Patente, 2020.

WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. Advances in Neural Information Processing Systems, v. 35, p. 24824-24837, 2022. Disponível em: https://arxiv.org/abs/2201.11903.

WHITE, J. et al. A prompt pattern catalog to enhance prompt engineering with ChatGPT. arXiv, arXiv:2302.11382, 2023. Disponível em: https://arxiv.org/abs/2302.11382.

XIA, B. et al. Production method of hydraulic oil. Depositante: HAINAN HANDI SUNSHINE PETROCHEMICAL CO LTD. Patente, 2019.

YOU, Y. Novel petroleum refining catalyst preparation device. Depositante: ENSHI PENN RENEWABLE ENERGY SCIENCE AND TECH LIMITED COMPANY. Patente, 2022.

ZHAO, W. X. et al. A survey of large language models. arXiv, arXiv:2303.18223, 2023. Disponível em: https://arxiv.org/abs/2303.18223.

Rio de Janeiro, 25 de setembro de 2026.

Elaborado por:

**JOÃO PEDRO BANDEIRA BELCHIOR – 1º Ten**
Al 5º ano/Comp

Revisado por:

**CARLOS ALEXANDRE SIQUEIRA DE ALMEIDA – Cap**
Al 5º ano/Comp

APROVO:

**GISELE DE FARIAS ROSA – Maj**
Coorientadora Externa

## B.7 Análise Crítica e Inconsistências Observadas no Relatório Gerado

A análise minuciosa do documento técnico gerado automaticamente pelo sistema para este estudo de caso específico (tema: *catalisadores de refino de petróleo*; REPTEC 001/2026, apresentado na subsecção anterior) permitiu identificar um conjunto de inconsistências quantitativas, metodológicas e de extração textual. As observações seguintes referem-se exclusivamente ao comportamento do sistema neste caso de estudo e não constituem avaliação generalizada de todos os cenários de uso. Estes desvios evidenciam os limites operacionais atuais da solução e justificam a necessidade de supervisão humana nas decisões estratégicas:

a. **Discrepâncias Amostrais e Recorte Temporal:** O relatório apresenta uma divergência entre o universo global de registos indexados (3.543 artigos e 399 patentes) e os montantes analisados nas séries históricas das curvas S (3.294 artigos e 381 patentes). O texto corrido gerado pelo modelo não elucida a exclusão do ano em curso ou de anos parciais, gerando ambiguidade na interpretação dos totais bibliométricos.

b. **Fragmentação e Duplicação de Entidades (Depositantes):** No mapeamento dos principais atores tecnológicos, a ausência de normalização léxica levou à divisão de uma mesma instituição em múltiplas entradas distintas do *ranking*. Observam-se cisões para a *Sinopec* (computada separadamente como *China Petroleum & Chemical Corporation* e *China Petroleum & Chem Corp*), bem como para institutos de investigação associados, distorcendo a real concentração de patentes.

c. **Generalização Indevida de Afiliações Acadêmicas:** A liderança no volume de publicações científicas foi atribuída à entidade genérica *"College of Engineering"*. Trata-se de uma falha de desambiguação nos metadados de afiliação da base de origem, que registou a denominação de um departamento interno em vez da universidade-mãe.

d. **Sobreposição Numérica em Áreas Multidisciplinares:** O somatório das frequências nos quadros temáticos excede largamente o universo absoluto de documentos recolhidos. O texto omite a ressalva metodológica essencial de que as categorias do Scopus e CPC não são mutuamente exclusivas (um mesmo documento abrange múltiplos domínios do conhecimento).

e. **Divergência Diagnóstica do Ciclo de Vida da Tecnologia (CVT):** Na síntese final, o relatório conclui de forma taxativa que a tecnologia se encontra no estágio de **Saturação**. Esta leitura apoia-se unicamente no indicador patentário (comercial), desconsiderando o descompasso com a trajetória bibliográfica (artigos científicos), cujo ajuste logístico projeta a saturação apenas para 2030, caracterizando ainda um regime de maturidade ativa.

f. **Ruído de Extração em Metadados Bibliográficos:** Identificou-se a presença de uma autoria espúria nas citações e referências (*"THE, I. H. W. T. R. T. B. C."*), decorrente da conversão inadequada de fragmentos descritivos do resumo de uma patente (*"The invention relates to..."*) como se fossem o apelido de um inventor.

# APÊNDICE C – MANUAL VISUAL E TELAS DA INTERFACE GRÁFICA DO SISTEMA AGIA

## C.1 Gestão de Sessões e Parametrização Inicial

O sistema disponibiliza um painel de gestão que reúne o histórico de todas as sessões de prospecção iniciadas (Figura 19), permitindo acompanhar o estado de execução, o total de iterações e a auditoria do consumo acumulado de *tokens*.

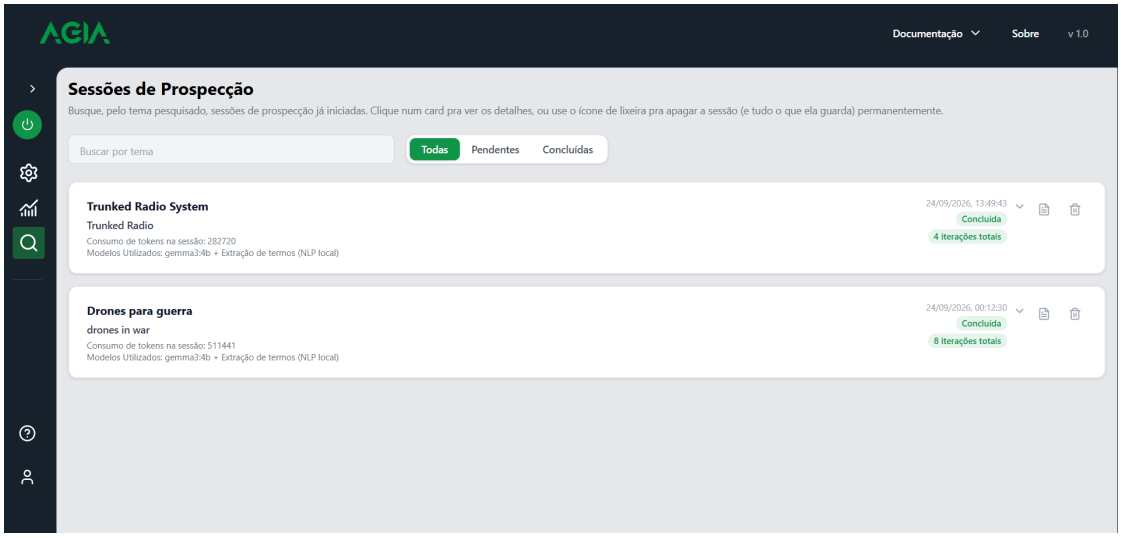



Figura 19: Painel de histórico e auditoria de sessões de prospecção.

O fluxo guiado (*wizard*) inicia-se pela submissão do tema e parâmetros complementares (Figura 20). Com base nas entradas, o modelo de linguagem propõe quatro variações estruturadas para escolha ou ajuste do utilizador (Figura 21).




Figura 20: Formulário inicial de parametrização da pesquisa.

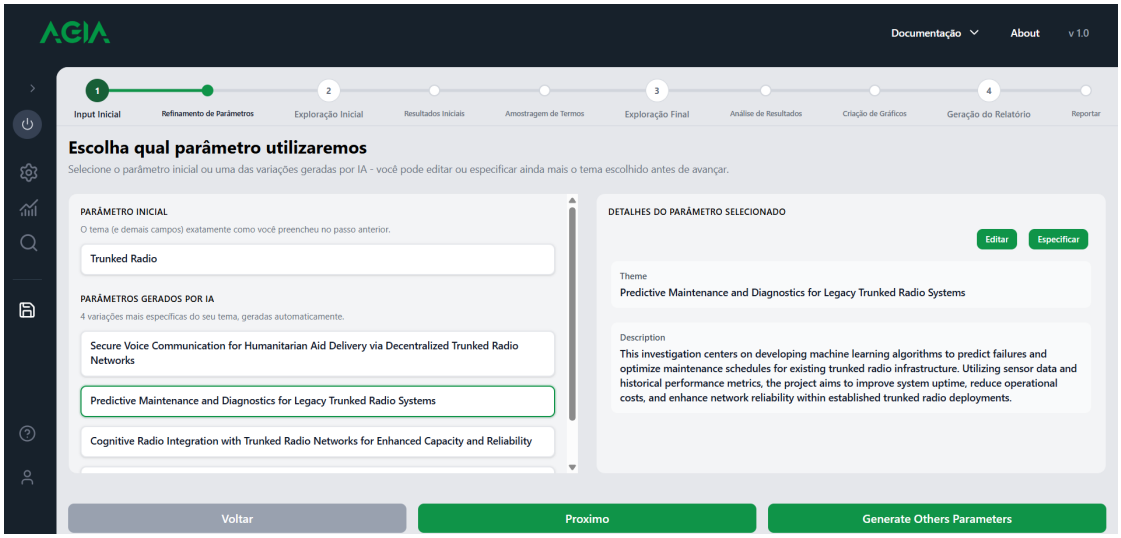



Figura 21: Selecção e edição das variações temáticas sugeridas por IA.

## C.2 Busca Exploratória e Triagem de Resultados

Na etapa de exploração, as consultas preliminares geradas para OPS e Scopus são apresentadas para inspeção e edição manual (Figura 22). Os documentos recuperados nessa fase são consolidados em painéis que exibem a cobertura temporal, classificações e metadados detalhados de títulos e autores (Figura 23).

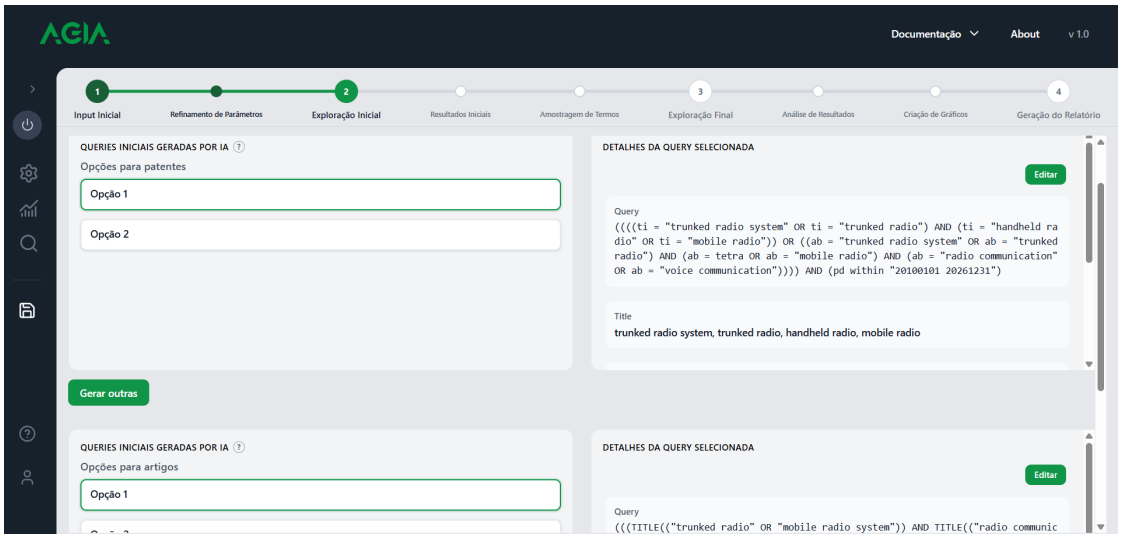



Figura 22: Painel de revisão das consultas exploratórias geradas por IA.

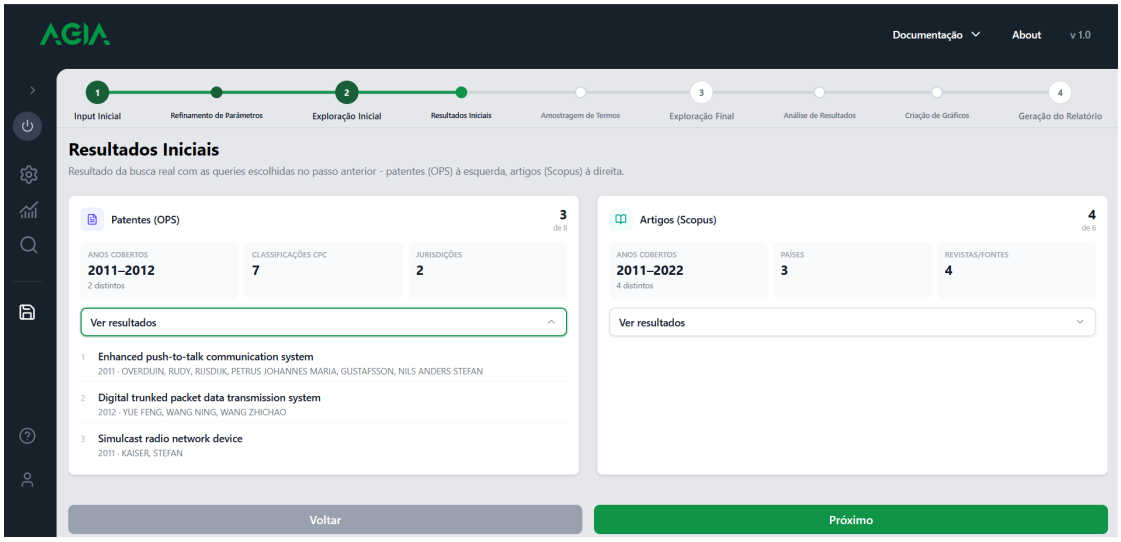



Figura 23: Resultados da busca exploratória com expansão detalhada de documentos.

## C.3 Mineração de Termos e Sintaxe da Busca Final

A partir da amostra exploratória, o pipeline local de PLN extrai e pontua palavras-chave técnicas por RRF (Reciprocal Rank Fusion — fusão de rankings lexical e semântico), disponibilizando-as para seleção pelo utilizador com ajuste da abrangência da pesquisa (Figura 24). Em seguida, a consulta final é montada, exibindo o diagnóstico de complexidade e validação de sintaxe booleana (Figura 25).

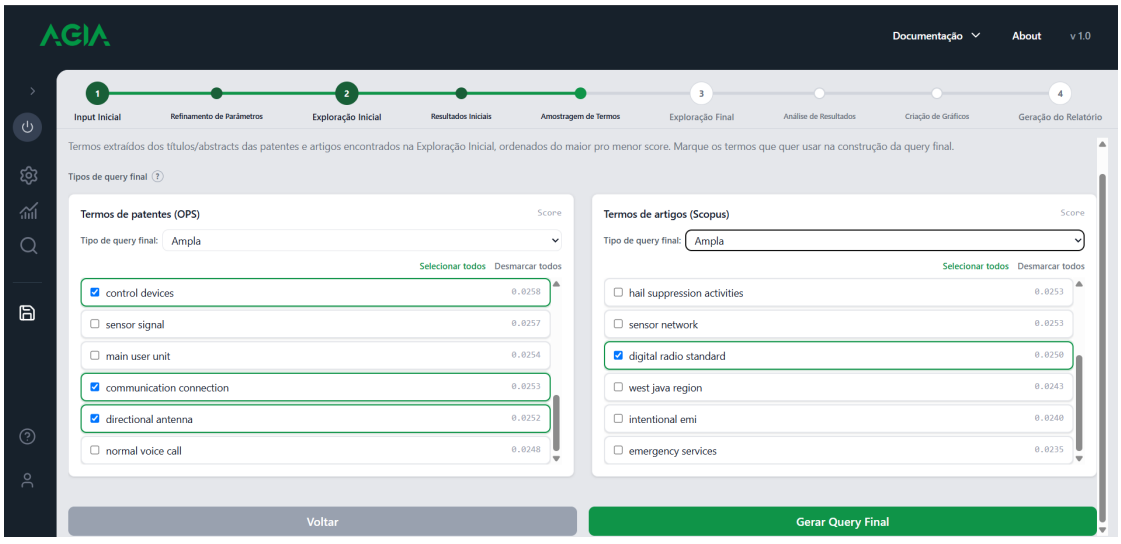



Figura 24: Painel de selecção de termos minerados por PLN e controlo de abrangência.

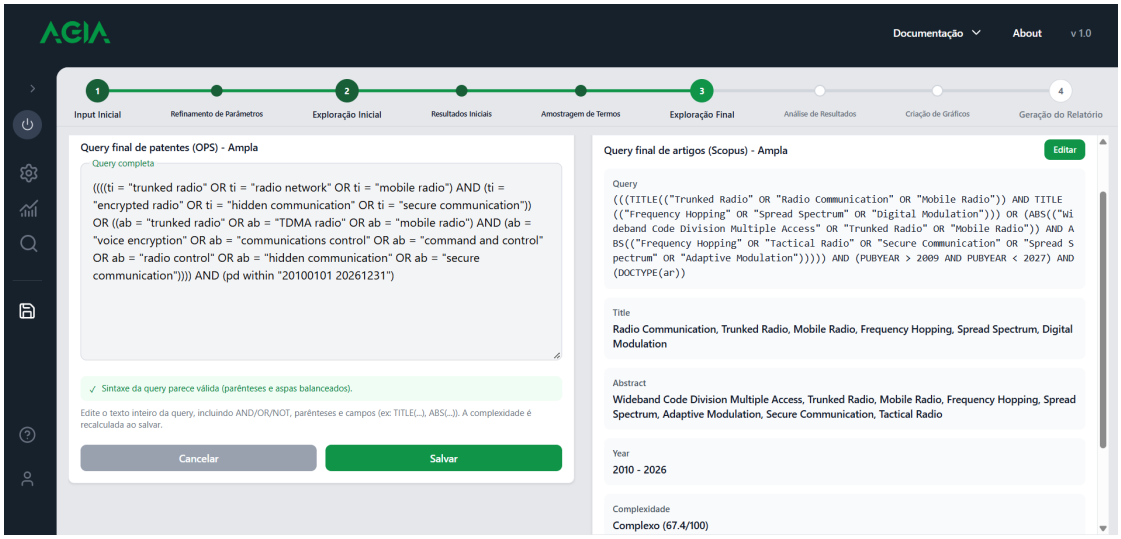



Figura 25: Editor da consulta booleana final com verificação automática de complexidade e sintaxe.

## C.4 Indicadores Bibliométricos e Curvas S

A submissão definitiva processa a série histórica e projeta as curvas S do ciclo de vida tecnológico na interface gráfica, viabilizando o ajuste paramétrico de projeções futuras e o descarregamento das ilustrações (Figura 26).

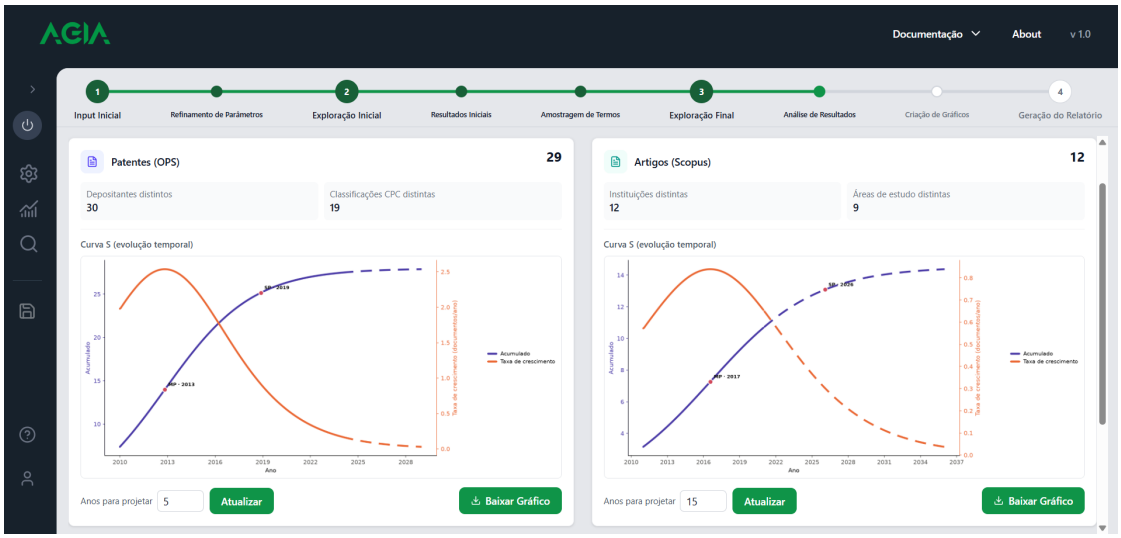



Figura 26: Visualização gráfica das curvas S temporais de patentes e artigos no *frontend*.

## C.5 Geração Textual via RAG, Edição LaTeX e Revisão

A etapa de confecção do relatório compreende a inserção de metadados institucionais (Figura 27) e o acompanhamento modular da geração via RAG local (Figura 28).

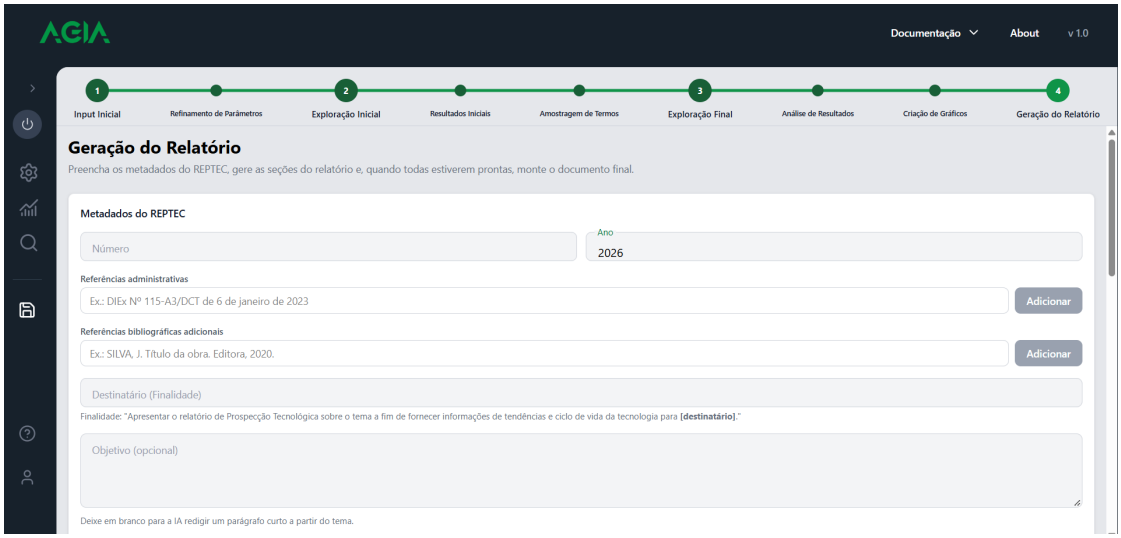



Figura 27: Formulário de metadados administrativos e estruturais do REPTEC.

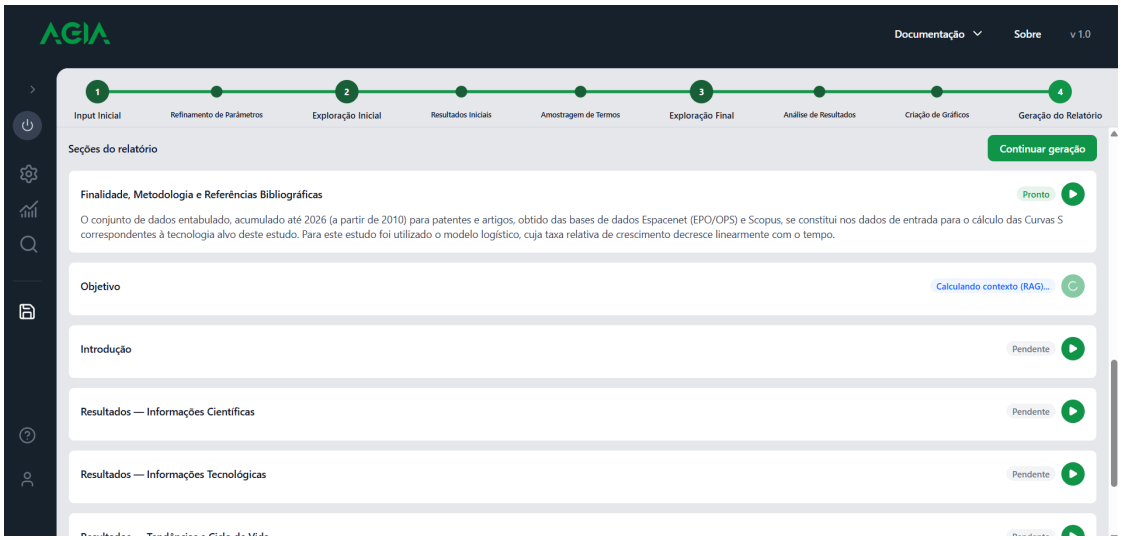



Figura 28: Esteira assíncrona de redação do relatório secção por secção.

O documento compilado é carregado num editor LaTeX embutido na interface, dotado de galeria lateral de figuras e exportação em pacote compactado (Figura 29). Na barra de ferramentas, o módulo de revisão interativa aciona o LanguageTool para apontar correções ortográficas e gramaticais antes da compilação final (Figura 30).

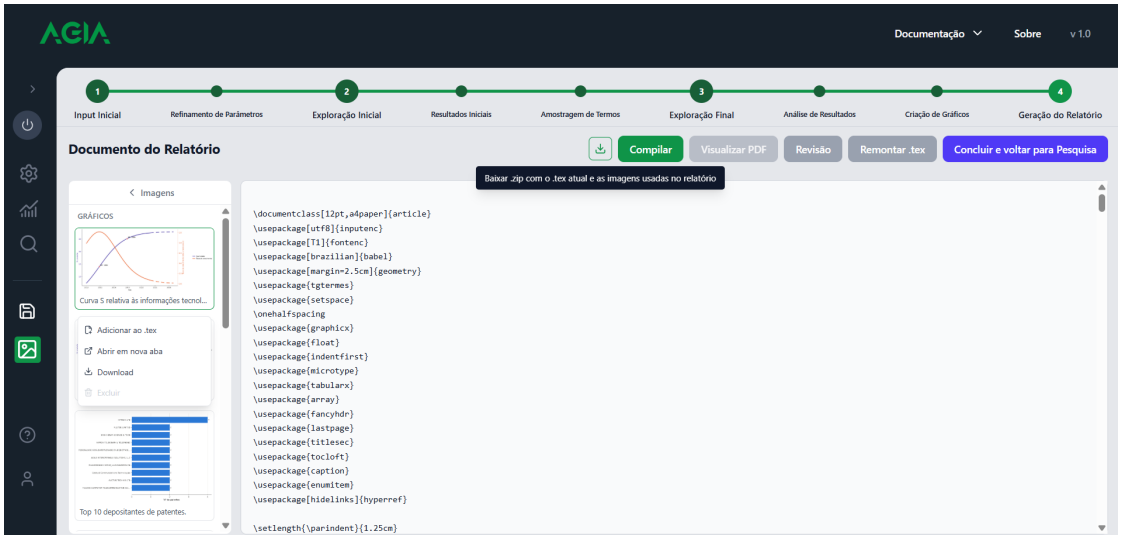



Figura 29: Ambiente integrado de edição de código LaTeX com galeria de gráficos.

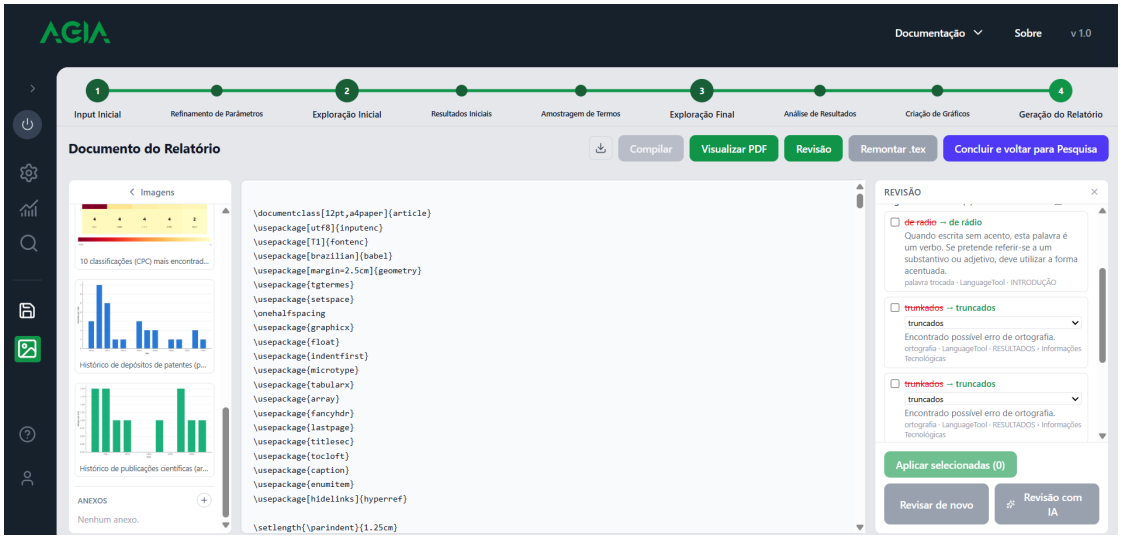



Figura 30: Módulo de revisão ortográfica e estilística com apontamentos interativos.

## C.6 Configurações Globais e Ponto de Uso de Modelos

Por fim, a secção administrativa do sistema viabiliza o mapeamento dinâmico dos modelos de linguagem por ponto de uso (Figura 31) e a parametrização de diretivas globais, como idioma de inspeção e modelo de representação vetorial (Figura 32).

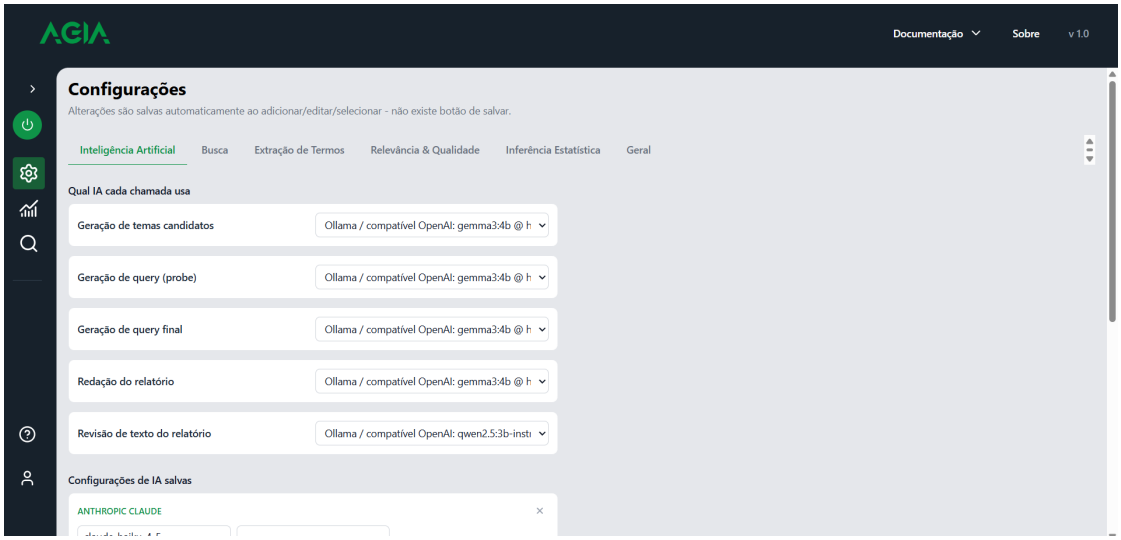



Figura 31: Painel de vinculação e configuração de modelos de linguagem por ponto de uso.

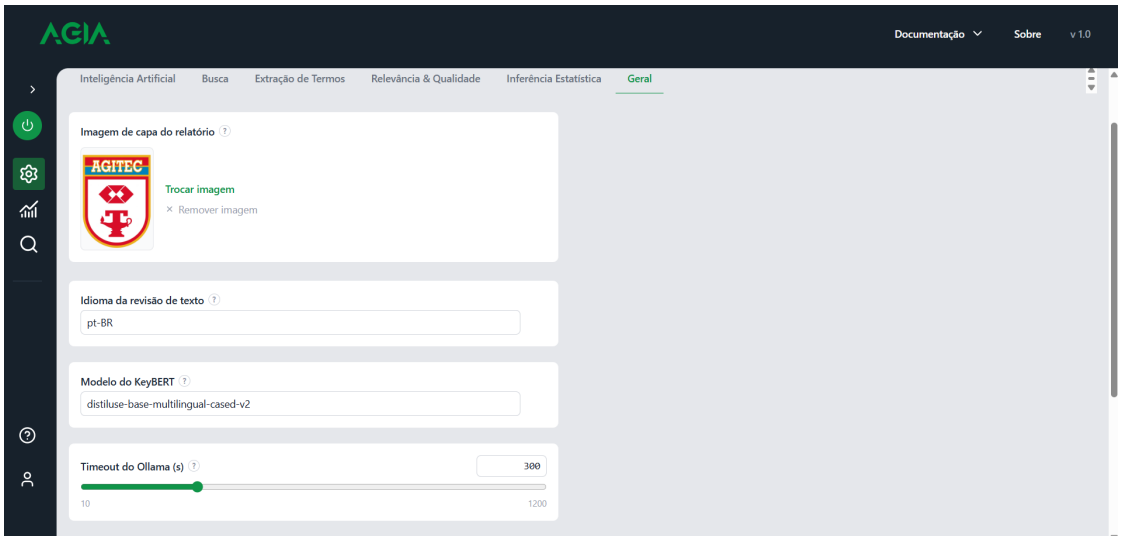



Figura 32: Painel de configurações gerais: imagem institucional, idioma e modelo vetorial.